

TP1 · Insurance Charges

Regresión, validación cruzada y
regularización

Problema y datos

Objetivo: predecir el costo anual charges.

1.338 casos originales

1.337 casos únicos

1.203 desarrollo · 90 %

134 test · 10 %

- Numéricas: age, bmi, children.
- Categóricas: sex, smoker, region.
- Quitamos una copia exactamente duplicada.
- Estratificamos por smoker.
- Semilla reproducible: 42.

[P01, pp. 1-2] [D01]

Train, validación y test

Train → aprende parámetros

Validación → elige grado y λ

Test → estima una vez el rendimiento final


Usamos **10-fold cross-validation** sólo sobre desarrollo:

Cada caso participa una vez en validación y nueve veces en entrenamiento.

El preprocesamiento se ajusta dentro de cada fold. Así evitamos que validación o test informen al modelo durante el entrenamiento.

[T02, pp. 85, 89, 94–96] [T03, pp. 12, 15]

Qué encontramos en el EDA



- Sin faltantes ni categorías inesperadas.
- Los `charges` altos pertenecían principalmente a fumadores.
- IQR por grupo mostró dos distribuciones distintas.
- Conservamos outliers plausibles y las seis variables.

[T02, pp. 39-42]

Pipeline y métrica

Dentro de cada fold:

1. Numéricas → estandarización.
2. Categóricas → one-hot.
3. Polinomio → grados 1, 2 o 3.
4. Para L1 → escalar los términos.
5. Regresión → ajustar coeficientes.


RMSE

Raíz del promedio de los errores cuadrados.

- Mismas unidades que `charges`.
- Penaliza más los errores grandes.
- Se calcula en train y validación.

[T02, p. 52] [T03, p. 87]

¿Qué grado generaliza mejor?



- Grado 2 mejora aproximadamente 20 % frente al lineal.
- Grado 3 baja train, pero empeora validación.
- La brecha crece de 114 a 430.


Señal de complejidad excesiva.

[T02, pp. 52–53, 76–77]

Regularización L1

Error cuadrático + penalización L1

- Elegimos $\lambda = 100$ por validación.
- Mejora modesta: 0,74 %.
- Reduce coeficientes activos.
- $\lambda = 1000$ subajusta.



[T03, p. 90]

Modelo seleccionado

Grado 2 + L1 + $\lambda = 100$

4.847,19 · train final

4.872,42 $\pm$ 776,46 · validación
CV

3.957,83 · test independiente

- Reentrenamos con 1.203 casos.
- Quedaron 22 de 44 coeficientes.
- Test se consultó una sola vez.
- No retocamos el pipeline después.

[P01, pp. 2-3] [T02, pp. 88-89]

Conclusiones

- 1. Menor error:** grado 2 con L1 y $\lambda = 100$.
- 2. Modelo para una aplicación:** el mismo; mejora al lineal y evita la brecha del grado 3.
- 3. RMSE a comunicar:** 3.957,83 sobre test independiente.

Cautela: test contiene sólo 134 casos. El resultado fue más favorable que el promedio de validación, por lo que es una estimación y no una garantía exacta.

Idea central: elegimos con validación; estimamos generalización con test.

Apéndice · ¿Qué se optimizó?

Regresión lineal / polinómica sin L1

- Minimiza la suma de residuos cuadrados.
- La regresión sigue siendo lineal en los coeficientes aunque las entradas tengan potencias e interacciones.

Lasso

- Minimiza error cuadrático + penalización L1.
- `scikit-learn` llama `alpha` al λ de nuestra presentación.
- Usa descenso por coordenadas.
- Con $\lambda = 100$ quedaron 22 coeficientes activos.

[T02, pp. 49–52] [T03, p. 90]

Apéndice · Decisiones defendibles

¿Por qué 10 % para test?

Priorizamos desarrollo para entrenar mejor en cada fold; aceptamos mayor variabilidad final.

¿Por qué estratificar por smoker?

Es la variable que más separa charges; estabiliza su proporción sin usar el objetivo para formar los grupos.

¿Por qué conservar outliers?

Eran plausibles y estructurales, no errores de carga. Quitarlos habría cambiado la población objetivo.

¿Por qué ajustar escalado dentro del fold?

Para impedir leakage desde validación hacia entrenamiento.