

TP2 · Bank Marketing

Clasificación supervisada: ¿a qué clientes llamar?

Problema y datos

Objetivo: predecir si el cliente contrata un plazo fijo (y) para priorizar a quién llamar.


- **41.188** llamadas · 20 variables · **11,3 %** respondió que sí · quitamos 12 duplicados exactos.
- Split estratificado por y , semilla 42: **32.940** desarrollo (80 %) · **8.236** test (20 %).

Qué datos usamos en cada etapa

- **EDA y decisiones** → sólo desarrollo.
- **Modelo, hiperparámetros y umbral** → 5-fold CV en desarrollo.
- **Desempeño esperado** → test, una sola vez.

[P02, p. 1] [D02] [T02, p. 89]



Los datos cambian con el tiempo



- De **4,8 %** (2008) a **52,1 %** (2010) de "yes".
- Los índices macro funcionan como un reloj: r de 0,91 a 0,97.
- **Split aleatorio estratificado**, como pide la consigna.
- Test será optimista para campañas futuras: lo medimos al final.

[D03] [P02, p. 2]


Del EDA a las decisiones



- Excluimos housing, loan, day_of_week, pdays y emp.var.rate.
- unknown como categoría: default desconocido acepta 5,3 % vs. 12,8 %.
- log1p en campaign y previous.
- Edad en U: relación no lineal.
- Verificado por CV: nr.employed volvió (+0,007 en NB).

[P02, p. 1] [T09, p. 39]

duration: leakage



- Se conoce **al terminar** la llamada.
- Con ella, RF pasa de 0,766 a **0,938** de AUC.
- Ese número no es alcanzable antes de llamar.
- **La excluimos de todos los modelos.**


[D03] [P02, p. 1]

Pipeline, validación y métricas

- **Pipeline por fold:** transformaciones fijas (exclusiones, `default_no`, `log1p`) → escalado → one-hot, o discretización en NB categórico → modelo.
- **5 folds estratificados:** ~742 positivos por fold.
- **AUC:** priorizar es ordenar clientes; al azar vale 0,5.
- **Recall:** perder un interesado (FN) cuesta más que una llamada de más (FP).
- **Accuracy no:** “siempre no” acierta el 88,7 % sin encontrar a nadie.
- **Umbral:** punto de la curva ROC más cercano a (0, 1), con predicciones out-of-fold de desarrollo.

[T02, pp. 94, 96] [T04, pp. 26, 41, 51, 52]



Comparación de modelos



- **RF** gana en AUC y en recall.
- **SVM**: balancear clases lo lleva de 0,700 a 0,777.
- **KNN**: k pasa de 5 a 321.
- **NB categórico**: 0,780 sin ajustar.

[P02, p. 2]

Sobreajuste y subajuste




- **RF sin límite:** train 0,999
· validación 0,766 → sobreajuste.
 - max_depth = 2: subajuste leve.
 - Elegimos max_depth = 10.
 - **KNN con k = 1** memoriza; con k grande la brecha se cierra.
- [T07, p. 50] [T09, p. 29]

Modelo final en test

Test: 8.236 clientes

llamar	TP 666	FP 1.555
no llamar	FN 262	TN 5.753
	real: yes	real: no





RF · profundidad 10 · 400
árboles · umbral 0,084

- Reentrenado con desarrollo; test consultado **una vez**.
- **AUC 0,809** (0,791–0,826)
- **Recall 0,718** (0,691–0,746)
- Precisión 0,300 vs. 0,113 llamando a todos.

*IC 95 % bootstrap · [T02,
p. 88]*

Limitación: el modelo aprende el período



- Índices macro y `month`: **59 %** de la importancia.
- Entrenado con 2008–2009, el AUC en 2010 cae a **0,678**.
- Con el umbral fijo llamaría al **100 %** de 2010.


[T07, p. 71]

Conclusiones

1. **RF** captura no linealidades (edad) e interacciones, no necesita escalar, y limitar la profundidad controló el sobreajuste.
2. **Supuestos:** NB sufre la correlación (`euribor3m-nr.employed`: 0,94) y las binarias no gaussianas; KNN, la superposición de clases y las 46 dimensiones; SVM, el desbalance.
3. **Errores:** FN = depósito perdido; FP = llamada fallida. En test: 262 FN y 1.555 FP, es decir 2,3 llamadas fallidas por éxito vs. 7,9 llamando a todos.
4. **Mejoras:** validación temporal y reentrenamiento, umbral por costo o capacidad, más información previa a la llamada.

Esperamos $AUC \approx 0,81$ y $recall \approx 0,72$ para clientes como los de 2008-2010; menos para campañas futuras.

Apéndice · SVM y desbalance



- Sin balanceo: validación de 0,70 a 0,71 con cualquier C.
- Con `balanced`, un error en un positivo pesa ~4,4 y en un negativo ~0,56.
- C grande sube train y abre la brecha.
- Kernels con $C = 0, 1$:
lineal 0,769 · polinómico 0,777 · RBF 0,777.

[T08, p. 49]

Apéndice · Exclusiones verificadas por CV

Cambio de AUC de validación al agregar cada grupo al conjunto del EDA. Con el RF ajustado, housing, loan y day_of_week tampoco mejoran (0,7979 vs. 0,7984). [P02, p. 1]

Grupo agregado	NB gauss.	NB categ.	RF	KNN
pdays	+0,000	0,000	−0,001	0,000
housing, loan, day_of_week	−0,001	0,000	+0,007	−0,008
nr.employed	+0,007	+0,004	0,000	0,000
emp.var.rate + nr.employed	+0,009	+0,003	−0,002	−0,001

Apéndice · Decisiones defendibles

- **¿Por qué no un split temporal?** Test tendría 31–46 % de positivos frente a 6–7 % en desarrollo: mezclaría la calidad del modelo con el cambio de distribución. Lo medimos aparte.
- **¿Por qué un umbral tan bajo (0,084)?** Con 11 % de positivos, el umbral 0,5 deja al RF con recall 0,23.
- **¿Por qué AUC y no accuracy?** “Siempre no” acierta 88,7 % sin encontrar ningún interesado.
- **¿Por qué test dio mejor que CV?** 0,809 vs. 0,798 está dentro de la variabilidad (IC 95 %: 0,791–0,826). No cambiamos nada después de mirarlo.