

Trabajo Práctico 1: Regresión e Introducción a la evaluación de modelos

Materia: 72.75 Aprendizaje Automático (Machine Learning)

Fecha de defensa: 26/08/26

En este trabajo práctico se implementarán modelos de regresión para predecir una variable numérica a partir de un conjunto de datos. El objetivo principal es **aprender a entrenar y evaluar modelos utilizando validación cruzada**.

Introducción teórica

Esta información deberá estar contenida en la presentación (brevemente):

1.1 Separación train-validación-test: qué es y porque es necesario

La presentación durará 10 minutos + 8 minutos de preguntas.

*mandar la presentación y el código 24 horas antes de la clase en la que se presentará el TP

0. Elección del Dataset.

Para este trabajo práctico deberán elegir uno de los siguientes datasets y trabajar con él durante todo el TP. Todos permiten resolver el mismo problema: predecir una variable numérica a partir de otras variables del dataset utilizando los modelos de regresión vistos en clase.

0.1. Bike Sharing

Este dataset corresponde a un sistema de alquiler de bicicletas. Contiene variables relacionadas con el clima y el calendario (temperatura, humedad, estación del año, día laboral, etc.), y el objetivo es predecir la cantidad de bicicletas alquiladas en un momento determinado. El dataset, así como más información sobre el mismo, está disponible en el UCI Machine Learning Repository: <https://archive.ics.uci.edu/ml/datasets/bike+sharing+dataset>

0.2. Insurance Charges

Este dataset contiene información de personas (edad, BMI, número de hijos, hábito de fumar, región, etc.) y el objetivo es predecir el costo anual de gastos médicos (charges). Es un problema de regresión muy común en ejemplos de machine learning aplicado a datos de salud y seguros. El dataset, así como más información sobre el mismo, está disponible en Kaggle:

<https://www.kaggle.com/datasets/mirichoi0218/insurance>

0.3. Wine Quality

Este dataset contiene propiedades físico-químicas del vino (acidez, pH, densidad, alcohol, sulfatos, entre otras). El objetivo es predecir la calidad del vino a partir de estas características. El dataset, así como más información sobre el mismo, está disponible en el UCI Machine Learning Repository: <https://archive.ics.uci.edu/ml/datasets/wine+quality>

1. Limpieza de datos

Antes de entrenar los modelos es necesario analizar y preparar el dataset.

1.1 Variables categóricas

Identificar si el dataset contiene variables categóricas. En caso afirmativo, aplicar una estrategia adecuada para poder utilizarlas en los modelos (por ejemplo: codificación one-hot). Justificar la elección.

1.2 Valores faltantes

Analizar si existen valores faltantes en el dataset. En caso de encontrarlos, indicar qué estrategia se utilizará para tratarlos (por ejemplo: eliminación de filas, imputación, etc.) y justificar la decisión.

1.3 Outliers

Analizar la posible presencia de valores atípicos en las variables numéricas. Indicar qué criterio se utiliza para detectarlos y justificar si se eliminan o se mantienen.

1.4 Características

Decidir qué características del dataset se incluyen (pueden ser todas) y aplicar el escalado si procede (justificar ambas decisiones).

2. Regresión lineal

2.1 Separación de datos. Separar el dataset en un conjunto de **entrenamiento (train)** y un conjunto de **test**. Explicar cómo se han separado y porque.

2.2 Validación cruzada. Implementar un esquema de **k-fold cross-validation** utilizando únicamente el conjunto de entrenamiento.

2.3 Entrenamiento del modelo. Entrenar un modelo de **regresión lineal** dentro de la validación cruzada y calcular el error de train y de validación utilizando el RMS.

3. Regresión polinómica

3.1 Transformación polinómica. Aplicar una transformación polinómica (de el/los grados que consideren oportuno) a las variables de entrada.

3.2 Entrenamiento del modelo. Entrenar el modelo de regresión lineal sobre las variables transformadas.

3.3 Regularización (opcional). Evaluar un par de valores del parámetro de regularización utilizando (lambda) para L1 en los modelos de regresión que usen variables polinómicas (puedes hacerlo también para el lineal si quieres).

4. Evaluación. Calcular los errores de validación/Dev y reportar el **RMSE** obtenido para los grados del polinomio evaluados (Indicar claramente **qué grado del polinomio y valor de lambda se utilizó en cada uno**)

5. Comparación de modelos. Comparar los resultados obtenidos con los modelos y responder brevemente:

1. ¿Qué modelo obtuvo menor error?
2. Si tuvieran que implementar uno de los modelos en una aplicación real, ¿cuál elegirían? Justificar.
3. Si tuvieran que venderlos o publicar esa aplicación, ¿que RMSE me dirían que esperan que tenga cuando se utilice? (i.e., Cómo esperan que el modelo elegido funcione en datos nuevos)