

Trabajo Práctico 2: Clasificación supervisada

Materia: 72.75 Aprendizaje Automático (Machine Learning)

Fecha de defensa: 07/10/26

En este trabajo práctico se implementarán modelos de regresión para predecir una variable numérica a partir de un conjunto de datos. El objetivo principal es **aprender a entrenar y evaluar modelos utilizando validación cruzada**.

La presentación durará 10 minutos + 10 minutos de preguntas.

*mandar la presentación y el código 24 horas antes de la clase en la que se presentará el TP

0. Dataset.

Para este trabajo se utilizará el dataset **Bank Marketing**, basado en campañas telefónicas realizadas por una institución bancaria portuguesa. El objetivo es predecir si un cliente contratará o no un depósito a plazo fijo ($y = \text{yes/no}$) a partir de información demográfica, datos de campañas previas y variables del contexto económico. La problemática representa un caso típico de clasificación supervisada en datos tabulares: a partir de información disponible antes o durante una campaña comercial, se busca estimar qué clientes tienen mayor probabilidad de responder positivamente, permitiendo priorizar recursos de marketing.

<https://www.kaggle.com/datasets/henriqueyamahata/bank-marketing>

1. Preprocesamiento y análisis exploratorio

Se espera que realicen un análisis exploratorio básico que les permita entender el dataset antes de entrenar los modelos. Este análisis debería incluir, por ejemplo, el balance de clases, la distribución de algunas variables relevantes, la relación entre variables predictoras y la variable objetivo, la presencia de valores faltantes o categorías poco frecuentes, y posibles diferencias entre clientes que aceptan y no aceptan la oferta.

*El EDA no es solo una exploración de datos sino que debe utilizarse para tomar decisiones concretas sobre el pipeline de Machine Learning. Por ejemplo, pueden justificar la exclusión de alguna variable, decidir cómo tratar variables categóricas, aplicar escalado cuando corresponda, agrupar categorías poco frecuentes, crear nuevas variables si consideran que aportan información útil, o comparar el desempeño del modelo con y sin ciertas variables problemáticas. Dado que no es el foco principal del TP, **no se espera un análisis exploratorio exhaustivo, pero sí que las observaciones realizadas durante el EDA tengan alguna consecuencia sobre el preprocesamiento, la selección de variables o la interpretación de los resultados**.

*Es importante analizar críticamente variables que puedan introducir *data leakage* si se interpreta como información que no debería estar disponible antes de realizar la llamada (y por tanto del momento en el que nuestro modelo operaría en la aplicación real).

*Recuerden realizar la división entre entrenamiento y test antes de aplicar cualquier transformación que pueda producir *data leakage*. Las transformaciones aprendidas de los datos, como escalado, imputación o codificación, deben ajustarse utilizando únicamente los datos de entrenamiento dentro del pipeline correspondiente.

2. Clasificación

2.1 Se deben **implementar** (usando Scikit-learn) **los siguientes clasificadores**:

- Naive-Bayes
- SVM
- KNN
- RF

Si bien no se espera que describan todos los métodos en su presentación, es importante que cuando discutan los resultados, tengan en cuenta como funcionan estos métodos para entender mejor los resultados

2.2 **Validación cruzada.** Para la evaluación de estos clasificadores, implementar un esquema de **k-fold cross-validation** utilizando únicamente el conjunto de entrenamiento (si no lo has hecho ya). Ojo con el data-leakage.

2.3 Métricas: Selecciona dos métricas de las vistas en clase y justifica su elección. Utiliza estas métricas para evaluar los clasificadores y tomar decisiones sobre el modelo elegido.

3. Ajuste de hiperparámetros

3.1 Para los siguientes modelos, evalúa al menos un **hiperparámetro** relevante:

- SVM (C o kernel)
- KNN (número de vecinos, ponderación...)
- RF (número de árboles, profundidad máxima del árbol...)

Utiliza las curvas de validación para elegir el mejor valor de esos hiperparámetros. Discutir brevemente sobre overfitting y underfitting en alguna de ellas en la presentación.

4. **Modelo final.** Elige el modelo que crees más adecuado para resolver este problema, entrénalo y estima cual es la performance (la/s métricas que hayas elegido) que esperas que vaya a tener en datos nuevos.

5. Conclusiones

Reflexionen sobre qué modelos funcionaron mejor y por qué, relacionando los resultados con el análisis exploratorio y con las características generales de cada algoritmo.

Mencionen brevemente si los datos parecen adecuados para los supuestos de algunos modelos. Por ejemplo, si hay variables muy correlacionadas, distribuciones no gaussianas, diferencias de escala entre variables o relaciones no lineales, y cómo esto podría haber afectado a Naive Bayes, SVM, KNN o Random Forest.

Finalmente, indiquen las principales limitaciones del sistema, qué errores consideran más relevantes para el problema y qué mejoras implementarían.

Consejos prácticos vistos en el TP1:

Importante: Durante un proyecto de ML, y también durante este TP, es crítico tener claro qué datos se usan para cada etapa. En la presentación (así como durante la elaboración del TP), debéis ser claros sobre qué datos se están usando y porque, de esta forma evitaréis posibles errores.

Mostrar resultados: Es mucho más efectivo mostrar los resultados con una gráfica que con una tabla de números, especialmente cuando hay muchas filas/columnas o números muy similares. Si además quieres que el valor concreto se muestre, puedes añadirlo a la gráfica.

Presentación: Recuerden que la presentación debe durar 10 minutos, no más y que deben incluir los números en las slides.