

72.75: Aprendizaje Automático (Machine Learning)

Horario: Miércoles 16-19h- virtual sincrónico


Profesorado de la asignatura:

Francisco Sammartino, Ing. | frperez@itba.edu.ar

Carlos Bibián Nogueras, PhD | cbibian@itba.edu.ar

Plan de la sesión de hoy

- Presentación
- Qué es ML y por qué es importante
- Tipos de aprendizaje
- Contenido y objetivos de la asignatura
- Estructura de un proyecto ML y principales desafíos



Aspectos organizativos importantes

- Las clases serán **grabadas** y estarán disponibles hasta la clase siguiente

Aspectos organizativos importantes

- Las clases serán **grabadas** y estarán disponibles hasta la clase siguiente
- La nota de la materia será calculada como promedio de la nota de la cursada y la del TPfinal

Aspectos organizativos importantes

- Las clases serán **grabadas** y estarán disponibles hasta la clase siguiente
- La nota de la materia será calculada como promedio de la nota de la cursada y la del TPfinal
- La nota de la cursada será el promedio de las notas de los 3 TPs

Aspectos organizativos importantes

- Las clases serán **grabadas** y estarán disponibles hasta la clase siguiente
- La nota de la materia será calculada como promedio de la nota de la cursada y la del TPfinal
- La nota de la cursada será el promedio de las notas de los 3 TPs
- Los TPs realizarán en grupos durante en horario de la materia*

*algunos alumnos nos han notificado que no van a poder asistir a algunas clases. Si este es tu caso, escribenos un mail contándonos tu situación para que podamos organizar los grupos de TPs y sus horarios de defensa.


Aspectos organizativos importantes

- Las clases serán **grabadas** y estarán disponibles hasta la clase siguiente
- La nota de la materia será calculada como promedio de la nota de la cursada y la del TPfinal
- La nota de la cursada será el promedio de las notas de los 4 TPs
- Los TPs realizarán en grupos durante en horario de la materia*
*algunos alumnos nos han notificado que no van a poder asistir a algunas clases. Si este es tu caso, escribenos un mail contándonos tu situación para que podamos organizar los grupos de TPs y sus horarios de defensa.
- La defensa del TP consta de una presentación oral del 10 mín (estricto) y 10 min de preguntas sobre el trabajo

Introducción al Aprendizaje Automático

Carlos Bibián Nogueras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires
Centro de Inteligencia Computacional



¿Qué es aprendizaje?



*... es el proceso mediante el cual un sistema (humano, animal o máquina) **adquiere, modifica o mejora** su comportamiento o conocimiento a partir de la experiencia o la información del entorno, permitiéndole adaptarse y responder mejor a situaciones futuras.*

¿Qué es aprendizaje?



... es el proceso mediante el cual un sistema (humano, animal o máquina) **adquiere, modifica o mejora su comportamiento o conocimiento** a partir de la experiencia o la información del entorno, permitiéndole adaptarse y responder mejor a situaciones futuras.

¿Y el aprendizaje automático?

“Campo de estudio que confiere a los ordenadores la capacidad de **aprender sin ser programados explícitamente**” Arthur Samuel (1959)



¿sin ser programados explícitamente?

*“Campo de estudio que confiere a los ordenadores la **capacidad de aprender sin ser programados explícitamente**” Arthur Samuel (1959)*

Programación “tradicional”



¿sin ser programados explícitamente?

*“Campo de estudio que confiere a los ordenadores la **capacidad de aprender sin ser programados explícitamente**” Arthur Samuel (1959)*

Programación “tradicional”



Ejemplos:

Ordenar una lista de números
Verificador de contraseña
Contador de palabras



¿sin ser programados explícitamente?

“Campo de estudio que confiere a los ordenadores la *capacidad de aprender sin ser programados explícitamente*” Arthur Samuel (1959)

Programación “tradicional”

3 7 9 2 1 0 Ordena una lista de números




```
for i in range(len(nums)):
    for j in range(i + 1, len(nums)):
        if nums[i] > nums[j]:
            nums[i], nums[j] = nums[j], nums[i]
    print(nums)
```




¿sin ser programados explícitamente?

*“Campo de estudio que confiere a los ordenadores la **capacidad de aprender sin ser programados explícitamente**” Arthur Samuel (1959)*

Programación “tradicional”



Aprendizaje Automático




Ejemplos:

Clasificador de spam
Predictor del precio de una casa
Identificación de pájaros




Flujo de un programa de AA






Flujo de un programa de AA

Ejemplo: Clasificador de spam



Flujo de un programa de AA


Ejemplo: Clasificador de spam



Ventajas del Aprendizaje Automático

¿Cómo haríamos un detector de spam con programación “tradicional”?

Programación “tradicional”



- 1-Observar decenas/cientos correos spam
- 2-Identificar patrones como el uso de ciertas palabras:
por ej.: "gratis", "promoción", uso de mayúsculas...
- 3-Programar reglas específicas para estas palabras
- 4-Evaluar la eficiencia del programa
- 5-Volver al punto 2 si no estás satisfecho con el resultado



Ventajas del Aprendizaje Automático


Ejemplo Clasificador Spam: “tradicional” vs Aprendizaje Automático

Programación “tradicional”

- 1-Observar decenas/cientos correos spam
- 2-Identificar patrones como el uso de ciertas palabras:
por ej.: "gratis", "promoción", uso de mayúsculas
- 3-Programar reglas específicas para estas palabras
- 4-Evaluar la eficiencia del programa
- 5-Volver al punto 2 para mejorar resultado



Aprendizaje Automático



¿Qué tipos de AA hay?

Varios criterios:

- 1 - ¿Es el aprendizaje supervisado por el humano? (el más usado)
- 2 - ¿Se aprende en tiempo real de un flujo de datos continuo?
- 3 - ¿Qué estrategia usa para generalizar a nuevos datos?

¿Qué tipos de AA hay?

Varios criterios:

1 - ¿Es el aprendizaje supervisado por el humano? (el más usado)

2 - ¿Se aprende en tiempo real de un flujo de datos continuo?

3 - ¿Qué estrategia usa para generalizar a nuevos datos?

¿Cómo aprendemos?

Identificar perro:

- viendo varios perros, extraemos rasgos característicos



Agrupar juguetes por colores

- observamos patrones en un grupo de juguetes, como forma o color, sin que nadie nos diga que son colores distintos



Aprender a caminar

- Probamos movimientos recibiendo feedback en base de “caída/no caída” y vamos ajustando en cada intento

¿Cómo aprendemos?

Identificar perro:

- viendo varios perros, extraemos rasgos característicos



Agrupar juguetes por colores

- observamos patrones en un grupo de juguetes, como forma o color, sin que nadie nos diga que son colores distintos



Aprender a caminar

- Probamos movimientos recibiendo feedback en base de “caída/no caída” y vamos ajustando en cada intento

¿Cómo aprendemos?

Identificar perro:

- viendo varios perros, extraemos rasgos característicos



Agrupar juguetes por colores

- observamos patrones en un grupo de juguetes, como forma o color, sin que nadie nos diga que son colores distintos





Aprender a caminar

- Probamos movimientos recibiendo feedback en base de “caída/no caída” y vamos ajustando en cada intento

Tipos de Aprendizaje Automático

Identificar perro -> **Supervisado**



Agrupar juguetes por colores -> **No supervisado**


Aprender a caminar -> **Por refuerzo**



Aprendizaje supervisado

¿Cómo funciona este tipo de aprendizaje?

Aprender una función que mapea entradas $\rightarrow$ salidas a partir de ejemplos **etiquetados**.





Aprendizaje supervisado

¿Qué tenemos?

- n datos

↓ cada dato $i \in \{1, \dots, n\}$: $\rightarrow D_n = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$

- $x^i = (x_1^i, \dots, x_d^i)$ – vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ – vector de etiquetas (labels): perro (1), no perro (0)



Aprendizaje supervisado

¿Qué tenemos?

- n datos



↳ cada dato $i \in \{1, \dots, n\}$: $\rightarrow D_n = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$

- $x^i = (x_1^i, \dots, x_d^i)$ – vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ – vector de etiquetas (labels): perro (1), no perro (0)

¿Qué queremos?

- Una buena estrategia para de etiquetar (clasificar) nuevos datos

módulo 1, y más en profundidad en **módulo 2** y **módulo 3**



Aprendizaje no supervisado

Agrupar juguetes por colores -> **No supervisado**

módulo 4

¿Cómo funciona este tipo de aprendizaje?

Algoritmos diseñados para buscar patrones en los datos

¿Qué tenemos?


- n datos

cada dato $i \in \{1, \dots, n\}$: $\rightarrow D_n = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$

- $x^i = (x_1^i, \dots, x_d^i)$ – vector de características (features): Canales RGB ...
- $y^i \in \{0, 1\}$ – **vector de etiquetas (labels):** perro (1), no perro (0)

¿Qué queremos?

- Encontrar patrones en los datos que los **agrupen** de la **mejor forma posible**





Aprendizaje no supervisado

Agrupar juguetes por colores -> **No supervisado**

módulo 4

¿Como funciona este tipo de aprendizaje?

Algoritmos diseñados para buscar patrones en los datos





Aprendizaje no supervisado

Agrupar juguetes por colores -> **No supervisado**

módulo 4

¿Como funciona este tipo de aprendizaje?

Algoritmos diseñados para buscar patrones en los datos





Aprendizaje no supervisado

Agrupar juguetes por colores -> **No supervisado**

módulo 4

¿Como funciona este tipo de aprendizaje?

Algoritmos diseñados para buscar patrones en los datos



Aprendizaje por refuerzo

Aprender a caminar -> **Por refuerzo**

¿Como funciona este tipo de aprendizaje?

- Aprende a tomar decisiones óptimas interactuando con un entorno (y recibiendo feedback indirecto (incluso diferido))

Diferente a otros métodos ya que no se dice cual es la acción correcta, se descubre mediante prueba y error, recibiendo recompensas cuando algo está bien y castigos cuando se equivoca

- No hay un mapeo directo entre entrada y salida (como en supervisado)
- El agente aprende una política que maximiza recompensas



Aprendizaje por refuerzo

Ejemplo

Imagina que quieres entrenar a un robot para salir de un laberinto:



- Cada vez que avanza hacia la salida, recibe una pequeña recompensa.
- Si choca contra una pared, recibe una penalización.
- Al final, cuando logra salir, recibe una gran recompensa.

Tras repetir este proceso muchas veces, el robot aprende el camino más rápido para salir del laberinto sin que nadie se lo haya explicado directamente.



Aprendizaje por refuerzo

Más ejemplos



Ejemplos de aplicación

Diagnóstico de imágenes médicas (supervisado)

Control de prótesis robóticas (por refuerzo)

Análisis genómico en ciencia: analizar grandes volúmenes de datos genéticos para detectar patrones clave. (no supervisado)

Fraude financiero: detectar patrones de transacciones fraudulentas (supervisado)

Segmentación de clientes para recomendación personalizada (no supervisado)

¿Qué tipos de AA hay?

Varios criterios:

- 1 - ¿Es el aprendizaje supervisado por el humano? (el más usado)
- 2 - ¿Se aprende en tiempo real de un flujo de datos continuo?
- 3 - ¿Qué estrategia usa para generalizar a nuevos datos?

¿Qué tipos de AA hay?

Varios criterios:

1 - ¿Es el aprendizaje supervisado por el humano? (el más usado)

2 - ¿Se aprende en tiempo real de un flujo de datos continuo?

3 - ¿Qué estrategia usa para generalizar a nuevos datos?

¿Batch vs Online Learning?




Batch/offline Learning

Aprende una vez y a partir de todos los datos

El entrenamiento suele ocupar muchos recursos: CPU, memoria...

Si quieres adaptar el algoritmo a nuevos datos debes reentrenarlo totalmente (coste alto)

Robusto si una parte de los datos es ruidosa



Online Learning

Aprende de forma continua a partir de datos individuales o pequeños paquetes de datos / mini-batches

Entrenamiento "ligero" ya que debe ocurrir en tiempo real

Se adapta a los nuevos datos de forma continua

Una secuencia de datos ruidosos podría arruinar el funcionamiento por un tiempo. *Importante definir como de rápido se adapta a nuevos datos (learning rate)

¿Batch vs Online Learning?




Batch/offline Learning

Aprende una vez y a partir de todos los datos

El entrenamiento suele ocupar muchos recursos: CPU, memoria...

Si quieres adaptar el algoritmo a nuevos datos debes reentrenarlo totalmente (coste alto)

Robusto si una parte de los datos es ruidosa



Online Learning

Aprende de forma continua a partir de datos individuales o pequeños paquetes de datos / mini-batches

Entrenamiento “ligero” ya que debe ocurrir en tiempo real

Se adapta a los nuevos datos de forma continua

Una secuencia de datos ruidosos podría arruinar el funcionamiento por un tiempo. *Importante definir cómo de rápido se adapta a nuevos datos (learning rate)

¿Batch vs Online Learning?

Caso especial (out-of-core learning)

En entornos de poca memoria y/o muchos datos las estrategias de online learning pueden ser muy útiles:

- Permiten aprender de los datos en mini-batches sin necesidad de guardarlos todos en memoria/disco
- Entrenar offline pero aplicando métodos de online learning sería algo así como aprendizaje incremental

¿Qué tipos de AA hay?

Varios criterios:

- 1 - ¿Es el aprendizaje supervisado por el humano? (el más usado)
- 2 - ¿Se aprende en tiempo real de un flujo de datos continuo?
- 3 - ¿Qué estrategia usa para generalizar a nuevos datos?

¿Qué tipos de AA hay?

Varios criterios:

- 1 - ¿Es el aprendizaje supervisado por el humano? (el más usado)
- 2 - ¿Se aprende en tiempo real de un flujo de datos continuo?
- 3 - ¿Qué estrategia usa para generalizar a nuevos datos?**

¿Cómo generaliza a nuevos datos?




Instance-Based Learning

Literalmente “aprender de memoria”

Se usan los datos para predecir – cual y cómo es el dato más parecido

Necesitamos definir como se evalúa esa similitud entre datos



Model-Based Learning

A partir de los datos, crea un modelo que los representa

Es el modelo lo que se usa para generalizar/predecir para datos nuevos

Necesitamos definir cómo construir en modelo a partir de datos

¿Cómo generaliza a nuevos datos?




Instance-Based Learning

Literalmente “aprender de memoria”

Se usan los datos para predecir – cuál y cómo es el dato más parecido

Necesitamos definir cómo se evalúa esa similitud entre datos



Model-Based Learning

A partir de los datos, crea un modelo que los representa

Es el modelo lo que se usa para generalizar/predecir para datos nuevos

Necesitamos definir cómo construir un modelo a partir de datos

Muy interesante pero...




IA vs AA vs DL

Metodología de entrenar sistemas para que sean capaces de aprender a partir de datos pasados para hacer predicciones.

Cualquier simulación/imitación de la inteligencia humana en máquinas. Máquinas programadas para imitar razonamiento humano, aprender o resolver problemas.

Redes neuronales grandes con múltiples capas (>3)


Sistemas de aprendizaje automático inspirados en las redes neuronales humanas: formadas por neuronas conectadas para aprender las relaciones entre inputs y outputs



¿Donde se sitúa esta materia?

Metodología de entrenar sistemas para que sean capaces de aprender a partir de datos pasados para hacer predicciones.

Redes neuronales grandes con múltiples capas (>3)



Cualquier simulación/imitación de la inteligencia humana por máquinas. Maquinas programadas para imitar razonamiento humano, aprender o resolver problemas.

Sistemas de Inteligencia Artificial (SIA)

Sistemas de aprendizaje automático inspirados en las redes neuronales humanas: formadas por neuronas conectadas para aprender las relaciones entre inputs y outputs

Objetivos de la materia

Módulo 1 – Fundamentos y supervisado clásico

Comprender los principios teóricos del aprendizaje supervisado y la estructura de un proyecto de ML supervisado.
Analizar métricas y procesos de validación para evaluar modelos básicos.

Módulo 2 – Clasificadores supervisados

Explorar el funcionamiento interno de clasificadores clásicos (KNN, SVM, árboles).
Comparar su comportamiento y supuestos en distintos contextos de datos.

Módulo 3 – Teoría del aprendizaje y mejora de modelos

Desarrollar criterios de diagnóstico y optimización (bias-variance, regularización, tuning).
Entender la selección de modelos y estrategias para evitar errores comunes – Consejos prácticos y buenas prácticas

Módulo 4 – No supervisado y feature engineering

Comprender los métodos de clustering y reducción de dimensionalidad y su aplicación.
Integrar técnicas de preprocesamiento y representación para mejorar el rendimiento del modelo.

Objetivos de la materia

Módulo 1 – Fundamentos y supervisado clásico

Comprender los principios teóricos del aprendizaje supervisado y la estructura de un proyecto de ML supervisado.
Analizar métricas y procesos de validación para evaluar modelos básicos.

Módulo 2 – Clasificadores supervisados

Explorar el funcionamiento interno de clasificadores clásicos (KNN, SVM, árboles).
Comparar su comportamiento y supuestos en distintos contextos de datos.

Módulo 3 – Teoría del aprendizaje y mejora de modelos

Desarrollar criterios de diagnóstico y optimización (bias-variance, regularización, tuning).
Entender la selección de modelos y estrategias para evitar errores comunes – Consejos prácticos y buenas prácticas

Módulo 4 – No supervisado y feature engineering

Comprender los métodos de clustering y reducción de dimensionalidad y su aplicación.
Integrar técnicas de preprocesamiento y representación para mejorar el rendimiento del modelo.

Objetivos de la materia

Módulo 1 – Fundamentos y supervisado clásico

Comprender los principios teóricos del aprendizaje supervisado y la estructura de un proyecto de ML supervisado.
Analizar métricas y procesos de validación para evaluar modelos básicos.

Módulo 2 – Clasificadores supervisados

Explorar el funcionamiento interno de clasificadores clásicos (KNN, SVM, árboles).
Comparar su comportamiento y supuestos en distintos contextos de datos.

Módulo 3 – Teoría del aprendizaje y mejora de modelos

Desarrollar criterios de diagnóstico y optimización (bias-variance, regularización, tuning).
Entender la selección de modelos y estrategias para evitar errores comunes – Consejos prácticos y buenas prácticas

Módulo 4 – No supervisado y feature engineering

Comprender los métodos de clustering y reducción de dimensionalidad y su aplicación.
Integrar técnicas de preprocesamiento y representación para mejorar el rendimiento del modelo.

Objetivos de la materia

Módulo 1 – Fundamentos y supervisado clásico

Comprender los principios teóricos del aprendizaje supervisado y la estructura de un proyecto de ML supervisado.
Analizar métricas y procesos de validación para evaluar modelos básicos.

Módulo 2 – Clasificadores supervisados

Explorar el funcionamiento interno de clasificadores clásicos (KNN, SVM, árboles).
Comparar su comportamiento y supuestos en distintos contextos de datos.

Módulo 3 – Teoría del aprendizaje y mejora de modelos

Desarrollar criterios de diagnóstico y optimización (bias-variance, regularización, tuning).
Entender la selección de modelos y estrategias para evitar errores comunes – Consejos prácticos y buenas prácticas

Módulo 4 – No supervisado y feature engineering

Comprender los métodos de clustering y reducción de dimensionalidad y su aplicación.
Integrar técnicas de preprocesamiento y representación para mejorar el rendimiento del modelo.





¿Dudas hasta aquí?

Módulo 1 – Fundamentos y supervisado clásico

Módulo 2 – Clasificadores supervisados

Módulo 3 – Teoría del aprendizaje y mejora de modelos


Módulo 4 – No supervisado y feature engineering



Estructura de un proyecto de ML supervisado

Carlos Bibián Nogueras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires
Centro de Inteligencia Computacional



... en la presentación anterior

Aprendizaje supervisado

¿Qué tenemos?

- n datos



↳ cada dato $i \in \{1, \dots, n\}$: $\rightarrow D_n = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$

- $x^i = (x_1^i, \dots, x_d^i)$ – vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ – vector de etiquetas (labels): perro (1), no perro (0)

¿Qué queremos?

- Una **buena estrategia para de etiquetar** (clasificar) **nuevos datos**

módulo 1, y más en profundidad en **módulo 2** y **módulo 3**



... en la presentación anterior

Aprendizaje supervisado

¿Qué tenemos?

- n datos



↳ cada dato $i \in \{1, \dots, n\}$: $D = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$

- $x^i = (x_1^i, \dots, x_d^i)$ - vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ - vector de etiquetas (labels): perro (1), no perro (0)

1. Obtener y preparar los datos

¿Qué queremos?

- Una **buena estrategia para de etiquetar** (clasificar) **nuevos datos**



... en la presentación anterior

Aprendizaje supervisado

¿Qué tenemos?

- n datos

↳ cada dato $i \in \{1, \dots, n\}$ es un par $((x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)}))$



- $x^i = (x_1^i, \dots, x_d^i)$ - vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ - vector de etiquetas (labels): perro (1), no perro (0)

1. Obtener y preparar los datos

¿Qué queremos?

2. Elegir una estrategia de aprendizaje (algoritmo)

- Una **buena estrategia para de etiquetar** (clasificar) **nuevos datos**



... en la presentación anterior

Aprendizaje supervisado

¿Qué tenemos?

- n datos

↳ cada dato $i \in \{1, \dots, n\}$ es un par $((x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)}))$



- $x^i = (x_1^i, \dots, x_d^i)$ - vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ - vector de etiquetas (labels): perro (1), no perro (0)

¿Qué queremos?

2. Elegir una estrategia de aprendizaje (algoritmo)

- Una **buena estrategia para de etiquetar** (clasificar) nuevos datos

3. Definir cómo evaluar el aprendizaje



... en la presentación anterior

Aprendizaje supervisado

¿Qué tenemos?

- n datos

↳ cada dato $i \in \{1, \dots, n\}$ es un par $((x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)}))$

- $x^i = (x_1^i, \dots, x_d^i)$ - vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ - vector de etiquetas (labels): perro (1), no perro (0)


¿Qué queremos?

2. Elegir una estrategia de aprendizaje (algoritmo)

- Una **buena estrategia para de etiquetar** (clasificar) nuevos datos

3. Definir cómo evaluar el aprendizaje

4. Evaluar cómo funcionará en datos nuevos



Estructura de un proyecto ML

1. Obtener y preparar los datos

2. Elegir una estrategia de aprendizaje (algoritmo)

3. Definir cómo evaluar el aprendizaje

4. Evaluar cómo funcionará en datos nuevos

Estructura de un proyecto ML (ejemplo)

Diagnóstico precoz de alzheimer

1. Obtener y preparar los datos

2. Elegir una estrategia de aprendizaje (algoritmo)

3. Definir cómo evaluar el aprendizaje

4. Evaluar cómo funcionará en datos nuevos



Estructura de un proyecto ML

1. Obtener y preparar los datos

2. Elegir una estrategia de aprendizaje (algoritmo)

3. Definir como evaluar el aprendizaje

4. Evaluar como funcionará en datos nuevos

Diagnóstico precoz de alzheimer

1.1 Hablar con neurólogos/leer para entender cómo se puede hacer.

1.2 Obtener imágenes de MRI y etiquetarlas (diagnóstico positivo y negativo)

1.3 Extraer información de las imágenes en base a la info extraída:

- descriptores de forma, contraste, color, textura.



Estructura de un proyecto ML

1. Obtener y preparar los datos

2. Elegir una estrategia de aprendizaje (algoritmo)

3. Definir como evaluar el aprendizaje

4. Evaluar como funcionará en datos nuevos

Diagnóstico precoz de alzheimer

1.1 Hablar con neurólogos/leer para entender cómo se puede hacer.

1.2 Obtener imágenes de MRI y etiquetarlas (diagnóstico positivo y negativo)

1.3 Extraer información de las imágenes en base a la info extraída:
- descriptores de forma, contraste, color, textura...

2.1 Viendo los datos y estado del arte, elegimos SVM (por ejemplo)



Estructura de un proyecto ML

1. Obtener y preparar los datos

2. Elegir una estrategia de aprendizaje (algoritmo)

3. Definir cómo evaluar el aprendizaje

4. Evaluar como funcionará en datos nuevos

Diagnostico precoz de alzheimer

1.1 Hablar con neurólogos/leer para entender cómo se puede hacer.

1.2 Obtener imágenes de MRI y etiquetarlas (diagnóstico positivo y negativo)

1.3 Extraer información de las imágenes en base a la info extraída:

- descriptores de forma, contraste, color, textura...

2.1 Viendo los datos y estado del arte, elegimos SVM (por ejemplo)

3.1 Elegimos una métrica que penalice más el falso negativo para evitar no detectar un posible caso positivo



Estructura de un proyecto ML

1. Obtener y preparar los datos

2. Elegir una estrategia de aprendizaje (algoritmo)

3. Definir cómo evaluar el aprendizaje

4. Evaluar cómo funcionará en datos nuevos

Diagnostico precoz de alzheimer

1.1 Hablar con neurólogos/leer para entender cómo se puede hacer.

1.2 Obtener imágenes de MRI y etiquetarlas (diagnóstico positivo y negativo)

1.3 Extraer información de las imágenes en base a la info extraída:
- descriptores de forma, contraste, color, textura...

2.1 Viendo los datos y estado del arte, elegimos SVM (por ejemplo)

3.1 Elegimos una métrica que penalice más el falso negativo para evitar no detectar un posible caso positivo

4.1 Probamos el sistema (pasos 1 a 3) en **datos nuevos**



Principales retos del ML

No tener suficientes datos


Principales retos del ML

No tener suficientes datos

Que los datos no sean representativos del problema a resolver (sampling bias)

1948 Chicago Tribune.

- Encuestas hechas por teléfono
- En esa época las personas con bajo nivel adquisitivo no tenían teléfono, pero (obviamente) sí votaban.



Principales retos del ML


No tener suficientes datos

Que los datos no sean representativos del problema a resolver (sampling bias)

1948 Chicago Tribune.

- Encuestas hechas por teléfono
- En esa época las personas con bajo nivel adquisitivo no tenían teléfono, pero (obviamente) sí votaban.

Survival bias.



Principales retos del ML


No tener suficientes datos

Que los datos no sean representativos del problema a resolver (sampling bias)

Mala calidad de los datos

Parte importante de nuestro tiempo en un proyecto se va en esto:

- outliers, datos faltantes, errores en la obtención de datos, ruido...



Principales retos del ML

No tener suficientes datos

Que los datos no sean representativos del problema a resolver (sampling bias)

Mala calidad de los datos

Variables/características irrelevantes para el problema

Seleccionar/crear nuevas características es una parte crítica de un proyecto ML

- Tanto en el diseño del proyecto (antes de obtención de datos) como después a la hora de seleccionar características o “extraer” nuevas combinando otras.

Principales retos del ML

No tener suficientes datos

Que los datos no sean representativos del problema


Mala calidad de los datos

Variables/características irrelevantes para el problema

Underfitting/overfitting

Pocos datos y un modelo muy complejo pueden llevarnos a overfitting

- Grabar más datos o implementar un algoritmo más simple, *además de algunas buenas prácticas*, pueden reducir el overfitting



Estructura de un proyecto ML

1. Obtener y preparar los datos

2. Elegir una estrategia de aprendizaje (algoritmo)

3. Definir cómo evaluar el aprendizaje

4. Evaluar cómo funcionará en datos nuevos

Próxima clase

1. Obtener y preparar los datos




- No tener suficientes datos
- Tener datos que no representan el problema
- Mala calidad de los datos
- Características (features) irrelevantes

2. Elegir una estrategia de aprendizaje (algoritmo)

3. Definir como evaluar el aprendizaje

4. Evaluar como funcionará en datos nuevos

- Underfitting
- Overfitting



Próxima clase

1. Obtener y preparar los datos




- No tener suficientes datos
- Tener datos que no representan el problema
- Mala calidad de los datos
- Características (features) irrelevantes

2. Elegir una estrategia de aprendizaje (algoritmo)



3. Todo el proceso **desde que definimos el problema hasta que llegamos a tener unas variables relevantes para poder resolverlo** – Clase siguiente

4. Evaluar como funcionará en datos nuevos



¿dudas?

1. Obtener y preparar los datos



2. Elegir una estrategia de aprendizaje (algoritmo)



3. Definir cómo evaluar el aprendizaje



4. Evaluar cómo funcionará en datos nuevos

