

72.75: Aprendizaje Automático (Machine Learning)

Horario: Miércoles 16-19h- virtual sincrónico

Profesorado de la asignatura:

Francisco Sammartino, Ing. | frperez@itba.edu.ar

Alexa Sessarego Aurich

Carlos Bibián Nogueras, PhD | cbibian@itba.edu.ar

Plan de la sesión de hoy

- Tipos de variables y qué hacer con ellos
- Limpieza de datos
- Primer ejemplo de supervisado: Regresión
- Data Splits
- Métricas

... en la sesión anterior

- Presentación
 - Qué es ML y por qué es importante
 - Tipos de aprendizaje
 - Contenido y objetivos de la asignatura
 - Estructura de un proyecto ML y principales desafíos
-

... en la clase anterior

*Aprendizaje automático: “Campo de estudio que confiere a los ordenadores la capacidad de aprender **sin ser programados explícitamente**” Arthur Samuel (1959)*

en sesión anterior...

- Presentación
- Qué es ML y por qué es importante
- Tipos de aprendizaje
- Contenido y objetivos de la asignatura
- Estructura de un proyecto ML y principales desafíos

Ventajas del Aprendizaje Automático


Ejemplo Clasificador Spam: “tradicional” vs Aprendizaje Automático

Programación “tradicional”

- 1-Observar decenas/cientos correos spam
- 2-Identificar patrones como el uso de ciertas palabras:
por ej.: "gratis", "promoción", uso de mayúsculas
- 3-Programar reglas específicas para estas palabras
- 4-Evaluar la eficiencia del programa
- 5-Volver al punto 2 para mejorar resultado





Aprendizaje Automático



Tipos de Aprendizaje Automático

Identificar perro -> **Supervisado**




Agrupar juguetes por colores -> **No supervisado**

Aprender a caminar -> **Por refuerzo**



Aprendizaje supervisado



¿Qué tenemos?

- n datos


↳ cada dato $i \in \{1, \dots, n\}$: $\rightarrow D_n = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$

- $x^i = (x_1^i, \dots, x_d^i)$ – vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ – vector de etiquetas (labels): perro (1), no perro (0)

¿Qué queremos?

- Una buena estrategia para de etiquetar (clasificar) nuevos datos

módulo 1, y más en profundidad en **módulo 2** y **módulo 3**



Aprendizaje no supervisado

Agrupar juguetes por colores -> **No supervisado**

módulo 4

¿Cómo funciona este tipo de aprendizaje?

Algoritmos diseñados para buscar patrones en los datos

¿Qué tenemos?


- n datos

cada dato $i \in \{1, \dots, n\}$: $\rightarrow D_n = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$

- $x^i = (x_1^i, \dots, x_d^i)$ – vector de características (features): Canales RGB ...
- $y^i \in \{0, 1\}$ – **vector de etiquetas (labels):** perro (1), no perro (0)

¿Qué queremos?

- Encontrar patrones en los datos que los **agrupen** de la **mejor forma posible**



Preparación de los datos

Carlos Bibián Nogueras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires

¿Cómo es un dataset*?

n datos

cada dato $i \in \{1, \dots, n\}$: $\rightarrow D_n = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$

- $x^i = (x_1^i, \dots, x_d^i)$ – vector de características (features): número de patas, orejas de perro? ...
- $y^i \in \{0, 1\}$ – vector de etiquetas (labels): perro (1), no perro (0)

¿Cómo son/pueden ser esas variables (x)?

***para clasificación supervisada**

Tipos de variables

Ejemplo de dataset

Una empresa hotelera nos contrata para hacer un modelo que predice si una reserva de hotel va a ser cancelada o no.



Cliente	Noches	Adultos	Niños	Días de anticipación	Cancelaciones previas	Precio por noche	Importe total	Descuento (%)	Días última reserva	País	Tipo de habitación	Canal de reserva	Tipo de cliente	Categoría hotel	Nivel fidelidad	Canceló
C1	3	2	0	45	0	120.5	361.5	10	180.5	España	Doble	Web	Nuevo	4★	Bronze	No
C2	5	2	2	90	1	95	475	5	60	Francia	Familiar	Agencia	Recurrente	3★	Silver	No
C3	1	1	0	3	2	150	150	0	400.2	Alemania	Individual	Web	Recurrente	5★	Gold	Sí
C4	7	2	1	120	0	80.75	565.25	15	30.5	Italia	Suite	Agencia	Recurrente	4★	Gold	No
C5	2	1	0	10	3	110	220	0	250	Reino Unido	Doble	Teléfono	Nuevo	3★	Bronze	Sí

Tipos de variables

Numéricas

Representan cantidades

Son las más comunes y pueden utilizarse directamente en la mayoría de los modelos.

Cliente	Noches	Adultos	Niños	Días de anticipación	Cancelaciones previas	Precio por noche	Importe total	Descuento (%)	Días última reserva	País	Tipo de habitación	Canal de reserva	Tipo de cliente	Categoría hotel	Nivel fidelidad	Canceló
C1	3	2	0	45	0	120.5	361.5	10	180.5	España	Doble	Web	Nuevo	4★	Bronze	No
C2	5	2	2	90	1	95	475	5	60	Francia	Familiar	Agencia	Recurrente	3★	Silver	No
C3	1	1	0	3	2	150	150	0	400.2	Alemania	Individual	Web	Recurrente	5★	Gold	Sí
C4	7	2	1	120	0	80.75	565.25	15	30.5	Italia	Suite	Agencia	Recurrente	4★	Gold	No
C5	2	1	0	10	3	110	220	0	250	Reino Unido	Doble	Teléfono	Nuevo	3★	Bronze	Sí

Tipos de variables

Numéricas discretas

Caso especial: Únicamente toman valores específicos (a diferencia de las variables continuas pueden tomar cualquier valor en un rango)

Cliente	Noches	Adultos	Niños	Días de anticipación	Cancelaciones previas	Precio por noche	Importe total	Descuento (%)	Días última reserva	País	Tipo de habitación	Canal de reserva	Tipo de cliente	Categoría hotel	Nivel fidelidad	Canceló
C1	3	2	0	45	0	120.5	361.5	10	180.5	España	Doble	Web	Nuevo	4★	Bronze	No
C2	5	2	2	90	1	95	475	5	60	Francia	Familiar	Agencia	Recurrente	3★	Silver	No
C3	1	1	0	3	2	150	150	0	400.2	Alemania	Individual	Web	Recurrente	5★	Gold	Sí
C4	7	2	1	120	0	80.75	565.25	15	30.5	Italia	Suite	Agencia	Recurrente	4★	Gold	No
C5	2	1	0	10	3	110	220	0	250	Reino Unido	Doble	Teléfono	Nuevo	3★	Bronze	Sí

Tipos de variables

Numéricas discretas

Las variables discretas (p. ej., número de habitaciones) **pueden usarse directamente como variables numéricas**, porque representan cantidades reales.

Sin embargo, sólo toman valores enteros, por lo que no existe continuidad entre ellos.

Esto puede generar relaciones no lineales o efectos umbral que algunos modelos no capturan bien.

Además, suelen tener rangos pequeños y distribuciones muy concentradas, lo que puede limitar la información que aportan.

Por eso, en presencia de estas variables se suele recomendar probar con modelos no lineales o incluso pasarlas a categóricas o a binarias (ej, >3 habitaciones)

Tipos de variables

Categóricas

Las variables categóricas representan categorías o etiquetas

La mayoría de algoritmos usan entradas numéricas, por lo que debemos transformarlas.

Cliente	Noches	Adultos	Niños	Días de anticipación	Cancelaciones previas	Precio por noche	Importe total	Descuento (%)	Días última reserva	País	Tipo de habitación	Canal de reserva	Tipo de cliente	Categoría hotel	Nivel fidelidad	Canceló
C1	3	2	0	45	0	120.5	361.5	10	180.5	España	Doble	Web	Nuevo	4★	Bronze	No
C2	5	2	2	90	1	95	475	5	60	Francia	Familiar	Agencia	Recurrente	3★	Silver	No
C3	1	1	0	3	2	150	150	0	400.2	Alemania	Individual	Web	Recurrente	5★	Gold	Sí
C4	7	2	1	120	0	80.75	565.25	15	30.5	Italia	Suite	Agencia	Recurrente	4★	Gold	No
C5	2	1	0	10	3	110	220	0	250	Reino Unido	Doble	Teléfono	Nuevo	3★	Bronze	Sí

Tipos de variables

Categóricas - Transformaciones

Primera aproximación: asignar un valor numérico a cada categoría

Esto se llama **encoding ordinal**, y sólo es útil cuando hay esa relación jerárquica entre categorías

Cliente	Canal de reserva	Canal de reserva (numérica)
C1	Web	1
C2	Agencia	2
C3	Web	1
C4	Agencia	2
C5	Teléfono	3

Tipos de variables

Categóricas ordinales

Categóricas pero en las cual existe una **relación jerárquica/de orden entre categorías**

Transformación -> encoding ordinal, visto antes

Cliente	Noches	Adultos	Niños	Días de anticipación	Cancelaciones previas	Precio por noche	Importe total	Descuento (%)	Días última reserva	País	Tipo de habitación	Canal de reserva	Tipo de cliente	Categoría hotel	Nivel fidelidad	Canceló
C1	3	2	0	45	0	120.5	361.5	10	180.5	España	Doble	Web	Nuevo	4★	Bronze	No
C2	5	2	2	90	1	95	475	5	60	Francia	Familiar	Agencia	Recurrente	3★	Silver	No
C3	1	1	0	3	2	150	150	0	400.2	Alemania	Individual	Web	Recurrente	5★	Gold	Sí
C4	7	2	1	120	0	80.75	565.25	15	30.5	Italia	Suite	Agencia	Recurrente	4★	Gold	No
C5	2	1	0	10	3	110	220	0	250	Reino Unido	Doble	Teléfono	Nuevo	3★	Bronze	Sí

Tipos de variables

Categóricas ordinales

Categóricas pero en las cual existe una **relación jerárquica/de orden entre categorías**

Transformación -> encoding ordinal, visto antes

Cliente	Noches	Adultos	Niños	Días de anticipación	Cancelaciones previas	Precio por noche	Importe total	Descuento (%)	Días última reserva	País	Tipo de habitación	Canal de reserva	Tipo de cliente	Categoría hotel	Nivel fidelidad	Canceló
C1	3	2	0	45	0	120.5	361.5	10	180.5	España	Doble	Web	Nuevo	4	1	No
C2	5	2	2	90	1	95	475	5	60	Francia	Familiar	Agencia	Recurrente	3	2	No
C3	1	1	0	3	2	150	150	0	400.2	Alemania	Individual	Web	Recurrente	5	3	Sí
C4	7	2	1	120	0	80.75	565.25	15	30.5	Italia	Suite	Agencia	Recurrente	4	3	No
C5	2	1	0	10	3	110	220	0	250	Reino Unido	Doble	Teléfono	Nuevo	3	1	Sí

Tipos de variables

Categóricas ordinales

Categóricas pero en las cual existe una **relación jerárquica/de orden entre categorías**

Transformación -> encoding ordinal, visto antes

Cliente	Noches	Adultos	Niños	Días de anticipación	Cancelaciones previas	Precio por noche	Importe total	Descuento (%)	Días última reserva	País	Tipo de habitación	Canal de reserva	Tipo de cliente	Categoría hotel	Nivel fidelidad	Canceló
C1	3	2	0	45	0	120.5	361.5	10	180.5	España	Doble	Web	Nuevo	4	1	No
C2	5												ecurrente	3	2	No
C3	1												ecurrente	5	3	Sí
C4	7												ecurrente	4	3	No
C5	2	1	0	10	3	110	220	0	250	Reino Unido	Doble	Teléfono	Nuevo	3	1	Sí

Pero... ¿y si no existe esa relación jerárquica?

Tipos de variables

Categóricas - One-hot encoding

One-hot encoding: crea una variable nueva para cada categoría

Muy utilizado pero aumenta la dimensionalidad mucho. Está bien si no hay muchas variables categóricas o muchas categorías

Cliente	Canal de reserva	Canal_Web	Canal_Agencia	Canal_Teléfono
C1	Web	1	0	0
C2	Agencia	0	1	0
C3	Web	1	0	0
C4	Agencia	0	1	0
C5	Teléfono	0	0	1

Tipos de variables

Categóricas - Frequency encoding

Frequency encoding: cada categoría toma el valor de la frecuencia de aparición de esa categoría.

Cliente	Canal de reserva	Canal de reserva
C1	Web	0.62
C2	Agencia	0.11
C3	Web	0.62
C4	Agencia	0.11
C5	Teléfono	0.17

Tipos de variables

Categóricas - Frequency encoding

Frequency encoding: cada categoría toma el valor de la frecuencia de aparición de esa categoría.

La idea detrás es que puede ser útil para el algoritmo saber que un dato pertenece a una categoría muy rara ya que las categorías raras suelen comportarse de forma distinta.

Cliente	Canal de reserva	Canal de reserva
C1	Web	0.62
C2	Agencia	0.11
C3	Web	0.62
C4	Agencia	0.11
C5	Teléfono	0.17

***Métodos como los basados en árboles usan muy bien la información de estas variables ya que “dividen” el dataset mirando variables individuales (lo veremos)

Tipos de variables

Categóricas - Target encoding

Target encoding: cada categoría toma el valor del promedio de Y para los datos de esa categoría.

Cliente	Canal de reserva	Canal de reserva
C1	Web	0.62
C2	Agencia	0.11
C3	Web	0.62
C4	Agencia	0.11
C5	Teléfono	0.17

$$TE_c = \bar{y}_c$$

Tipos de variables

Categóricas - Target encoding

Target encoding: cada categoría toma el valor del promedio de Y para los datos de esa categoría.

Es algo así como: cómo se comportan los datos de esa categoría en promedio

Peligros: si hay pocos datos de esa categoría, o incluso solo uno, el promedio puede no ser directamente la y a estimar/predecir...

Cliente	Canal de reserva	Canal de reserva
C1	Web	0.62
C2	Agencia	0.11
C3	Web	0.62
C4	Agencia	0.11
C5	Teléfono	0.17

$$TE_c = \bar{y}_c$$

Tipos de variables

Categóricas - Regularized Target encoding

Regularized Target encoding: cada categoría toma el valor del promedio de Y para los datos de esa categoría, ponderado con la frecuencia de aparición.

Si la categoría está poco presente, tomará el valor promedio del target, y si está muy presente tomará el valor promedio de esa categoría.

Cliente	Canal de reserva	Canal de reserva
C1	Web	0.62
C2	Agencia	0.11
C3	Web	0.62
C4	Agencia	0.11
C5	Teléfono	0.17

`TargetEncoder(smooth="auto")`

$$TE_c = \bar{y}_c$$

$$TE_c = \frac{n_c \bar{y}_c + \lambda \bar{y}}{n_c + \lambda}$$

lambda: parámetro regularizador
 “añado *lambda* observaciones virtuales que tienen de media la media global”

Tipos de variables

Categóricas - Modelos que “soportan” este tipo de variables

Hay modelos explícitamente diseñados para utilizar este tipo de variables.

Métodos como CatBoost, LightGBM o XGBoost...

Cliente	Canal de reserva	Canal_Web	Canal_Agencia	Canal_Teléfono
C1	Web	1	0	0
C2	Agencia	0	1	0
C3	Web	1	0	0
C4	Agencia	0	1	0
C5	Teléfono	0	0	1

Limpieza de datos

Carlos Bibián Nogueras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires

Limpieza de datos

Antes de entrenar un modelo es necesario revisar y limpiar los datos para evitar errores o resultados engañosos.

¿qué problemas nos podemos encontrar?

- Valores faltantes/erróneos
- Outliers
- Datos duplicados

Limpieza de datos

Valores faltantes/erróneos

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	País	Tipo habitación	Canal reserva	Canceló
C1	3	2	45	120.5	España	Doble	Web	No
C2	5	2	90	95	Francia	Familiar	Agencia	No
C3	1	1	3	150	Alemania	Individual	Web	Sí
C4	7	2	120	80.7	Italia	Suite	Agencia	No
C5	2	1	10	110	Reino Unido	Doble	Teléfono	Sí
C6	4	2	NA	105	España	Doble	online	No
C7	0	1	30	98	Francia	Individual	Web	No
C8	6	NA	60	85	Italia	Familiar	Agencia	No
C9	3	2	20	-50	España	Suite	Web	Sí
C10	5	2	75	NA	Alemania	Doble	Agencia	No
C11	2	1	15	102	NA	Individual	Web	No
C12	10	2	200	70	Brasil	Familiar	Web	No

- Valores faltantes

Limpieza de datos

Valores faltantes/erróneos

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	País	Tipo habitación	Canal reserva	Canceló
C1	3	2	45	120.5	España	Doble	Web	No
C2	5	2	90	95	Francia	Familiar	Agencia	No
C3	1	1	3	150	Alemania	Individual	Web	Sí
C4	7	2	120	80.7	Italia	Suite	Agencia	No
C5	2	1	10	110	Reino Unido	Doble	Teléfono	Sí
C6	4	2	NA	105	España	Doble	online	No
C7	0	1	30	98	Francia	Individual	Web	No
C8	6	NA	60	85	Italia	Familiar	Agencia	No
C9	3	2	20	-50	España	Suite	Web	Sí
C10	5	2	75	NA	Alemania	Doble	Agencia	No
C11	2	1	15	102	NA	Individual	Web	No
C12	10	2	200	70	Brasil	Familiar	Web	No

- Valores faltantes

- Valores imposibles

Ej: noches o adultos ≤ 0

Limpieza de datos

Valores faltantes/erróneos

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	País	Tipo habitación	Canal reserva	Canceló
C1	3	2	45	120.5	España	Doble	Web	No
C2	5	2	90	95	Francia	Familiar	Agencia	No
C3	1	1	3	150	Alemania	Individual	Web	Sí
C4	7	2	120	80.7	Italia	Suite	Agencia	No
C5	2	1	10	110	Reino Unido	Doble	Teléfono	Sí
C6	4	2	NA	105	España	Doble	online	No
C7	0	1	30	98	Francia	Individual	Web	No
C8	6	NA	60	85	Italia	Familiar	Agencia	No
C9	3	2	20	-50	España	Suite	Web	Sí
C10	5	2	75	NA	Alemania	Doble	Agencia	No
C11	2	1	15	102	NA	Individual	Web	No
C12	10	2	200	70	Brasil	Familiar	Web	No

- Valores faltantes

- Valores imposibles

Ej: noches o adultos ≤ 0

- Categorías erróneas

Ej.: Wb, Online...

`df["canal"].unique()`

Limpieza de datos

Valores faltantes/erróneos

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	País	Tipo habitación	Canal reserva	Canceló
C1	3	2	45	120.5	España	Doble	Web	No
C2	5	2	90	95	Francia	Familiar	Agencia	No
C3	1	1	3	150	Alemania	Individual	Web	Sí
C4	7	2	120	80.7	Italia	Suite	Agencia	No
C5	2	1	10	110	Reino Unido	Doble	Teléfono	Sí
C6	4	2	NA	105	España	Doble	online	No
C7	0	1	30	98	Francia	Individual	Web	No
C8	6	NA	60	85	Italia	Familiar	Agencia	No
C9	3	2	20	-50	España	Suite	Web	Sí
C10	5	2	75	NA	Alemania	Doble	Agencia	No
C11	2	1	15	102	NA	Individual	Web	No
C12	10	2	200	70	Brasil	Familiar	Web	No

- Valores faltantes

- Valores imposibles

Ej: noches o adultos ≤ 0

- Categorías erróneas

Ej.: Wb, Online...

`df["canal"].unique()`

- Valores atípicos (outliers)

boxplots, IQR

Limpieza de datos

Valores faltantes/erróneos

¿Qué hacer con ellos?

- **Quitar todo el dato:** Si tenemos un dataset no muy grande, mejor evitarlo

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	Tipo de habitación
C1	3	2	45	120.5	Doble
C2	5	2	90	95	Familiar
C3	1	1	3	150	Suite
C4	7	1	120	80.7	Individual
C5	2	2	10	110	Familiar
C6	4	2	NA	105	Doble
C7	0	2	30	98	Doble
C8	6	1	60	85	Individual
C9	3	2	20	-50	Suite
C10	5	2	75	NA	Individual
C11	2	1	15	102	NA
C12	10	1	200	70	Individual

Limpieza de datos

Valores faltantes/erróneos

¿Qué hacer con ellos?

- **Quitar todo el dato:** Si tenemos un dataset no muy grande, mejor evitarlo

- **Quitar la variable**
si % de datos faltantes en una columna (x) es alto (20%)

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	Tipo de habitación
C1	3	2	45	120.5	Doble
C2	5	2	90	95	Familiar
C3	1	1	3	150	Suite
C4	7	1	120	80.7	Individual
C5	2	2	10	110	Familiar
C6	4	2	NA	105	Doble
C7	0	2	30	98	Doble
C8	6	1	60	85	Individual
C9	3	2	20	-50	Suite
C10	5	2	75	NA	Individual
C11	2	1	15	102	NA
C12	10	1	200	70	Individual

Limpieza de datos


Valores faltantes/erróneos

¿Qué hacer con ellos?

- **Quitar todo el dato:** Si tenemos un dataset no muy grande, mejor evitarlo

- **Quitar la variable**
si % de datos faltantes en una columna (x) es alto (20%)

- **Imputar un valor**



Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	Tipo de habitación
C1	3	2	45	120.5	Doble
C2	5	2	90	95	Familiar
C3	1	1	3	150	Suite
C4	7	1	120	80.7	Individual
C5	2	2	10	110	Familiar
C6	4	2	NA	105	Doble
C7	0	2	30	98	Doble
C8	6	1	60	85	Individual
C9	3	2	20	-50	Suite
C10	5	2	75	NA	Individual
C11	2	1	15	102	NA
C12	10	1	200	70	Individual

Limpieza de datos

Imputación de valores

Imputación en base a:

Estadísticos globales

Estadísticos por grupo

Valor constante

Basado en modelos

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	Tipo de habitación
C1	3	2	45	120.5	Doble
C2	5	2	90	95	Familiar
C3	1	1	3	150	Suite
C4	7	1	120	80.7	Individual
C5	2	2	10	110	Familiar
C6	4	2	NA	105	Doble
C7	0	2	30	98	Doble
C8	6	NA	60	85	Individual
C9	3	2	20	-50	Suite
C10	5	2	75	NA	Individual
C11	2	1	15	102	NA
C12	10	1	200	70	Individual

Limpieza de datos

Imputación de valores

Imputación en base a:

Estadísticos globales
 media, mediana, moda...

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	Tipo de habitación
C1	3	2	45	120.5	Doble
C2	5	2	90	95	Familiar
C3	1	1	3	150	Suite
C4	7	1	120	80.7	Individual
C5	2	2	10	110	Familiar
C6	4	2	60.7	105	Doble
C7	0	2	30	98	Doble
C8	6	1	60	85	Individual
C9	3	2	20	96.6	Suite
C10	5	2	75	96.6	Individual
C11	2	1	15	102	Individual
C12	10	1	200	70	Individual

Limpieza de datos

Imputación de valores

Imputación en base a:

Estadísticos globales

Estadísticos por grupo

Ej: precio medio del grupo tipo de habitación.

Mejor que el estadístico global, pero debe haber relación entre dos variables/categorías

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	Tipo de habitación
C1	3	2	45	120.5	Doble
C2	5	2	90	95	Familiar
C3	1	1	3	150	Suite
C4	7	1	120	80.7	Individual
C5	2	2	10	110	Familiar
C6	4	2	30	105	Doble
C7	0	2	30	98	Doble
C8	6	1	60	85	Individual
C9	3	2	20	150	Suite
C10	5	2	75	78.3	Individual
C11	2	1	15	102	Doble
C12	10	1	200	70	Individual

Limpieza de datos

Imputación de valores

Imputación en base a:

Estadísticos globales

Estadísticos por grupo

Valor constante

Útil cuando el hecho de que falte es relevante para el modelo

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	Tipo de habitación
C1	3	2	45	120.5	Doble
C2	5	2	90	95	Familiar
C3	1	1	3	150	Suite
C4	7	1	120	80.7	Individual
C5	2	2	10	110	Familiar
C6	4	2	0	105	Doble
C7	0	2	30	98	Doble
C8	6	0	60	85	Individual
C9	3	2	20	0	Suite
C10	5	2	75	0	Individual
C11	2	1	15	102	0
C12	10	1	200	70	Individual

Limpieza de datos

Imputación de valores

Imputación en base a:

Estadísticos globales

Estadísticos por grupo

Valor constante

Basado en modelos

busca modelar el valor más probable en los valores de todo el dataset. ej: KNN

costoso computacionalmente, pero el método más preciso. **Posible data leakage!**

Cliente	Noches	Adultos	Días anticipación	Precio noche (€)	Tipo de habitación
C1	3	2	45	120.5	Doble
C2	5	2	90	95	Familiar
C3	1	1	3	150	Suite
C4	7	1	120	80.7	Individual
C5	2	2	10	110	Familiar
C6	4	2	55	105	Doble
C7	0	2	30	98	Doble
C8	6	1	60	85	Individual
C9	3	2	20	136	Suite
C10	5	2	75	81	Individual
C11	2	1	15	102	Doble
C12	10	1	200	70	Individual

Limpieza de datos

Outliers - Impacto

Pueden afectar gravemente al modelo:


- Distorsionan estadísticas (media, desviación estándar...)
- Sesgan el entrenamiento: algunos modelos intentan ajustarse a esos valores extremos.
- Algunos algoritmos son especialmente sensibles

***No** tienen por que ser **erróneos**, pero sí pueden ser ejemplos **no representativos en el dataset** y por tanto poco útiles para el modelo y quizás **confusos**

Limpieza de datos


Outliers - Detección

Métodos visuales (Generalmente necesitan de un estadístico para justificar la eliminación del outlier en un paper o un trabajo importante)




Boxplot

hace estadística basada en IQR para marcar outlier



Histogramas



Scatter plot

Limpieza de datos

Outliers - Detección

Métodos estadísticos

- Basado en IQR:

Es outlier si:

$$x < Q1 - 1.5 \cdot IQR$$

$$x > Q3 + 1.5 \cdot IQR$$

*IQR = diferencia entre
percentil 75 y 25

- Basado en Z-score:

Es outlier si: $|z| > 3$

$$z = \frac{x - \mu}{\sigma}$$

x = valor observado

μ = media

σ = desviación estándar

Limpieza de datos

Outliers - qué hacer con ellos

- Eliminar el dato: si no son errores sino que representan un dato raro
ej: un atleta olímpico en un dataset de app para salud
 - Algunas transformaciones estadísticas pueden reducir su efecto
 - Utilizar modelos más robustos a outliers, que se vean menos afectados
- *Si son outliers y se detectan de forma robusta, lo más seguro es eliminar el dato**

Limpieza de datos

Checklist

Paso	Qué revisar	Qué hacer	Relación con el ejemplo (hotel)
Tipos de variables	Verificar que cada columna tenga el tipo correcto	Convertir tipos si es necesario (numérico, categórico, etc.)	precio debe ser numérico, país categórico
Duplicados	Detectar registros repetidos	Eliminar duplicados	misma reserva registrada dos veces
Valores faltantes	Detectar columnas con valores NA	Imputar valores o eliminar registros	precio, país, adultos pueden tener NA
Rangos válidos	Detectar valores imposibles	Corregir o eliminar registros erróneos	precio < 0, noches = 0
Outliers	Detectar valores extremos	eliminar, corregir o transformar	reserva con 200 días de anticipación
Porcentaje de missing	Evaluar gravedad del problema	Si el porcentaje es alto, considerar eliminar la variable.	Si precio falta en muchas filas
Categorías existentes	Verificar categorías válidas	Unificar o limpiar etiquetas	"web" vs "Web"
Frecuencias categóricas	Analizar distribución de categorías	Detectar clases muy raras o errores	ver cuántas reservas vienen de cada canal

Limpieza de datos

Checklist

Paso	Qué revisar	Qué hacer	Relación con el ejemplo (hotel)
Tipos de variables	Verificar que cada columna tenga el tipo	Convertir tipos si es necesario (numérico, categórico,	precio debe ser numérico, país categórico
Duplicados	Det	Antes de imputar o eliminar aquí, mirar si la variable tiene alto porcentaje de missing	
Valores faltantes	Detectar columnas con valores NA	Imputar valores o eliminar registros	precio, país, adultos pueden tener NA
Rangos válidos	Detectar valores imposibles	Corregir o eliminar registros erróneos	precio < 0, noches = 0
Outliers	Detectar valores extremos	eliminar, corregir o transformar	reserva con 200 días de anticipación
Porcentaje de missing	Evaluar gravedad del problema	Si el porcentaje es alto, considerar eliminar la variable.	Si precio falta en muchas filas
Categorías existentes	Verificar categorías válidas	Unificar o limpiar etiquetas	"web" vs "Web"
Frecuencias categóricas	Analizar distribución de categorías	Detectar clases muy raras o errores	ver cuántas reservas vienen de cada canal

Primer ejemplo de aprendizaje supervisado: Regresión

Carlos Bibián Nogueras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires

Aprendizaje supervisado

Resumen

En el **aprendizaje supervisado** el modelo aprende una **relación entre** variables de entrada (**features**) y una variable objetivo conocida (**target**).

Si la variable objetivo es


discreta/categórica - Clasificación!

continua - Regresión

Regresión

En un problema de regresión el objetivo es predecir una variable numérica continua.


Una cadena hotelera quiere mejorar su sistema de precios. Nos contacta para construir un modelo que estime el precio total de una reserva en función del número de noches -> **output continua** -> **regresión**



Regresión

Idea básica

Un modelo de regresión intenta aprender una función que relacione las variables de entrada con la variable objetivo.



$$y = f(x)$$

$$\text{precio} = f(\text{noches})$$



Regresión

Regresión lineal

La regresión lineal **asume** que la **relación entre las variables** puede aproximarse mediante una combinación **lineal** de las features.

Modelo (regresión lineal)

$$y = \beta_0 + \beta_1 x$$


donde:

y: valor que queremos predecir (precio)

x: variable de entrada (noches)

β_0 : intercepto

β_1 : pendiente (cuánto sube el precio cuando suben las noches)



Regresión

Regresión lineal - Ajuste del modelo

Durante el entrenamiento el modelo ajusta sus parámetros (β_0, β_1) para minimizar el error entre las predicciones y los valores reales.

Modelo (regresión lineal)

$$y = \beta_0 + \beta_1 x$$

Ajuste del modelo

Error generalmente a través del MSE

donde:

y: valor que queremos predecir (precio)


x: variable de entrada (noches)

β_0 : intercepto

β_1 : pendiente (cuánto sube el precio cuando suben las noches)

$$MSE = \frac{1}{n} \sum_{\text{residuos}} (y_i - \hat{y}_i)^2$$

Predicción



Regresión

Regresión lineal - Predicción

Durante el entrenamiento el modelo ajusta sus parámetros (β_0, β_1) para minimizar el error entre las predicciones y los valores reales.

Modelo (regresión lineal)

$$y = \beta_0 + \beta_1 x$$

Ajuste del modelo

Error generalmente a través del MSE

donde:

y: valor que queremos predecir (precio)


x: variable de entrada (noches)

β_0 : intercepto

β_1 : pendiente (cuánto sube el precio cuando suben las noches)

$$MSE = \frac{1}{n} \sum_{\text{residuos}} (y_i - \hat{y}_i)^2$$

Predicción



Regresión

Regresión polinómica

En algunos casos (muchos) la relación entre variables no es lineal y puede aproximarse utilizando transformaciones como términos polinómicos.


La regresión polinómica extiende la regresión lineal añadiendo términos de mayor grado para capturar relaciones más complejas.

Aumentar el grado del polinomio incrementa la complejidad del modelo y su capacidad para ajustarse a los datos.

Regresión

Underfitting y overfitting

Un modelo demasiado simple puede **no capturar la relación real** (underfitting) mientras que uno demasiado complejo puede **ajustarse demasiado a los datos de entrenamiento** (overfitting).




underfitting / alto sesgo
high bias


Regresión

Underfitting y overfitting

Un modelo demasiado simple puede **no capturar la relación real** (underfitting) mientras que uno demasiado complejo puede **ajustarse demasiado a los datos de entrenamiento** (overfitting).



underfitting / alto sesgo
high bias




overfitting / alta varianza
high variance


Regresión

Underfitting y overfitting


Un modelo demasiado simple puede **no capturar la relación real** (underfitting) mientras que uno demasiado complejo puede **ajustarse demasiado a los datos de entrenamiento** (overfitting).



underfitting / alto sesgo
high bias



buen ajuste




overfitting / alta varianza
high variance


Regresión

Underfitting y overfitting


Ejemplo en clasificación



underfitting / alto sesgo
high bias



buen ajuste




overfitting / alta varianza
high variance


Overfitting

Cómo evitarlo

Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.



¿Cómo podemos reducir el overfitting?




Overfitting

Cómo evitarlo

Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.

¿Cómo podemos reducir el overfitting?

- Aumentar la cantidad de datos de entrenamiento




Overfitting

Cómo evitarlo

Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.

¿Cómo podemos reducir el overfitting?

- Aumentar la cantidad de datos de entrenamiento
- Reducir la cantidad de características (x)




Overfitting

Cómo evitarlo

Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.

¿Cómo podemos reducir el overfitting?


- Aumentar la cantidad de datos de entrenamiento
- Reducir la cantidad de características (x)
- Evaluar el modelo en datos nuevos -> medirá su capacidad de generalización



Overfitting

Cómo evitarlo

Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.




¿Cómo podemos reducir el overfitting?

- Aumentar la cantidad de datos de entrenamiento → Caro y muchas veces imposible
- Reducir la cantidad de características (x)
- Evaluar el modelo en datos nuevos -> medirá su capacidad de generalización

Overfitting

Cómo evitarlo

Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.




¿Cómo podemos reducir el overfitting?

- Aumentar la cantidad de datos de entrenamiento → Caro y muchas veces imposible
- Reducir la cantidad de características (x) →
 - > Regularización
 - > Selección de características
- Evaluar el modelo en datos nuevos -> medirá su capacidad de generalización

Overfitting

Cómo evitarlo

Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.




¿Cómo podemos reducir el overfitting?

- Aumentar la cantidad de datos de entrenamiento → Caro y muchas veces imposible
- Reducir la cantidad de características (x) →
 - > Regularización
 - > Selección de características
- Evaluar el modelo en datos nuevos -> medirá su capacidad de generalización → Data Splits

Overfitting

Cómo evitarlo


Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.




¿Cómo podemos reducir el overfitting?

- Aumentar la cantidad de datos de entrenamiento → Caro y muchas veces imposible
- Reducir la cantidad de características (x) →
 - > Regularización **Clase siguiente**
 - > Selección de características
- Evaluar el modelo en datos nuevos -> medirá su capacidad de generalización → Data Splits **Hoy**


¿Dudas?



underfitting / alto sesgo



buen ajuste



overfitting / alta varianza



Data Splits y Learning Theory

Carlos Bibián Nogueras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires

Data Splits

Overfitting es que nuestro modelo no generalice bien a nuevos datos

¿Cómo podemos saber si generaliza bien o no?

Entrenamiento (Train)



Data Splits

Overfitting es que nuestro modelo no generalice bien a nuevos datos

¿Cómo podemos saber si generaliza bien o no? -> teniendo **datos nuevos** -> separar una parte de los datos para evaluar el modelo

Entrenamos el algoritmo en una **parte de los datos** y dejamos el **resto** sin usar para **evaluar cómo funciona** el modelo en datos nuevos.

Entrenamiento (Train)



Evaluación (Test)



Train vs Test

¿Cómo separarlos?

- El conjunto de **train** debe:
 - Ser lo suficientemente grande para poder entrenar el modelo
 - Representar el problema
- El conjunto de **test** debe:
 - **Ser totalmente independiente**
 - Debe representar los datos reales en los que el modelo se usará (que deberían ser como los de train)
 - No hace falta que sea tan grande como el train, pero debe tener suficientes datos para representar la muestra

Train vs Test

Error de predicción esperado

Elegimos el menor error en Test -> evitamos overfitting al train set

Sin embargo, el error en **predicción en test del modelo elegido en test es optimista**, ya que **ha sido elegido por funcionar mejor en esos datos**

Si modela mejor el ruido del test, no por eso funcionará mejor en datos nuevos

Necesitamos otra partición en los datos para elegir modelo en unos datos nuevos y hacer una estimación del error en otros nuevos! -> Validation set (o Dev set)

- wait what?!

Learning Theory

Introducción

Queremos modelar la relación entre unas variables y un fenómeno concreto

$$y = f(x_{real}) + \epsilon \quad \xrightarrow{\text{Al entrenar el modelo}} \quad \min_h \hat{E}_{train}(h)$$

x_{real} = variables reales que explican y
 $f(\cdot)$ = función real que relaciona x e y
 ϵ = ruido del dataset / todo lo demás
todo lo que no se puede modelar

$$\hat{E}_{train}(h) = E(h) + \epsilon$$



El modelo aprende a minimizar el error $E(h)$, pero también el error en el ruido!

Learning Theory

Tipos/fuentes de ruido

Tres tipos/fuentes de ruido:

1. **Aleatoriedad del mundo real:** errores de medición, eventos aleatorios... irreducible!

Learning Theory

Tipos/fuentes de ruido

Tres tipos/fuentes de ruido:

1. **Aleatoriedad del mundo real:** errores de medición, eventos aleatorios... irreducible!
1. **Ruido de muestreo:** al trabajar con subconjuntos de los datos, estos tienen pequeños sesgos, varianzas, ruido producido al muestrear (sería 0 para infinitos datos)

Learning Theory

Tipos/fuentes de ruido

Tres tipos/fuentes de ruido:

1. **Aleatoriedad del mundo real:** errores de medición, eventos aleatorios... irreducible!
1. **Ruido de muestreo:** al trabajar con subconjuntos de los datos, estos tienen pequeños sesgos, varianzas, ruido producido al muestrear (sería 0 para infinitos datos)
1. **Información relevante no incluida (variables):** si el modelo no tiene toda la información necesaria para modelar la relación entre x e y , verá parte de los cambios de y como ruido ya que nunca podrá explicarlos

Learning Theory

Ejemplo de falta de información como ruido

Queremos hacer un modelo para predecir

y: Índice de masa corporal (IMC) en función a

x: (marca de celular, dinosaurio favorito)

¿qué ocurrirá?

desde el punto de vista del modelo:

$$y = f(x) + \epsilon$$

$f(x)$ no tiene relación con y , será una constante casi...
imposible de minimizar

$$\min_h \hat{E}_{train}(h)$$

$$\hat{E}_{train}(h) = E(h) + \epsilon$$

1. Al minimizar el error en train, **la única forma será minimizar el error en epsilon**, el modelo intentará explicar la varianza de y como ruido, **sin usar las x ...**

2. Pero cuando lleguen datos nuevos los patrones del ruido cambiarán, y el error volverá a ser alto...

Learning Theory y Overfitting

Si entrenamos en unos datos y evaluamos en otros:

si conseguimos que:

$$E_{test}(h) \approx E_{train}(h) \longrightarrow \min_h \hat{E}_{train}(h)$$

$$\hat{E}_{train}(h) = E(h) + \epsilon$$



El modelo ha reducido $E_{train}(h)$ principalmente reduciendo $E(h)$, no aprovechando el ruido ϵ . Por eso generaliza bien.

ya que el error en test y en train se deben a los epsilon y a lo que no hayan podido reducir de $E(h)$

Learning Theory y Overfitting

Si entrenamos en unos datos y evaluamos en otros:
si obtenemos que:

$$E_{test}(h) \approx E_{train}(h) \longrightarrow \min_h \hat{E}_{train}(h)$$

$$\hat{E}_{train}(h) = E(h) + \epsilon$$



generalization gap: $E_{test}(h) - E_{train}(h)$

*Si el modelo aprende/modela ruido del train

→ el gap crece.

*Si el gap es cero, el modelo generaliza bien

El modelo ha reducido $E_{train}(h)$ principalmente reduciendo $E(h)$, no aprovechando el ruido ϵ . Por eso generaliza bien.

ya que el error en test y en train se deben a los epsilon y a lo que no hayan podido reducir de $E(h)$

Train vs Dev Pipeline

Por eso, para elegir el modelo de controlando el overfitting necesitamos dos conjuntos de datos separados.

¿Qué modelo elegimos?



	Error Datos1	Error Datos2
Modelo 1	7.2 %	7.0 %
Modelo 2	6.1 %	7.3 %
Modelo 3	4.4 %	8.8 %
Modelo 4	6.5 %	7.4 %

Train vs Dev Pipeline

Por eso, para elegir el modelo de controlando el overfitting necesitamos dos conjuntos de datos separados.

¿Qué modelo elegimos?



	Error Datos1	Error Datos2
Modelo 1	7.2 %	7.0 %
Modelo 2	6.1 %	7.3 %
Modelo 3	4.4 %	8.8 %
Modelo 4	6.5 %	7.4 %

Train vs Dev Pipeline

Por eso, para elegir el modelo de controlando el overfitting necesitamos dos conjuntos de datos separados.

¿Qué modelo elegimos?

¿Cómo funciona ese modelo en datos nuevos?

	Error Datos1	Error Datos2
Modelo 1	7.2 %	7.0 %

Entrenamiento (**Train**)

Model selec. (**Dev**)



Train vs Dev Pipeline

Por eso, para elegir el modelo de controlando el overfitting necesitamos dos conjuntos de datos separados.

¿Qué modelo elegimos?

¿Cómo funciona ese modelo en datos nuevos?

	Error Datos1	Error Datos2
Modelo 1	7.2 %	7.0 %

Entrenamiento (**Train**)



Model selec. (**Dev**)



Hemos elegido el modelo que mejor iba en Datos2, por lo que **ese estimador estaría optimistamente sesgado!** **Datos2** ya no son “datos nuevos” para eso

Train vs Dev vs Test Pipeline

Por eso, para elegir el modelo de controlando el overfitting y poder además estimar de forma insesgada como va a funcionar ese modelo en datos nuevos...

Entrenamiento (**Train**)



Model selec. (**Dev**)



Evaluación (**Test**)



Train vs Dev vs Test

¿Cómo separarlos?



Generalmente, 60-20-20 es una buena regla (en datasets pequeños-medianos approx 200-500 datos)



En datasets muy grandes (DL), de millones de ejemplos, se suele reducir a 90-5-5 o incluso 98-1-1.

*Depende de la resolución que necesitemos en la performance de dev y test, si necesitamos 0.05% de resolución, dev y test necesitarán un poco más de datos, 90-5-5 por ejemplo.



Si el dataset es muy pequeño (100 datos) ... 20 ejemplos para elegir el modelo (dev) y para estimar perf (test) puede ser insuficiente. (a veces incluso los 60 para train también).

Train vs Dev vs Test

¿Cómo separarlos?



Generalmente, 60-20-20 es una buena regla (en datasets pequeños-medianos approx 200-500 datos)

En esta materia nos vamos a mover en este rango



En datasets muy grandes (DL), de millones de ejemplos, se suele reducir a 90-5-5 o incluso 98-1-1.

*Depende de la resolución que necesitemos en la performance de dev y test, si necesitamos 0.05% de resolución, dev y test necesitarán un poco más de datos, 90-5-5 por ejemplo.



Si el dataset es muy pequeño (100 datos) ... 20 ejemplos para elegir el modelo (dev) y para estimar perf (test) puede ser insuficiente. (a veces incluso los 60 para train también).


Train vs Dev vs Test

Cross Validation

Recomendable para datasets pequeños (por ejemplo salud)

Computacionalmente más costoso, pero con datasets pequeños eso no debería ser un problema muy grande, y nos permite utilizar los datos de manera más eficiente

$k = 5$ o 10 son las más usadas y son suficientes



k = 5 o 10 son las más usadas y son suficientes




Train vs Dev vs Test

Cross Validation (leave-one-out)

Útil para datasets muy pequeños (menos de 80 ejemplos)

¡Aún más costoso computacionalmente que el anterior!



Train vs Dev vs Test

Ejemplo

ya tengo mi modelo elegido, ¿y ahora? ¿qué modelo entrego/implemento/publico?

...

Se elige y **ese modelo se entrena con TODO el train+dev** y ese modelo se entrega/implementa y se evalúa en test

Test set

Sólamente se utiliza para estimar el error de predicción en datos nuevos, nunca para tomar decisiones.

Lo más seguro es usarlo solo al final del proyecto para reportar resultados a jefe/a, publicarlo en un paper etc.



Excepciones (avanzado):

*si sólo necesitamos elegir el mejor modelo pero no necesitamos saber cómo de bien va a funcionar, podríamos hacer solo train-dev, y así usar todos los datos.


****Pero sabiendo que el error en dev del modelo ganador va a estar optimistamente sesgado!!****

*se puede usar durante el proyecto si únicamente se reporta el valor a otra persona/jefe/parte del proyecto. Pero en ese caso, ser extra cuidadosos con **no elegir un modelo por el resultado de test, o no dejar de probar modelos cuando el test sea suficientemente bueno...**

Overfitting

Cómo evitarlo

Si añadimos suficientes feats (x), eventualmente seremos capaces de reducir el error al máximo ya que cada w se podría “usar” para modelar cada datapoint.



¿Cómo podemos reducir el overfitting?

- Aumentar la cantidad de datos de entrenamiento → **Caro y muchas veces imposible**
- Reducir la cantidad de características (x) →
 - > Regularización **Clase siguiente**
 - > Selección de características
- Evaluar el modelo en datos nuevos -> medirá su capacidad de generalización → **Data Splits Visto!**

¿Cuántos datos?

Algunas guías prácticas

Regla práctica: La “**regla del 10x**” -> 10 veces más ejemplos que parámetros (degrees of freedom).

- Ejemplo: 10 variables/features → se necesitan ~100 ejemplos.
- Funciona como aproximación para modelos pequeños.
- Limitación: en modelos grandes (deep learning) no basta con contar filas; también importa el tamaño y complejidad de cada input.

Para Deep learning, Goodfellow, Bengio et al., en su libro recomiendan 5000 ejemplos por clase en un DL supervisado

Para visión por computador 1000 imágenes por clase puede ser un buen punto de partida

Importante, buscar ejemplos similares de proyectos para ver cuántos datos usaron!


¿Serían útiles más datos?

Curvas de aprendizaje

Empezar con una cantidad razonable de datos, y evaluar el learning

- **Curvas de aprendizaje:** evaluar performance para distintas cantidades de datos (ej: 50%,60%..100% de los datos que tenemos) y ver si añadir datos aumentaría el resultado

¿Cual de esas sugiere que grabar datos sería útil?



Train vs Dev vs Test

Recap y ejemplo

¿Donde realizarían la separación train-test?

Recolección de datos

Limpieza de datos - quitar outliers, duplicados, imputar ...

Convertir a tipos de variables que sepamos usar (numéricas)

Evaluar features y elegir las mejores (o todas)

Elegir modelos que se van a evaluar

Entrenar modelos

Elegir el mejor modelo

Implementar el mejor modelo y estimar su error estimado en datos nuevos

Train vs Dev vs Test

Recap y ejemplo

¿Donde realizarían la separación train-test?

Recolección de datos

Limpieza de datos - quitar outliers, duplicados, imputar ...

Convertir a tipos de variables que sepamos usar (numéricas)

Evaluar features y elegir las mejores (o todas)

Elegir modelos que se van a evaluar

Entrenar modelos

Elegir el mejor modelo

¿Separar Test aquí?

Cuidado con el data leakage! Si quitamos outliers e imputamos valores usando TODO el dataset, información que luego irá al test, estará siendo usada para train!

Implementar el mejor modelo y estimar su error estimado en datos nuevos

Train vs Dev vs Test

Recap y ejemplo

Recolección de datos

Limpieza de datos - quitar outliers, duplicados, imputar ...

Convertir a tipos de variables que sepamos usar (numéricas)

Evaluar features y elegir las mejores (o todas)

Elegir modelos que se van a evaluar

Entrenar modelos

Elegir el mejor modelo

Separar Test aquí

idealmente automatizar toda la limpieza, imputación... etc y conversión de tipos para que en los datos de test se aplique el mismo procesamiento (y también en dev!)

¿Donde se separa el dev?

Implementar el mejor modelo y estimar su error estimado en datos nuevos

Train vs Dev vs Test

Recap y ejemplo

Recolección de datos

Limpieza de datos - quitar outliers, duplicados, imputar ...

Convertir a tipos de variables que sepamos usar (numéricas)

Evaluar features y elegir las mejores (o todas)

Elegir modelos que se van a evaluar

Entrenar modelos

Elegir el mejor modelo

Separar Test aquí

idealmente automatizar toda la limpieza, imputación... etc y conversión de tipos para que en los datos de test se aplique el mismo procesamiento (y también en dev!)

Separar Dev aquí



idealmente deberíamos separar el Dev a la vez que el test, pero en la práctica a veces se separa justo antes de entrenar por simplicidad

Mirando error en Dev

Implementar el mejor modelo y estimar su error estimado en datos nuevos

Calculando error en Test


¿dudas?



Entrenamiento (**Train**)

Model selec. (**Dev**)

Evaluación (**Test**)



7.8
7.6
8.2
6.9
7.5
8.0

