

72.75: Aprendizaje Automático (Machine Learning)

Horario: Miércoles 16-19h- virtual sincrónico

Profesorado de la asignatura:

Francisco Sammartino, Ing. | frperez@itba.edu.ar

Alexa Sessarego Aurich

Carlos Bibián Nogueras, PhD | cbibian@itba.edu.ar

Plan de la sesión de hoy

- Problema-Datos-Features
- EDA
- Feature selection
- Regularización
- Métricas

... en la sesión anterior

- Tipos de variables y qué hacer con ellos
- Limpieza de datos
- Primer ejemplo de supervisado: Regresión
- Data Splits

Referencias

References

Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. O'Reilly, 2019.



Zinkevich, M. Rules of Huyen, C. *Designing Machine Learning Systems*. O'Reilly, 2022.

Machine Learning: Best Practices for ML Engineering. Google Developers.

Google Cloud. *MLOps: Continuous delivery and automation pipelines in machine learning*.

Sculley, D. et al. *Hidden Technical Debt in Machine Learning Systems*. NeurIPS, 2015.

scikit-learn. *Model evaluation: quantifying the quality of predictions*.



Terminología

Terminology

Classifier / Model: El componente que aprende la regla de decisión y produce la predicción. / *The component that learns the decision rule and produces the prediction.* Ej.: Decision Tree, SVM, Logistic Regression, Random Forest.

ML Pipeline: El sistema completo desde las features de entrada hasta la predicción. / *The complete system from input features to prediction.*

$X \rightarrow \text{preprocessing} \rightarrow \text{feature selection} \rightarrow \text{classifier} \rightarrow y$

Parameters: Valores aprendidos durante el entrenamiento. / *Values learned during training.*

Hyperparameters: Decisiones que configuran el aprendizaje o el pipeline. / *Choices that configure the learning process or the pipeline.* Ej.: `max_depth`, `C`, `k` en feature selection.

Feature set: Conjunto de variables que decidimos usar. / *The set of features we decide to use.*

¿Qué estamos estimando en realidad?

What are we actually estimating?

$$\text{Performance_validation} = \text{Performance_real} + \text{validation noise}$$

¿Qué estamos estimando en realidad?

What are we actually estimating?

$$\text{Performance_validation} = \text{Performance_real} + \text{validation noise}$$

Ese **ruido** proviene de varias fuentes, la principal es que los datos de validación son un **subconjunto finito de los datos** (también las características son sólo **una parte de toda la información disponible** para resolver el problema)

*That **noise** comes from several factors: the main one being our dataset is a **subset of the data** (also our features are only a **part of the information available** to model our problem)*

Model selection (**Development/Validation set**)

M1	M2	M3	M4	M5
0.67	0.72	0.69	0.77	0.74

¿Qué estamos estimando en realidad?

What are we actually estimating?

$$\text{Performance_validation} = \text{Performance_real} + \text{validation noise}$$

Ese **ruido** proviene de varias fuentes, la principal es que los datos de validación son un **subconjunto finito de los datos** (también las características son sólo **una parte de toda la información disponible** para resolver el problema)

*That **noise** comes from several factors: the main one being our dataset is a **subset of the data** (also our features are only a **part of the information available** to model our problem)*

Model selection (Development/Validation set)

M1	M2	M3	M4	M5
0.67	0.72	0.69	0.77	0.74

En otro dataset de validación podríamos obtener...

M1	M2	M3	M4	M5
0.66	0.72	0.72	0.75	0.76

O...

M1	M2	M3	M4	M5
0.65	0.70	0.76	0.74	0.73

¿Por qué lo hacemos?

Why bother?

$$\text{Performance_validation} = \text{Performance_real} + \text{validation noise}$$

Al elegir el modelo usando los datos de validación, **evitamos seleccionar simplemente el modelo que mejor se ajustó a las particularidades** —y al ruido— del conjunto de **entrenamiento**.

By selecting the model using validation data, we avoid simply choosing the model that best fits the particularities —and noise— of the training set.

La validación nos permite pasar **de mejor ajuste a los datos de entrenamiento a mejor generalización**

Validation helps us move from fit-to-train to estimate-of-generalization.

Entonces... ¿Por qué lo hacemos?

So... Why bother again?

La performance en validación también es una estimación ruidosa de la performance real.

Validation performance is also a noisy estimate of the true performance.

Si probamos muchos modelos y elegimos el que obtiene el mejor resultado en validación, **tenderemos a seleccionar no solo un modelo bueno, sino también uno que tuvo una estimación favorable por azar.**

If we try many models and select the one with the best validation score, we tend to select not only a good model, but also one that benefited from favorable random variation.

Solución: Tener un conjunto nuevo (test) para realizar una estimación nueva de cómo funciona el modelo elegido

Solution: Having a subset of new data (test) to make a new estimation of how the chosen model works

Resumen

Recap



Train set

para aprender los **parámetros** el modelo
*to learn the model **parameters***

El **modelo** ajusta a los patrones de esos
datos

*The **model** fits the patterns in these
data.*

Resumen

Recap




Train set

para aprender los **parámetros** el modelo
*to learn the model **parameters***

El **modelo** ajusta a los patrones de esos
datos

*The **model** fits the patterns in these
data.*



Validation set

para hacer la elección de todo el **pipeline**
*to make decisions on the whole **pipeline**.*

Elegimos **modelos**, **hiperparámetros**... evitando
elegir los que mejor ajusten las particularidades
de los datos de train

*We use it to compare **models** and tune
hyperparameters without the one that best fits
the particularities of training data.*

Resumen

Recap




Train set

para aprender los **parámetros** el modelo
*to learn the model **parameters***

El **modelo** ajusta a los patrones de esos datos

*The **model** fits the patterns in these data.*



Validation set

para hacer la elección de todo el **pipeline**
*to make decisions on the whole **pipeline**.*

Elegimos **modelos**, **hiperparámetros**... evitando elegir los que mejor ajusten las particularidades de los datos de train

*We use it to compare **models** and tune **hyperparameters** without the one that best fits the particularities of training data.*



Test set

para estimar la generalización del **pipeline** final
*to estimate the generalization of the final **pipeline**.*

Nos permite calcular un estimador insesgado de la performance en datos nuevos


It provides an independent estimate of performance on unseen data.

k-fold Cross-Validation

Recap

Nos permite utilizar los datos de manera más eficiente -> utilizamos TODOS los datos de train para validación una vez (sin que se usen para entrenar esa vez)

$k = 5$ o 10 son las más usadas y son suficientes




k-fold Cross-Validation

Recap

Nos permite utilizar los datos de manera más eficiente -> cada dato de train se utiliza para validación una vez (sin que se usen para entrenar esa vez)

$k = 5$ o 10 son las más usadas y son suficientes



k-fold Cross-Validation

Recap

Nos permite utilizar los datos de manera más eficiente -> utilizamos TODOS los datos de train para validación una vez (sin que se usen para entrenar esa vez)

$k = 5$ o 10 son las más usadas y son suficientes



k-fold Cross-Validation

Recap

Utilizamos los datos de forma más eficiente: Cada observación se utiliza una vez para validación y el resto de las veces para entrenamiento.

We use the available data more efficiently: each observation is used once for validation and in the remaining folds for training.

Obtenemos una **estimación más estable** del rendimiento: En lugar de depender de una única partición, evaluamos el modelo en varios splits y promediamos los resultados.


More robust estimation of performance: *since we evaluate it across several splits and averaging the results.*

Reducimos nuestra dependencia de un único validation split, que puede ser afortunado (o desafortunado!)

We reduce our dependence on a single validation split that may be lucky — or unlucky.


Proyecto de ML

Pipeline clásico de un proyecto



Proyecto de ML

Pipeline clásico de un proyecto



Problema-Datos-Features

Carlos Bibián Nogueras, PhD

cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires

Ejemplo de proyecto de ML

Example of ML project

[Sign In](#) [Register](#)

 UCI MACHINE LEARNING AND 1 COLLABORATOR ·
UPDATED 9 YEARS AGO

▲ 3853

<> Code


Download



⋮

Breast Cancer Wisconsin (Diagnostic) Data Set

Predict whether the cancer is benign or malignant



[Data Card](#) [Code \(3462\)](#) [Discussion \(53\)](#) [Suggestions \(0\)](#)

Visión del proyecto

Vision of the project

- ¿Cual es el objetivo del proyecto?
 - Construir un algoritmo no es el objetivo!! (casi nunca)
- ¿Como va a usarse el resultado del modelo?
 - ¿Se va a implementar en tiempo real el modelo? ¿Independiente o como parte de otro?
 - ¿Hay algún tipo de error del sistema que no deba producirse? (Diagnostico erróneo de una enfermedad)
- ¿Hay algún modelo que actualmente se use para esto en la empresa/laboratorio/etc?
 - Referencia de performance, que estrategia se siguió para resolver el problema...

Estas preguntas ya van a empezar a definir:

- **Algoritmos** que podemos usar: clasificación/regresión, supervisado/no supervisado, DL o ML...
- **Métricas** debemos evaluar: precisión (y que métrica usar) , tiempo de computo, complejidad del sistema...
- Cuánto esfuerzo debemos poner y **qué aspectos optimizar**



Visión del proyecto

Vision of the project

- ¿Cual es el objetivo del proyecto?
 - Construir un algoritmo no es el objetivo!! (casi nunca)
- ¿Cómo va a usarse el resultado del modelo?
 - ¿Se va a implementar en tiempo real el modelo? ¿Independiente o como parte de otro?
 - ¿Hay algún tipo de error del sistema que no deba producirse? (Diagnóstico erróneo de una enfermedad)
- ¿Hay algún modelo que actualmente se use para esto en la empresa/laboratorio/etc?
 - Referencia de performance, que estrategia se siguió para resolver el problema...

Estas preguntas ya van a empezar a definir:

- **Algoritmos** que podemos usar: clasificación/regresión, supervisado/no supervisado, DL o ML...
- **Métricas** debemos evaluar: precisión (y que métrica usar) , tiempo de computo, complejidad del sistema...
- Cuánto esfuerzo debemos poner y **qué aspectos optimizar**



Visión del proyecto

Vision of the project

- ¿Cual es el objetivo del proyecto?
 - Construir un algoritmo no es el objetivo!! (casi nunca)
- ¿Cómo va a usarse el resultado del modelo?
 - ¿Se va a implementar en tiempo real el modelo? ¿Independiente o como parte de otro?
 - ¿Hay algún tipo de error del sistema que no deba producirse? (Diagnóstico erróneo de una enfermedad)
- ¿Hay algún modelo que actualmente se use para esto en la empresa/laboratorio/etc?
 - Referencia de performance, que estrategia se siguió para resolver el problema...

Estas preguntas ya van a empezar a definir:

- **Algoritmos** que podemos usar: clasificación/regresión, supervisado/no supervisado, DL o ML...
- **Métricas** debemos evaluar: precisión (y que métrica usar) , tiempo de computo, complejidad del sistema...
- Cuánto esfuerzo debemos poner y **qué aspectos optimizar**




Visión del proyecto

Vision of the project

- ¿Cual es el objetivo del proyecto?
 - Construir un algoritmo no es el objetivo!! (casi nunca)
- ¿Cómo va a usarse el resultado del modelo?
 - ¿Se va a implementar en tiempo real el modelo? ¿Independiente o como parte de otro?
 - ¿Hay algún tipo de error del sistema que no deba producirse? (Diagnóstico erróneo de una enfermedad)
- ¿Hay algún modelo que actualmente se use para esto en la empresa/laboratorio/etc?
 - Referencia de performance, que estrategia se siguió para resolver el problema...

Estas preguntas ya van a empezar a definir:

- **Algoritmos** que podemos usar: clasificación/regresión, supervisado/no supervisado, DL o ML...
- **Métricas** debemos evaluar: precisión (y que métrica usar) , tiempo de cómputo, complejidad del sistema...
- Cuánto esfuerzo debemos poner y **qué aspectos optimizar**



Visión del proyecto

Vision of the project

- ¿Cuál es el objetivo del proyecto?
 - Construir un algoritmo no es el objetivo!!

Construir una herramienta automática de diagnóstico de Cáncer de pecho a partir de imágenes.

- ¿Cómo va a usarse el resultado del modelo?
 - ¿Se va a implementar en tiempo real el modelo? ¿Independiente?
 - ¿Hay algún tipo de error del sistema que no deba producirse?

Se va a utilizar offline (no tiempo real).
El Falso negativo es el tipo de error que más penaliza.

- ¿Hay algún modelo que actualmente se use para esto en la empresa/laboratorio/etc?
 - Referencia de performance, que estrategia se siguió para resolver el problema...

Estas preguntas ya van a empezar a definir:

- **Algoritmos** que podemos usar: clasificación/regresión, s...
- **Métricas** debemos evaluar: precisión (y que métrica usar)
- Cuánto esfuerzo debemos poner y **qué aspectos optimiz**

- 1) No hay limitación en tiempo de cómputo (ya que no se va a usar en tiempo real)
- 2) Las métricas deben tener en cuenta la presencia de Falsos Negativos
- 3) No tenemos acceso a una gran cantidad de datos

Datos

Data

- ¿Qué factores son relevantes para el problema a resolver?
 - ¿Cómo resolverías tú el problema manualmente?
 - Preguntar a expertos en el tema (multidisciplinar!)
 - ¿Hay problemas similares ya resueltos?
- ¿Qué capacidad de cómputo y almacenamiento tenemos?
- ¿Tenemos ya los datos?
 - Entender bien la estructura de los datos y qué son cada una de las características.


Antes de seguir, **crear el conjunto de test** y separar esos datos para no volverlos a usar hasta el final del proyecto

- Típicamente seleccionar aleatoriamente 20% de los datos (a no ser que tengamos un dataset muy grande)


Datos

Data

- ¿Qué factores son relevantes para el problema a resolver?
 - **¿Cómo resolverías tú el problema manualmente?**
 - **Preguntar a expertos en el tema (multidisciplinar!)**
 - ¿Hay problemas similares ya resueltos?



Smear with BENIGN diagnosis – uniform nucleus of cells, symmetrical, homogeneous, with areas within normal size



Smear with MALIGNANT diagnosis – nucleus of cells without uniformity, asymmetrical, not homogeneous (multiple sizes) and with areas above normal size


Un patólogo para realizar su diagnóstico se basa en:

- Uniformidad nuclear (Benigno: núcleos - pequeños y uniformes, Maligno: núcleos grandes e irregulares)
- Mitosis (Benigno: rara o ausente, Maligno: frecuente)
- Contorno nuclear (Benigno: lisos, Maligno: irregulares o dentados)


...

Datos

Data



Smear with BENIGN diagnosis – uniform nucleus of cells, symmetrical, homogeneous, with areas within normal size



Smear with MALIGNANT diagnosis – nucleus of cells without uniformity, asymmetrical, not homogeneous (multiple sizes) and with areas above normal size




Figure 6: Sequence of Measurements for Computing Fractal Dimension

- a) **Radio** (media de las distancias desde el centro a los puntos del perímetro)
- b) **Textura** (desviación estándar de los valores en escala de grises)
- c) **Perímetro**
- d) **Área**
- e) **Suavidad** (variación local en las longitudes del radio)
- f) **Compacidad** ($\text{perímetro}^2 / \text{área} - 1.0$)
- g) **Concavidad** (gravedad de las porciones cóncavas del contorno)
- h) **Puntos cóncavos** (número de porciones cóncavas del contorno)
- i) **Simetría**

Datos

Data

- ¿Qué factores son relevantes para el problema a resolver?
 - ¿Cómo resolverías tú el problema manualmente?
 - Preguntar a expertos en el tema (multidisciplinar!)
 - ¿Hay problemas similares ya resueltos?
- ¿Qué capacidad de cómputo y almacenamiento tenemos?

- a) **Radio**
- b) **Textura**
- c) **Perímetro**
- d) **Área**
- e) **Suavidad**
- f) **Compacidad**
- g) **Concavidad**
- h) **Puntos cóncavos**
- i) **Simetría**

- ¿Tenemos ya los datos?
 - Entender bien la estructura de los datos y qué son cada una de las características.

Antes de seguir, **crear el conjunto de test** y separar esos datos para no volverlos a usar hasta el final del proyecto

- Típicamente seleccionar aleatoriamente 20% de los datos (a no ser que tengamos un dataset muy grande)

Datos

Data

- ¿Qué factores son relevantes para el problema a resolver?
 - ¿Cómo resolverías tú el problema manualmente?
 - Preguntar a expertos en el tema (multidisciplinar!)
 - ¿Hay problemas similares ya resueltos?
- ¿Qué capacidad de cómputo y almacenamiento tenemos?
- ¿Tenemos ya los datos?
 - Entender bien la estructura de los datos y qué son cada una de las características.

Antes de seguir, [crear el conjunto de test](#) y separar esos datos para no volverlos a usar hasta el final del proyecto

- Típicamente seleccionar aleatoriamente 20% de los datos (a no ser que tengamos un dataset muy grande)

Datos

Data

- ¿Qué factores son relevantes para el problema a resolver?
 - ¿Cómo resolverías tú el problema manualmente?
 - Preguntar a expertos en el tema (multidisciplinar!)
 - ¿Hay problemas similares ya resueltos?
- ¿Qué capacidad de cómputo y almacenamiento tenemos?
- ¿Tenemos ya los datos?
 - **Entender bien la estructura de los datos y qué son cada una de las características. ->EDA**

Antes de seguir, [crear el conjunto de test](#) y separar esos datos para no volverlos a usar hasta el final del proyecto

- Típicamente seleccionar aleatoriamente 20% de los datos (a no ser que tengamos un dataset muy grande)

Análisis Exploratorio de Datos (EDA)

Exploratory Data Analysis (EDA)

Carlos Bibián Nogueras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires

Análisis Exploratorio de Datos (EDA)

Exploratory Data Analysis (EDA)

Antes de entrenar modelos, necesitamos **entender los datos que tenemos**

En la clase anterior, vimos cómo transformar las variables a valores numéricos y cómo limpiar los posibles datos erróneos o anómalos

EDA es el proceso siguiente y consiste en explorar y resumir un dataset

Si hemos participado en la creación del dataset, ya tenemos mucho aprendido sobre las variables que tenemos, pero todavía necesitamos entender mejor la estructura, patrones y posibles problemas

Objetivos

Goals

El Análisis Exploratorio de Datos (EDA) consiste en examinar y visualizar los datos para comprender su estructura y patrones antes de entrenar modelos.

- detectar problemas en los datos (limpieza de datos-Clase anterior)
- entender las variables del dataset,
- descubrir relaciones entre variables.

Distribución de las variables/características


Distribution of the variables/features

- Estadísticas descriptivas (media, mediana, desviación estándar, mínimos y máximos) permiten obtener una primera comprensión de los datos.

- Histogramas y Boxplots

Nos permiten entender mejor la distribución de los datos


Como vimos en la clase anterior, también nos permite detectar outliers y posibles valores erróneos



Distribución de las variables/características - Ejemplo

Distribution of the variables/features - Example

Variable peso en un sistema de envío



Podríamos pensar que es numérica continua, pero al ver el histograma vemos que está discretizada al peso del envío (categoría de precio..)

Solución:

Aplicar lo que vimos de numéricas discretas:


one-hot encoding

-> o crear otra feature binaria (ej., >15 kgs)

Distribución de las variables/características - Ejemplo 2

Distribution of the variables/features - Example 2


Variable frecuencia visitas a una web /dia)



Distribución de las variables/características - Ejemplo 2

Distribution of the variables/features - Example 2

Variable frecuencia visitas a una web /dia)



Otro pico en torno a 120/día... probablemente bots -> 2 poblaciones distintas!

-Evaluar si el modelo debe modelar también el comportamiento de esa población. Si no, quitarlo. Si si... :

- a) Dar esa info al sistema: crear variable `is_bot` (binaria) que sea 1 si `nvisitas > 80` (por ejemplo)
- b) Separar el dataset en dos y entrenar dos modelos distintos


Ver cantidad de datos y relevancia del segundo grupo para ver si se justifica y se puede hacer

Ver el histograma separado para cada población para ver si realmente son distintas las otras variables en función a esta división

Distribución de las variables/características - Ejemplo 2

Distribution of the variables/features - Example 2

Variable frecuencia visitas a una web /dia)



Otro pico en torno a 120/día... probablemente bots -> 2 poblaciones distintas!

-Evaluar si el modelo debe modelar también el comportamiento de esa población. Si no, quitarlo. Si si... :

- Dar esa info al sistema: crear variable `is_bot` (binaria) que sea 1 si `nvisitas > 80` (por ejemplo)
- Separar el dataset en dos y entrenar dos modelos distintos


Ver cantidad de datos y relevancia del segundo grupo para ver si se justifica y se puede hacer

Ver el histograma separado para cada población para ver si realmente son distintas las otras variables en función a esta división

Distribución de las variables/características - Ejemplo 3

Distribution of the variables/features - Example 3

Variable superficie de una propiedad



¿Qué está ocurriendo?

Escalado de variables

Relevancia

Las variables numéricas pueden tener escalas muy diferentes.

Ejemplo:

- edad $\rightarrow$ 0-100
- ingresos $\rightarrow$ 0-100000
- número de compras $\rightarrow$ 0-50

Estas diferencias de escala pueden afectar a algunos modelos.

El error de regresión, por ejemplo, será mucho mayor en las variables de mayor rango, y por tanto el modelo priorizará reducir el error en esas variables

Escalado de variables

Relevancia

Antes de comparar características o entrenar ningún clasificador, es recomendable **siempre escalar las variables** para que todas estén en el **mismo rango**:

Sin escalado, algunos métodos daría más peso a las variables con rangos más grandes (errores más grandes)

Por eso siempre se transforman las variables para que tengan escalas comparables.

Métodos más usados:

- min-max scaling
- standardization (z-score)

Escalado de variables

min-max scaling

min-max:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Se usa cuando quieres acotar los valores en un rango fijo.

Recomendado cuando:

- cuando el rango $[0,1]$ tiene sentido práctico
- redes neuronales (si la función de activación requiere ese rango tanh...)

contra: muy sensible a outliers.

Escalado de variables

z-score normalization

z-score:

$$x' = \frac{x - \mu}{\sigma}$$

Se usa por defecto en la mayoría de modelos.

Es mucho menos sensible a outliers

*si la variable tiene distribución gaussiana: el 68, 95 y 99 % de los datos tendrán $z < 1,2$ y 3 respectivamente

Variables: Cuantas más... ¿mejor?

Features: The more... the merrier?

No

No

Variables: Cuantas más... ¿mejor?

Features: The more... the merrier?

No - No todas las variables aportan información nueva o relevante

No - Not all the variables add new or relevant information

Aumentar la dimensionalidad hace el problema más complejo: hay más grados de libertad y más formas posibles de separar o ajustar los datos.

Higher dimensionality makes the problem more complex: there are more degrees of freedom and more ways to fit or separate the data.

Si parte de esas features aporta poco valor, añadimos ruido que el modelo puede aprender en train.

If some features add little useful information, we introduce noise that the model can fit on the training data.

Más dimensionalidad → mayor riesgo de overfitting.

Higher dimensionality → higher risk of overfitting.

Variables: Cuantas más... ¿mejor?

Features: The more... the merrier?

Más variables no significa necesariamente más información.

More features do not necessarily mean more information.

Dos fuentes frecuentes de complejidad innecesaria:

Two common sources of unnecessary complexity:

Variables poco informativas: poca o nula relación con y .

Weakly informative features: little or no relationship with y .

Variables redundantes: contienen información muy similar entre sí.

Redundant features: they carry largely overlapping information.

Siguientes pasos

Next steps

1. Analizar si las características de nuestro dataset son “buenas”
Check if all our features are “good”
2. Analizar si todas esas variables son necesarias
Check if all our features are necessary
3. (Opcional) Buscar combinaciones de las variables que puedan ser útiles
(Optional) Look for combinations of variables that help the model

Relación con la variable objetivo (y)


Relationship with the target variable (y)

¿Aportan información todas las variables?

En problemas supervisados, es importante analizar la relación entre cada variable y la variable objetivo.

En regresión -> Correlación de las variable con y

En clasificación -> Boxplot/histograma de cada variable por separado entre las clases (más métodos luego)



Relación entre variables (x)

Feature redundancy

Analizar la relación entre variables puede revelar patrones o dependencias relevantes para el modelo.

Calcular la correlación entre variables, la más usada, Pearson:

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

La correlación mide qué tan alineadas están las variaciones de dos variables: **los cambios de una variable tienden a ir acompañados por cambios en otra.**

Relación entre variables (x)

Feature redundancy

Analizar la relación entre variables puede revelar patrones o dependencias relevantes para el modelo.

Calcular la correlación entre variables, la más usada, Pearson:

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$


La correlación mide qué tan alineadas están las variaciones de dos variables: los cambios de una variable tienden a ir acompañados por cambios en otra.



¡Correlación no implica causalidad!



Correlación NO implica causalidad

Correlation DOES NOT imply causality



Correlación NO implica causalidad

Correlation DOES NOT imply causality



Relación entre variables (x) - Matriz de correlación

Feature redundancy - Correlation Matrix

Muestra la correlación de cada variable con cada una de las otras.

Muy útil para analizar de forma rápida la relación entre variables

Relación entre variables (x) - Matriz de correlación

Feature redundancy - Correlation Matrix

Muestra la correlación de cada variable con cada una de las otras.

Muy útil para analizar de forma rápida la relación entre variables

Variables con alta correlación, contienen información muy similar y son probablemente redundantes

symmetry_se	-0.10	0.01	-0.08	-0.07	0.20	0.23	0.18	0.10	0.45	0.35	0.24	0.41	0.27	0.13
fractal_dimension_se	-0.04	0.05	-0.01	-0.02	0.28	0.51	0.45	0.26	0.33	0.69	0.23	0.28	0.24	0.13
radius_worst	0.97	0.35	0.97	0.96	0.21	0.54	0.69	0.83	0.19	-0.25	0.72	-0.11	0.70	0.76
texture_worst	0.30	0.91	0.30	0.29	0.04	0.25	0.30	0.29	0.09	-0.05	0.19	0.41	0.20	0.20
perimeter_worst	0.97	0.36	0.97	0.96	0.24	0.59	0.73	0.86	0.22	-0.21	0.72	-0.10	0.72	0.76
area_worst	0.94	0.34	0.94	0.96	0.21	0.51	0.68	0.81	0.18	-0.23	0.75	-0.08	0.73	0.81
smoothness_worst	0.12	0.08	0.15	0.12	0.81	0.57	0.45	0.45	0.43	0.50	0.14	-0.07	0.13	0.13
compactness_worst	0.41	0.28	0.46	0.39	0.47	0.87	0.75	0.67	0.47	0.46	0.29	-0.09	0.34	0.28
concavity_worst	0.53	0.30	0.56	0.51	0.43	0.82	0.88	0.75	0.43	0.35	0.38	-0.07	0.42	0.39
concave points_worst	0.74	0.30	0.77	0.72	0.50	0.82	0.86	0.91	0.43	0.18	0.53	-0.12	0.55	0.54
symmetry_worst	0.16	0.11	0.19	0.14	0.39	0.51	0.41	0.38	0.70	0.33	0.09	-0.13	0.11	0.07
fractal_dimension_worst	0.01	0.12	0.05	0.00	0.50	0.69	0.51	0.37	0.44	0.77	0.05	-0.05	0.09	0.02
radius_mean														
texture_mean														
perimeter_mean														
area_mean														
smoothness_mean														
compactness_mean														
concavity_mean														
concave points_mean														
symmetry_mean														
fractal_dimension_mean														
radius_se														
texture_se														
perimeter_se														
area_se														

Relación entre variables (x) - Matriz de correlación

Feature redundancy - Correlation Matrix

Muestra la correlación de cada variable con cada una de las otras.

Muy útil para analizar de forma rápida la relación entre variables

Variables con alta correlación, contienen información muy similar y son probablemente redundantes

symmetry_se	-0.10	0.01	-0.08	-0.07	0.20	0.23	0.18	0.10	0.45	0.35	0.24	0.41	0.27	0.13
fractal_dimension_se	-0.04	0.05	-0.01	-0.02	0.28	0.51	0.45	0.26	0.33	0.69	0.23	0.28	0.24	0.13
radius_worst	0.97	0.35	0.97	0.96	0.21	0.54	0.69	0.83	0.19	-0.25	0.72	-0.11	0.70	0.76
texture_worst	0.30	0.91	0.30	0.29	0.04	0.25	0.30	0.29	0.09	-0.05	0.19	0.41	0.20	0.20
perimeter_worst	0.97	0.36	0.97	0.96	0.24	0.59	0.73	0.86	0.22	-0.21	0.72	-0.10	0.72	0.76
area_worst	0.94	0.34	0.94	0.96	0.21	0.51	0.68	0.81	0.18	-0.23	0.75	-0.08	0.73	0.81
smoothness_worst	-0.12	0.08	0.15	0.12	0.81	0.57	0.45	0.45	0.43	0.50	0.14	-0.07	0.13	0.13
compactness_worst	-0.41	0.28	0.46	0.39	0.47	0.87	0.75	0.67	0.47	0.46	0.29	-0.09	0.34	0.28
concavity_worst	-0.53	0.30	0.56	0.51	0.43	0.82	0.88	0.75	0.43	0.35	0.38	-0.07	0.42	0.39
concave points_worst	-0.74	0.30	0.77	0.72	0.50	0.82	0.86	0.91	0.43	0.18	0.53	-0.12	0.55	0.54
symmetry_worst	-0.16	0.11	0.19	0.14	0.39	0.51	0.41	0.38	0.70	0.33	0.09	-0.13	0.11	0.07
fractal_dimension_worst	-0.01	0.12	0.05	0.00	0.50	0.69	0.51	0.37	0.44	0.77	0.05	-0.05	0.09	0.02
radius_mean														
texture_mean														
perimeter_mean														
area_mean														
smoothness_mean														
compactness_mean														
concavity_mean														
concave points_mean														
symmetry_mean														
fractal_dimension_mean														
radius_se														
texture_se														
perimeter_se														
area_se														

Hasta aquí...

So far...

Hemos analizado / *we have analyzed:*

- La distribución de las variables / *Feature distributions*
- Outliers y valores anómalos o faltantes / *Outliers, missing and weird data values*
- Posibles inconsistencias en los datos / *Potential data inconsistencies*
- Relaciones entre variables / *Relationships between features*

Terminamos esta etapa ajustando la escala de las variables cuando es necesario.

We finish this stage by adjusting feature scales when needed.

Con toda esta información, la siguiente pregunta es: **¿Qué variables deberíamos usar en el modelo?**

*With all this information, the next question is: **Which features should we use in the model?***

Selección de características

Feature Selection

Carlos Bibián Noguerras, PhD

cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires

Introducción

Introduction

No siempre es necesario seleccionar características pero suele ayudar al modelo

Not always necessary, but it usually helps the model (we have seen why a few slides ago)

Tener un número elevado de variables (alta dimensionalidad), tiene efectos negativos sobre el modelo:

El modelo se vuelve más lento y menos fiable.

En general, más features implica más ruido y por tanto, más datos necesarios.

Y más riesgo de overfitting!

La maldición de la dimensionalidad

The dimensionality curse

A medida que aumenta el número de dimensiones, los datos se vuelven más dispersos.


As dimensionality increases, data become increasingly sparse.

Cada región del espacio contiene menos ejemplos. / *Each region of the feature space contains fewer observations.*

Más dimensiones requieren exponencialmente más datos para mantener una densidad comparable.

Higher dimensions require exponentially more data to maintain comparable density.

Las distancias pierden poder discriminativo. / *Distances become less informative.*



La maldición de la dimensionalidad

The dimensionality curse

A medida que aumenta el número de dimensiones, los datos se vuelven más dispersos.

As dimensionality increases, data become increasingly sparse.

Cada región del espacio contiene menos ejemplos. / *Each region of the feature space contains fewer observations.*

Más dimensiones requieren exponencialmente más datos para mantener una densidad comparable.

Higher dimensions require exponentially more data to maintain comparable density.

Las distancias pierden poder discriminativo. / *Distances become less informative.*

Los métodos basados en vecinos o similitud funcionan peor. / *Neighbor- and similarity-based methods become less effective.*

Consecuencia: aumenta el riesgo de overfitting. *Consequence: the risk of overfitting increases.*

El modelo tiene más oportunidades de ajustar ruido o patrones accidentales.

The model has more opportunities to fit noise or spurious patterns.

Dos estrategias para reducir la dimensionalidad

Two strategies for dimensionality reduction

1. Feature Selection

Elegir qué variables conservar / *Choose which original features to keep*

Conserva un subconjunto de las variables originales. / *Keeps a subset of the original features.*

Puede apoyarse en importancia de variables, asociación con y o criterios estadísticos.

Can rely on feature importance, association with y , or statistical criteria.

2. Feature Projection

Crear nuevas variables / *Create new lower-dimensional features*

Combina las variables originales en una representación más compacta. / *Combines the original features into a more compact representation.*

Busca reducir dimensionalidad preservando la mayor cantidad posible de información relevante.

Aims to reduce dimensionality while preserving as much relevant information as possible.

Selección características - Métodos

Feature Selection - Methods

Filtros → Aplican métricas o criterios estadísticos independientes del modelo para evaluar features.

- Correlación de Pearson, ANOVA F-test o χ^2 (variables categóricas).

Son rápidos, fáciles de aplicar, pero no consideran interacciones entre variables.

Wrappers → Evalúa subsets de variables con un modelo y elige el que maximiza la performance.

- Forward Selection (empezar sin features, añadir uno a uno) o Backward Elimination (empezar con todos, quitar de a uno).

Consideran interacciones entre variables, pero son muy costosos computacionalmente.

Embedded → Selección automática de variables dentro del entrenamiento del modelo.

- Random Forest (feature importance- RFI) o Lasso (L1 regularization)

Son un buen balance entre precisión y coste computacional.

Selección características - Métodos

Feature Selection - Methods

Filtros → Aplican métricas o criterios estadísticos independientes del modelo para evaluar features.

- Correlación de Pearson, ANOVA F-test o χ^2 (variables categóricas).

Son rápidos, fáciles de aplicar, pero no consideran interacciones entre variables.

Wrappers → Evalúa subsets de variables con un modelo y elige el que maximiza la performance.

- Forward Selection (empezar sin features, añadir uno a uno) o Backward Elimination (empezar con todos, quitar de a uno).

Consideran interacciones entre variables, pero son muy costosos computacionalmente.

Embedded → Selección automática de variables dentro del entrenamiento del modelo.

- Random Forest (feature importance- RFI) o Lasso (L1 regularization)

Son un buen balance entre precisión y coste computacional.

Filtros de características

Correlación de Pearson


Mide la **relación lineal entre dos variables** (para variables numéricas continuas)

Dos aplicaciones en selección de features:

- Calcular **correlación con variable objetivo (y)**, y si un feature está correlacionado con el target será más útil.

- Calcular correlación entre variables, y podemos eliminar una de ellas ya que

Tener en cuenta que únicamente capt



Filtros de características

Correlación de Pearson

Mide la **relación lineal entre dos variables** (para variables numéricas continuas)

Dos aplicaciones en selección de features:

- Calcular **correlación con variable objetivo (y)**, y si un feature está correlacionado con el target será más útil.
- Calcular **correlación entre variables**, y si dos features están muy correlacionadas entre sí podemos eliminar una de ellas ya que aportan información muy similar.

Tener en cuenta que ¡únicamente capta **relaciones lineales**!

symmetry_se -	-0.10	0.01	-0.08	-0.07	0.20	0.23	0.18	0.10	0.45	0.35	0.24	0.41	0.27	0.13
fractal_dimension_se -	-0.04	0.05	-0.01	-0.02	0.28	0.51	0.45	0.26	0.33	0.69	0.23	0.28	0.24	0.13
radius_worst -	-0.97	0.35	-0.97	-0.96	0.21	0.54	0.69	0.83	0.19	-0.25	0.72	-0.11	0.70	0.76
texture_worst -	-0.30	-0.91	0.30	0.29	0.04	0.25	0.30	0.29	0.09	-0.05	0.19	0.41	0.20	0.20
perimeter_worst -	-0.97	0.36	-0.97	-0.96	0.24	0.59	0.73	0.86	0.22	-0.21	0.72	-0.10	0.72	0.76
area_worst -	-0.94	0.34	-0.94	-0.96	0.21	0.51	0.68	0.81	0.18	-0.23	0.75	-0.08	0.73	0.81
smoothness_worst -	-0.12	0.08	0.15	0.12	0.81	0.57	0.45	0.45	0.43	0.50	0.14	-0.07	0.13	0.13
compactness_worst -	-0.41	0.28	0.46	0.39	0.47	0.87	0.75	0.67	0.47	0.46	0.29	-0.09	0.34	0.28
concavity_worst -	-0.53	0.30	0.56	0.51	0.43	0.82	0.88	0.75	0.43	0.35	0.38	-0.07	0.42	0.39
concave points_worst -	-0.74	0.30	0.77	0.72	0.50	0.82	0.86	0.91	0.43	0.18	0.53	-0.12	0.55	0.54
symmetry_worst -	-0.16	0.11	0.19	0.14	0.39	0.51	0.41	0.38	0.70	0.33	0.09	-0.13	0.11	0.07
fractal_dimension_worst -	-0.01	0.12	0.05	0.00	0.50	0.69	0.51	0.37	0.44	0.77	0.05	-0.05	0.09	0.02
radius_mean														
texture_mean														
perimeter_mean														
area_mean														
smoothness_mean														
compactness_mean														
concavity_mean														
concave points_mean														
symmetry_mean														
fractal_dimension_mean														
radius_se														
texture_se														
perimeter_se														
area_se														

Filtros de características

Información Mutua - Mutual Information (MI)

Mide cuánta información aporta un feature sobre la variable objetivo.

- MI: **cuánta incertidumbre sobre Y reducimos por conocer X**

$$I(X; Y) = \sum_{y \in \mathcal{Y}} \sum_{x \in \mathcal{X}} P_{(X,Y)}(x, y) \log \left(\frac{P_{(X,Y)}(x, y)}{P_X(x) P_Y(y)} \right)$$

Ventajas:

Detecta relaciones no lineales (a diferencia de Pearson).


Útil tanto en clasificación como en regresión.

Limitaciones:

Más costosa de calcular.



En Scikit-Learn:

`mutual_info_classif` (clasificación). `mutual_info_regression` (regresión).



Filtros de características

Ejemplo



symmetry_se	-0.10	0.01	-0.08	-0.07	0.20	0.23	0.18	0.10	0.45	0.35	0.24	0.41	0.27	0.13
fractal_dimension_se	-0.04	0.05	-0.01	-0.02	0.28	0.51	0.45	0.26	0.33	0.69	0.23	0.28	0.24	0.13
radius_worst	0.97	0.35	0.97	0.96	0.21	0.54	0.69	0.83	0.19	-0.25	0.72	-0.11	0.70	0.76
texture_worst	0.30	0.91	0.30	0.29	0.04	0.25	0.30	0.29	0.09	-0.05	0.19	0.41	0.20	0.20
perimeter_worst	0.97	0.36	0.97	0.96	0.24	0.59	0.73	0.86	0.22	-0.21	0.72	-0.10	0.72	0.76
area_worst	0.94	0.34	0.94	0.96	0.21	0.51	0.68	0.81	0.18	-0.23	0.75	-0.08	0.73	0.81
smoothness_worst	-0.12	0.08	0.15	0.12	0.81	0.57	0.45	0.45	0.43	0.50	0.14	-0.07	0.13	0.13
compactness_worst	-0.41	0.28	0.46	0.39	0.47	0.87	0.75	0.67	0.47	0.46	0.29	-0.09	0.34	0.28
concavity_worst	-0.53	0.30	0.56	0.51	0.43	0.82	0.88	0.75	0.43	0.35	0.38	-0.07	0.42	0.39
concave_points_worst	-0.74	0.30	0.77	0.72	0.50	0.82	0.86	0.91	0.43	0.18	0.53	-0.12	0.55	0.54
symmetry_worst	-0.16	0.11	0.19	0.14	0.39	0.51	0.41	0.38	0.70	0.33	0.09	-0.13	0.11	0.07
fractal_dimension_worst	-0.01	0.12	0.05	0.00	0.50	0.69	0.51	0.37	0.44	0.77	0.05	-0.05	0.09	0.02
dius_mean														
iture_mean														
perimeter_mean														
area_mean														
smoothness_mean														
compactness_mean														
concavity_mean														
concave_points_mean														
symmetry_mean														
fractal_dimension_mean														
radius_se														
texture_se														
perimeter_se														
area_se														

Filtros de características

ANOVA F-test

Compara la **varianza entre clases vs. la varianza dentro de cada clase**.


Si la **varianza entre clases** $\gg$ **varianza dentro de clases**, el feature es relevante.

Se usa en clasificación (features numéricos con target categórico).

Asume normalidad y varianzas similares.

1-Calcular el estadístico F para cada feature vs. target categórico.

2-Conservar los features con mayor F (o con p-value significativo).



Filtros de características

χ^2 (Chi-cuadrado)

Mide la **dependencia entre dos variables** (feature vs. target) **categorías**.

Si hay alta dependencia, el feature es informativo.

Uso: clasificación con variables categóricas.

Calcular p-value para cada feature vs. target.

Seleccionar los features con p-value menor a un umbral (ej. 0.05)

Selección características - Métodos

Feature Selection - Methods

Filtros → Aplican métricas o criterios estadísticos independientes del modelo para evaluar features.

- Correlación de Pearson, ANOVA F-test o χ^2 (variables categóricas).

Son rápidos, fáciles de aplicar, pero no consideran interacciones entre variables.

Wrappers → Evalúa subsets de variables con un modelo y elige el que maximiza la performance.

- Forward Selection (empezar sin features, añadir uno a uno) o Backward Elimination (empezar con todos, quitar de a uno).

Consideran interacciones entre variables, pero son muy costosos computacionalmente.

Embedded → Selección automática de variables dentro del entrenamiento del modelo.

- Random Forest (feature importance- RFI) o Lasso (L1 regularization)

Son un buen balance entre precisión y coste computacional.

Selección características - Métodos

Feature Selection - Methods

Filtros → Aplican métricas o criterios estadísticos independientes del modelo para evaluar features.

- Correlación de Pearson, ANOVA F-test o χ^2 (variables categóricas).

Son rápidos, fáciles de aplicar, pero no consideran interacciones entre variables.

Wrappers → Evalúa subsets de variables con un modelo y elige el que maximiza la performance.

- Forward Selection (empezar sin features, añadir uno a uno) o Backward Elimination (empezar con todos, quitar de a uno).

Consideran interacciones entre variables, pero son muy costosos computacionalmente.

Embedded → Selección automática de variables dentro del entrenamiento del modelo.

- Random Forest (feature importance- RFI) o Lasso (L1 regularization)

Son un buen balance entre precisión y coste computacional.

Wrappers

RFE (Recursive Feature Elimination)

Entrenar modelo sucesivamente eliminando cada vez la feature menos importante y evaluar el impacto en clasificación cada vez. **(se puede hacer también al revés añadiendo de una en una - Forward Selection)**

Pasos:

Entrenar un modelo inicial (ej. regresión lineal o SVM).

Medir importancia de cada feature*

Eliminar el menos importante.

Repetir hasta llegar al número deseado de variables o hasta que la performance baje.

Visualización sugerida: ranking de variables → eliminación progresiva.

*Cómo medir la importancia de cada feature?-> impacto en performance de añadirla, o valor del coeficiente de esa feature en modelos lineales, o reducción de impureza que aporta esa feature (DT o RF)...

Scikit-Learn: *RFE* o *RFECV* (con validación cruzada para elegir el número óptimo de features).

Selección características - Métodos

Feature Selection - Methods

Filtros → Aplican métricas o criterios estadísticos independientes del modelo para evaluar features.

- Correlación de Pearson, ANOVA F-test o χ^2 (variables categóricas).

Son rápidos, fáciles de aplicar, pero no consideran interacciones entre variables.

Wrappers → Evalúa subsets de variables con un modelo y elige el que maximiza la performance.

- Forward Selection (empezar sin features, añadir uno a uno) o Backward Elimination (empezar con todos, quitar de a uno).

Consideran interacciones entre variables, pero son muy costosos computacionalmente.

Embedded → Selección automática de variables dentro del entrenamiento del modelo.

- Random Forest (feature importance- RFI) o Lasso (L1 regularization)

Son un buen balance entre precisión y coste computacional.

Selección características - Métodos

Feature Selection - Methods

Filtros → Aplican métricas o criterios estadísticos independientes del modelo para evaluar features.

- Correlación de Pearson, ANOVA F-test o χ^2 (variables categóricas).

Son rápidos, fáciles de aplicar, pero no consideran interacciones entre variables.

Wrappers → Evalúa subsets de variables con un modelo y elige el que maximiza la performance.

- Forward Selection (empezar sin features, añadir uno a uno) o Backward Elimination (empezar con todos, quitar de a uno).

Consideran interacciones entre variables, pero son muy costosos computacionalmente.



Embedded → Selección automática de variables dentro del entrenamiento del modelo.

- Random Forest (feature importance- RFI), L1 Lasso (regularización)

Son un buen balance entre precisión y coste computacional.


Selección de características

Wrappers vs Filtros




Selección de características

Wrappers vs Filtros





Efecto de reducir variables según RF Importance (Breast Cancer)



Selección de características

Wrappers vs Filtros



... ¿y si todas las variables son relevantes?

Feature Selection: Nos quedamos con las variables originales más útiles.

- De 20 tests médicos, elegir los 5 más predictivos.

Pero... ¿Qué pasa si todas las variables aportan algo?

Por ejemplo, en una imagen, cada píxel tiene información, no podemos descartar alegremente.

En vez de elegir, tenemos que transformar y combinar las variables para generar un espacio más compacto (menor dimensionalidad), perdiendo poca información.

Esto es **Feature Projection (Dimensionality Reduction)**. - **Módulo 4**

Selección de características

Comparación - Resumen

Método	Cómo funciona	Ventajas	Desventajas	Ejemplos
Filtro	Evalúa cada feature de forma independiente del modelo (tests estadísticos, correlación).	Muy rápido, simple, escalable a alta dimensión.	No captura interacciones entre features.	Chi ² , Correlación de Pearson, ANOVA F-test.
Wrapper	Evalúa subsets de features entrenando un modelo repetidamente.	Considera interacciones, suele mejorar performance.	Muy costoso computacionalmente, no garantiza subset óptimo.	Forward selection, Backward elimination, RFE.
Embedded	El modelo decide durante el entrenamiento qué features conservar.	Buen equilibrio entre precisión y coste, selección más “natural”.	Depende del modelo elegido, puede sesgar.	Random Forest importance, Lasso (L1), Elastic Net.

Selección de características

Comparación - Resumen

Método	Cómo funciona	Ventajas	Desventajas	Ejemplos
Filtro	Evalúa cada feature de forma independiente del modelo (tests estadísticos, correlación).	Muy rápido, simple, escalable a alta dimensión.	No captura interacciones entre features.	Chi ² , Correlación de Pearson, ANOVA F-test.
Wrapper	Evalúa subsets de features entrenando un modelo repetidamente.	Considera interacciones, suele mejorar performance.	Muy costoso computacionalmente, no garantiza subset óptimo.	Forward selection, Backward elimination, RFE.
Embedded	El modelo decide durante el entrenamiento qué features conservar.	Buen equilibrio entre precisión y coste, selección más “natural”.	Depende del modelo elegido, puede sesgar.	Random Forest importance, Lasso (L1), Elastic Net.

Regularización


Carlos Bibián Nogueras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires


Regularización

Complejidad del modelo


Los modelos complejos pueden ajustarse demasiado a los datos de entrenamiento.



underfitting / alto sesgo
high bias



buen ajuste




overfitting / alta varianza
high variance

Regularización

Complejidad del modelo

Los modelos complejos tienden a ajustar demasiado bien los datos “vistos” y a generalizar mal a datos nuevos



overfitting / alta varianza
high variance


Objetivo: controlar la
complejidad del modelo
para que generalice
mejor

x

Regularización

Complejidad del modelo


Los modelos complejos tienden a ajustar demasiado bien los datos “vistos” y a generalizar mal a datos nuevos



$$w_1x + w_2x^2 + w_3x^3 + w_4x^4 \dots + b$$

overfitting / alta varianza
high variance

Objetivo: controlar la complejidad del modelo para que generalice mejor



$$w_1x + w_2x^2 + b$$

buen ajuste

Regularización

Idea principal

La regularización busca controlar la complejidad del modelo.

La idea es penalizar modelos demasiado complejos durante el entrenamiento.

En modelos lineales:

$$y = w_1x_1 + w_2x_2 + \dots + w_nx_n$$

La complejidad del modelo está relacionada con el tamaño de los coeficientes w .

Coefficientes muy grandes pueden indicar un modelo demasiado sensible a los datos.

Métricas de evaluación

Carlos Bibián Noguerras, PhD
cbibian@itba.edu.ar |

Instituto Tecnológico de Buenos Aires

Métricas para regresión

Error de predicción y RMS

El error de predicción mide la diferencia entre el valor predicho por el modelo y el valor real observado.

$$e_i = y_i - \hat{y}_i$$

El Root Mean Squared Error mide el promedio de los errores al cuadrado entre las predicciones y los valores reales.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Métricas para regresión

Coeficiente de determinación (R^2)

El coeficiente R^2 mide qué proporción de la variabilidad de la variable objetivo es explicada por el modelo.

Interpretación:

Valores de R^2 cercanos a 1 indican un buen ajuste del modelo, mientras que valores cercanos a 0 indican un modelo poco informativo.

Regularización

Idea principal

La regularización busca controlar la complejidad del modelo.

¿Como?

Modificando la función de coste para **penalizar coeficientes altos**:

$$J(w) = \text{Error}(w) + \lambda \cdot \text{Penalización}(w)$$

Error(w) mide el ajuste a los datos

λ controla la intensidad de la regularización

Esto obliga al modelo a equilibrar ajuste y simplicidad.

Regularización

L1 (Lasso)

La penalización es la suma de los valores absolutos de los coeficientes

$$J(w) = \text{Error}(w) + \lambda \sum_{j=1}^p |w_j|$$

La penalización L1 favorece soluciones donde $w = 0$ para algunas variables. (modelos más sparse)

Si $w=0$, la variable no se usa. Por eso Lasso es también considerado un método de selección de variables

λ , parámetro de regularización -> cuanto mayor, más se fuerza al modelo a tener coeficientes pequeños. Valor que tenemos que elegir nosotros durante el entrenamiento/Validación

Regularización

L2 (Ridge)

La penalización es la suma del cuadrado de los coeficientes

$$J(w) = \text{Error}(w) + \lambda \sum_{j=1}^p w_j^2$$

Los coeficientes grandes reciben una penalización mayor.

L2 empuja los coeficientes hacia valores pequeños, pero raramente los hace exactamente cero.

Todas las variables siguen participando en el modelo.

Regularización

Elastic Net

Combina ambos (L1 y L2) mediante alpha

$$J(\mathbf{w}) = \text{Error}(\mathbf{w}) + \lambda \left[\alpha \sum_j |w_j| + (1 - \alpha) \sum_j w_j^2 \right]$$

Lambda es la “fuerza” de la regularización y alpha el balance entre L1 y L2

L1 empuja algunos coeficientes exactamente a 0; L2 mantiene muchos coeficientes pequeños y estabiliza el modelo. Elastic Net intenta obtener las dos ventajas.

Regularización

Ejemplo

¿Cómo elegirían el valor de λ ?

How would you choose the value of λ ?

Regularización

Ejemplo

Dataset: Diabetes dataset (kaggle)

Separamos el 20% para test

Entrenamos modelos sobre 80% de los datos - 5-fold cross-validation

Utilizamos el RMSE como métrica


Modelos a probar:

- regresión lineal
- regresión polinómica (grado 2) + L1, $\lambda=0.001$
- regresión polinómica (grado 2) + L1, 0.01,
- regresión polinómica (grado 2) + L1, $\lambda=0.1$
- regresión polinómica (grado 2) + L1, $\lambda=1$

Regularización

Ejemplo

¿Cuál elegimos?



Regularización

Ejemplo


¿Cuál elegimos?

El modelo con menor error en Dev/Validation

-> la regresión lineal

Validation RMSE (Linear): 53.853

¿Cuál esperaría que tuviese más diferencia entre train y dev error?




Regularización

Ejemplo

El modelo con menor error en Dev/Validation es la regresión lineal

Al comparar train y dev, vemos que , como esperábamos, hay **más overfitting para lambdas bajas**

Esa diferencia es lo que se llama **generalization gap**



Ejemplo final

Final Example

Un equipo prueba 200 configuraciones distintas sobre el mismo validation set.

A team tests 200 different configurations on the same validation set.

Elige la mejor:

Train: 96%, Validation: 91% Test: 84%

¿Que ha podido pasar?

Ejemplo final

Final Example

Un equipo prueba 200 configuraciones distintas sobre el mismo validation set.

A team tests 200 different configurations on the same validation set.

Elige la mejor:

Train: 96%, Validation: 91% Test: 84%

¿Que ha podido pasar?

Al elegir el mejor resultado entre muchas estimaciones ruidosas, tendemos a seleccionar también una configuración que tuvo ruido favorable.

When we select the best result among many noisy estimates, we also tend to select a configuration that benefited from favorable noise.

El modelo aprende del train. Nosotros aprendemos del validation.

The model learns from the train set. We learn from the validation set.

Cómo reducimos overfitting a la validación (Avanzado)

How to reduce overfitting the validation set (Advanced)

Cross-validation

Reduce la dependencia de un único validation split. / *Reduces dependence on a single validation split.*

Limitar búsquedas ad hoc

Cuanto más decisiones tomamos mirando validation, mayor riesgo de adaptarnos a él.

The more decisions we make based on validation, the greater the risk of adapting to it.

Mantener otro test set intacto - holdout / shallow test set

Se usa sólo al final para estimar la generalización del pipeline elegido. Puede ser usado unas pocas veces

Keep the test set untouched until the end to estimate the generalization of the selected pipeline. Can be used a few times


Nested cross-validation

Para selección intensiva de modelos o datasets pequeños: CV interna para elegir y CV externa para evaluar.

For intensive model selection or small datasets: inner CV for selection, outer CV for evaluation.

Proyecto de ML

Pipeline clásico de un proyecto



Proyecto de ML

Pipeline clásico de un proyecto

