

72.75: Aprendizaje Automático (Machine Learning)

Horario: Miércoles 16-19h- virtual sincrónico

Profesorado de la asignatura:

Francisco Sammartino, Ing. | frperez@itba.edu.ar

Carlos Bibián Noguera, PhD | cbibian@itba.edu.ar

Plan de la sesión de hoy

- Regresión Logística
- Métricas de Evaluación
- Métricas de Evaluación con clases desbalanceadas
- Curva ROC
- Multiclase

... en la sesión anterior

- Problema-Datos-Features
- EDA
- Feature selection
- Regularización
- Métricas

Repaso Clase 3


- Problema — Datos — Features: definir el objetivo y entender los datos disponibles
- EDA: explorar distribuciones, outliers y relaciones entre variables
- Feature Selection y Regularización: elegir variables y controlar la complejidad del modelo
- Métricas: cómo medimos si un modelo generaliza bien

- Estadísticas descriptivas, histogramas y boxplots para ver distribuciones y detectar outliers

- Correlación (Pearson) y matriz de correlación para ver relaciones entre variables

- Escalado de variables (min-max o z-score) antes de comparar o entrenar modelos

$$x' = \frac{x - \mu}{\sigma}$$



Repaso Clase 3


Feature Selection

Feature Selection: ¿cuáles variables conservar? / *Feature Selection: which features to keep?*

- Más variables no es necesariamente mejor: maldición de la dimensionalidad y riesgo de overfitting
 - Filtros: métricas estadísticas independientes del modelo (Pearson, Mutual Information, ANOVA, χ^2)
 - Wrappers (Recursive Feature Elimination) y Embedded (Lasso, Random Forest importance): usan el modelo para elegir variables
-

Ejemplo

symmetry_se	-0.10	0.01	-0.08	-0.07	0.20	0.23	0.18	0.10	0.45	0.35	0.24	0.41	0.27	0.13
fractal_dimension_se	-0.04	0.05	-0.01	-0.02	0.28	0.51	0.45	0.26	0.33	0.69	0.23	0.28	0.24	0.13
radius_worst	0.97	0.35	0.97	0.96	0.21	0.54	0.69	0.83	0.19	-0.25	0.72	-0.11	0.70	0.76
texture_worst	-0.30	0.91	0.30	0.29	0.04	0.25	0.30	0.29	0.09	-0.05	0.19	0.41	0.20	0.20
perimeter_worst	0.97	0.36	0.97	0.96	0.24	0.59	0.73	0.86	0.22	-0.21	0.72	-0.10	0.72	0.76
area_worst	0.94	0.34	0.94	0.96	0.21	0.51	0.68	0.81	0.18	-0.23	0.75	-0.08	0.73	0.81
smoothness_worst	-0.12	0.08	0.15	0.12	0.81	0.57	0.45	0.45	0.43	0.50	0.14	-0.07	0.13	0.13
compactness_worst	-0.41	0.28	0.46	0.39	0.47	0.87	0.75	0.67	0.47	0.46	0.29	-0.09	0.34	0.28
concavity_worst	-0.53	0.30	0.56	0.51	0.43	0.82	0.88	0.75	0.43	0.35	0.38	-0.07	0.42	0.39
concave points_worst	-0.74	0.30	0.77	0.72	0.50	0.82	0.86	0.91	0.43	0.18	0.53	-0.12	0.55	0.54
symmetry_worst	-0.16	0.11	0.19	0.14	0.39	0.51	0.41	0.38	0.70	0.33	0.09	-0.13	0.11	0.07
fractal_dimension_worst	-0.01	0.12	0.05	0.00	0.50	0.69	0.51	0.37	0.44	0.77	0.05	-0.05	0.09	0.02
	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	symmetry_mean	fractal_dimension_mean	radius_se	texture_se	perimeter_se	area_se



Repaso Clase 3

Regularización

Regularización: controlar la complejidad del modelo / *Regularization: controlling model complexity*

- Penaliza coeficientes grandes para evitar el overfitting
 - L1 (Lasso): puede llevar coeficientes a cero — también selecciona variables
 - L2 (Ridge) y Elastic Net: reducen los coeficientes sin anularlos, combinando ambos enfoques
-

Repaso Clase 3

Métricas

Métricas: ¿cómo sabemos si el modelo generaliza?

- RMSE: promedio del error de predicción al cuadrado

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- R²: proporción de la variabilidad explicada por el modelo
-

Regresión Logística




Instituto Tecnológico de Buenos Aires

Regresión Logística

Motivación

Resolver problemas de clasificación binaria basado en datos anteriores, por ejemplo:

- Emails: no es spam / es spam
- Tumor: benigno / maligno
- Producción de semiconductores: unidad defectuosa / unidad OK




Regresión Logística

Motivación

Resolver problemas de clasificación binaria basado en datos anteriores, por ejemplo:

- Emails: no es spam / es spam
- Tumor: benigno / maligno
- Producción de semiconductores: unidad defectuosa / unidad OK



Regresión Logística

Motivación


Ya vimos la variable a predecir Y , ahora ¿cuáles podrían ser los features X para cada uno de estos ejemplos?

- Emails: no es spam / es spam → frecuencia de palabras: address / free / order
- Tumor: benigno / maligno → radio / textura / perímetro / área / suavidad
- Semiconductor: funciona / es defectuoso → información de sensores

Regresión Logística


Ejemplo

Tomemos como ejemplo un set de entrenamiento para clasificar un tumor como benigno/maligno.




Regresión Logística

Regresión Lineal




Regresión Logística

Regresión Lineal




Regresión Logística

Regresión Lineal




Regresión Logística

Regresión Lineal



Regresión Logística

Regresión Lineal



Características:

- Predice valores continuos
- Resuelve problemas de regresión

Problemas:


- Predice valores fuera del rango de 0 y 1, no tiene sentido interpretarlos como probabilidad

Intuición: debemos “aplastarlo” para que los resultados caigan entre 0 y 1.

Regresión Logística

Función Sigmoidea


Para resolver este problema la regresión logística utiliza la función sigmoidea:



Regresión Logística

Función Sigmoidea

Para resolver este problema la regresión logística utiliza la función sigmoidea:




$$P(Y = 1) = \frac{1}{1 + e^{-(\mathbf{w}x+b)}}$$

- Asíntotas en 0 y 1
- Transforma cualquier número real en una probabilidad
- Se utiliza para problemas de clasificación (NO REGRESIÓN)

Regresión Logística

Función Sigmoidea

Para resolver este problema la regresión logística utiliza la función sigmoidea:



$$P(Y = 1) = \frac{1}{1 + e^{-(\mathbf{w}x+b)}}$$


- Asíntotas en 0 y 1
- Transforma cualquier número real en una probabilidad
- Se utiliza para problemas de clasificación (NO REGRESIÓN)

Usamos el conjunto de entrenamiento para definir las variables w y b más adecuadas para nuestros datos.

Regresión Logística

Ejemplo

Entrené mi modelo, tengo la regresión logística.



Llega un paciente con un tumor de 4cm.

Salida del modelo: 0.7


Interpretación: el paciente tiene 70% de probabilidad de tener un tumor maligno.

¿Cómo paso de la probabilidad a la predicción?

Regresión Logística

Ejemplo

Entrené mi modelo, tengo la regresión logística.



Llega un paciente con un tumor de 4cm.

Salida del modelo: 0.7

Interpretación: el paciente tiene 70% de probabilidad de tener un tumor maligno.

¿Cómo paso de la probabilidad a la predicción?

- CON UN UMBRAL

Regresión Logística

Evaluación

Ya entrenamos un modelo de regresión logística: dado el tamaño de un tumor, predice la probabilidad de que sea maligno.

¿Cómo sabemos si este modelo es bueno?

Métricas de Evaluación

-
- Accuracy (Porcentaje de aciertos)
 - Matriz de confusión
 - Elección del umbral y curva ROC
 - Otras métricas (precisión, recall, F1)
-

Métricas de evaluación

Accuracy (porcentaje de aciertos)

De todas las predicciones que hizo el modelo, ¿qué porcentaje acertó?

Accuracy = predicciones correctas / total de predicciones

Métricas de evaluación

Accuracy (porcentaje de aciertos)

De todas las predicciones que hizo el modelo, ¿qué porcentaje acertó?

$$\text{Accuracy} = \text{predicciones correctas} / \text{total de predicciones}$$

Ejemplo: probamos nuestro modelo con 10 pacientes nuevos, y acertó el diagnóstico (maligno/benigno) en 8 de ellos.

$$\text{Accuracy} = 8/10 = 80\%$$


Pero el accuracy no distingue qué tipo de error cometió el modelo. ¿Los dos pacientes mal diagnosticados eran falsos positivos o negativos?

Métricas de evaluación

Limitaciones del Accuracy

3 modelos, 3 resultados distintos, 10 mismos pacientes, misma accuracy.


Escenario A



Accuracy = 80%

2 falsos negativos


Escenario B



Accuracy = 80%

2 falsos positivos

Escenario C



Accuracy = 80%

1 falso negativo + 1 falso positivo

● Acierto



● Falso negativo

● Falso positivo

Métricas de evaluación

Matriz de Confusión

Método de visualización para los resultados de un algoritmo clasificador.



Métricas de evaluación

Matriz de Confusión

		Ground truth	
		+	-
Predicted	+	True positive (TP)	False positive (FP)
	-	False negative (FN)	True negative (TN)

TP (verdadero positivo): tumor maligno, el modelo dijo maligno.

TN (verdadero negativo): tumor benigno, el modelo dijo benigno.

FP (falso positivo): tumor benigno, el modelo dijo maligno.

FN (falso negativo): tumor maligno, el modelo dijo benigno - el error más grave acá.

Métricas de evaluación

Precisión y Recall

		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = TP / (TP + FP)
	-	False negative (FN)	True negative (TN)	
		Recall = TP / (TP + FN)		Accuracy = (TP + TN) / (TP + FP + TN + FN)

Métricas de evaluación

Precisión y Recall

		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = TP / (TP + FP)
	-	False negative (FN)	True negative (TN)	
		Recall = TP / (TP + FN)		Accuracy = (TP + TN) / (TP + FP + TN + FN)

Precisión: qué tan exactas son las predicciones positivas

Recall: capacidad del modelo de encontrar todos los casos positivos presentes.

Métricas de evaluación

Specificity y negative predicted value

		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = $TP / (TP + FP)$
	-	False negative (FN)	True negative (TN)	?
		Recall = $TP / (TP + FN)$	?	Accuracy = $(TP + TN) / (TP + FP + TN + FN)$

Métricas de evaluación

Specificity y negative predicted value

		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = $TP / (TP + FP)$
	-	False negative (FN)	True negative (TN)	$TN / (TN + FN)$
		Recall = $TP / (TP + FN)$		Accuracy = $(TP + TN) / (TP + FP + TN + FN)$

Métricas de evaluación

Specificity y negative predicted value

		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = $TP / (TP + FP)$
	-	False negative (FN)	True negative (TN)	$TN / (TN + FN)$
		Recall = $TP / (TP + FN)$		Accuracy = $(TP + TN) / (TP + FP + TN + FN)$

Qué tan exactas son las predicciones negativas.

Métricas de evaluación

Specificity y negative predicted value

		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = $TP / (TP + FP)$
	-	False negative (FN)	True negative (TN)	
		Recall = $TP / (TP + FN)$	$TN / (TN + FP)$	Accuracy = $(TP + TN) / (TP + FP + TN + FN)$

Métricas de evaluación

Specificity y negative predicted value

		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = $TP / (TP + FP)$
	-	False negative (FN)	True negative (TN)	
		Recall = $TP / (TP + FN)$	$TN / (TN + FP)$	Accuracy = $(TP + TN) / (TP + FP + TN + FN)$

Specificity: Capacidad del modelo de encontrar los negativos.

Métricas de evaluación

Precisión y Recall (Sensitivity)


		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = TP / (TP + FP)
	-	False negative (FN)	True negative (TN)	
		Recall = TP / (TP + FN)		Accuracy = (TP + TN) / (TP + FP + TN + FN)

En el caso de la predicción de tumores benignos/malignos. Preferimos tener un recall alto o precisión alta?

Métricas de evaluación

El trade-off del Umbral


Recordemos: la regresión logística devuelve una probabilidad. Nosotros elegimos el umbral para convertirla en 0 o 1.



Métricas de evaluación

El trade-off del Umbral

Recordemos: la regresión logística devuelve una probabilidad. Nosotros elegimos el umbral para convertirla en 0 o 1.




Si bajamos el umbral: el modelo marca maligno más seguido $\uparrow$ **Recall**, $\downarrow$ **Precision** más falsas alarmas pero no se escapa ningún maligno.

Métricas de evaluación

El trade-off del Umbral

Recordemos: la regresión logística devuelve una probabilidad. Nosotros elegimos el umbral para convertirla en 0 o 1.



Si subimos el umbral: el modelo marca benigno más seguido $\uparrow$ **Precision**, $\downarrow$ **Recall**. No hay falsas alarmas pero se escapan algunos tumores malignos.

Métricas de evaluación

El Trade-Off del Umbral

¿Qué conviene? Depende del costo de cada error:

- Diagnóstico de cáncer:

Métricas de evaluación

El Trade-Off del Umbral

¿Qué conviene? Depende del costo de cada error:

- Diagnóstico de cáncer: preferimos **umbral bajo** (recall alto) — es peor dejar pasar un maligno que revisar de más un caso benigno.

Métricas de evaluación

El Trade-Off del Umbral

¿Qué conviene? Depende del costo de cada error:

- Diagnóstico de cáncer: preferimos **umbral bajo** (recall alto) — es peor dejar pasar un maligno que revisar de más un caso benigno.
- Filtro de spam: preferimos **umbral alto** (precision alta) — es peor perder un mail importante que dejar pasar algún spam.

Métricas de evaluación

El Trade-Off del Umbral

¿Qué conviene? Depende del costo de cada error:

- Diagnóstico de cáncer: preferimos **umbral bajo** (recall alto) — es peor dejar pasar un maligno que revisar de más un caso benigno.
- Filtro de spam: preferimos **umbral alto** (precision alta) — es peor perder un mail importante que dejar pasar algún spam.

No existe un umbral “correcto” universal: depende del problema.

¿Cómo visualizamos este trade-off? → curva ROC.

Métricas de evaluación

Curva ROC

En vez de fijar UN umbral y calcular UN (Precision, Recall), la curva ROC recorre *todos* los umbrales posibles.

Para cada umbral, calculamos dos cosas:

-**TPR (True Positive Rate) = Recall:** de los malignos reales, ¿a cuántos detectó?

$$TPR = TP / (TP + FN)$$

-**FPR (False Positive Rate):** de los benignos reales, ¿a cuántos etiquetó mal como malignos?

$$FPR = FP / (FP + TN)$$


Graficando cada (FPR, TPR) a medida que bajamos el umbral de 1 a 0, obtenemos la curva ROC.

Métricas de evaluación

Curva ROC


$$TPR = TP / (TP + FN)$$

$$FPR = FP / (FP + TN)$$




$$TP = 0$$

$$FP = 0$$



Métricas de evaluación

Curva ROC



$$TP = 35$$


$$FP = 5$$

$$FN = 6$$

$$TN = 37$$


$$TPR = TP / (TP + FN) = 0,85$$

$$FPR = FP / (FP + TN) = 0,11$$



Métricas de evaluación

Curva ROC



$$TP = 45$$


$$FP = 45$$

$$FN = 0$$

$$TN = 0$$


$$TPR = TP / (TP + FN) = 1$$

$$FPR = FP / (FP + TN) = 1$$



Métricas de evaluación

Curva ROC




$TP = 45$

$FP = 45$


$FN = 0$

$TN = 0$



Métricas de evaluación

Curva ROC





¿Cómo es un clasificador ideal?

Métricas de evaluación



AUC

Manera equivalente de ver el desempeño del clasificador para diferentes umbrales.



$AUC = 1 \rightarrow$ Clasificador ideal

$AUC = 0.5 \rightarrow$ Clasificador aleatorio



Métricas de evaluación

Elección del mejor umbral

No hay un umbral "correcto" único: depende de si priorizás positivos, negativos o ambos.

Un criterio práctico: elegir el umbral cuyo punto (FPR, TPR) esté más cerca de (0, 1), el punto ideal en la curva ROC.

Procedimiento:

1. Definir un rango de umbrales según el clasificador
2. Para cada umbral: clasificar los datos, calcular FPR y TPR, y guardar la distancia al punto (0,1)
3. Elegir el umbral con distancia mínima

MUCHAS GRACIAS!

Referencias

[1] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 3rd ed. Sebastopol, CA, USA: O'Reilly Media, 2022.

[2] Codificando Bits, “Clasificación: la curva ROC y el AUC,” *Codificando Bits*, 2021. [Online]. Available: <https://codificandobits.com/tutorial/clasificacion-curva-roc-auc/>. [Accessed: Sep. 1, 2026].

[3] [YouTube], “Video sobre regresión logística y clasificación,” YouTube. [Online]. Available: <https://www.youtube.com/watch?v=4u81xU7BIOc>. [Accessed: Sep. 1, 2026].

Regresión Logística

El modelo logístico no es más que una regresión lineal común... pero aplicada sobre una escala logarítmica.

Utiliza odds:

$$odds = \frac{p}{(1 - p)}$$

Ejemplo: $odds = 0.8 / 1 - 0.8 = 0.8/0.2 = 4$

Intuición: es 4 veces más probable que compre a que no compre

Dominio: $p \in (0,1)$

Rango: $(0, +\infty)$

Odds tiene rango de 0 a infinito, para estirar el rango a todos los reales se utiliza el logaritmo.

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x$$

El modelo es lineal, solo que no en p si no en logit de p .

Dominio: $(0, +\infty)$

Rango: $(-\infty, +\infty)$

Regresión Logística

Despejamos p

$$\ln \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 x$$

Llamamos $z = \beta_0 + \beta_1 x$.

Paso 1: aplicar la exponencial de ambos lados

$$\frac{p}{1-p} = e^z$$

Paso 2: multiplicar ambos lados por (1 - p)

$$p = e^z(1-p)$$

Paso 3: distribuir el lado derecho

$$p = e^z - e^z p$$

Paso 4: agrupar los términos con p

$$p + e^z p = e^z$$

Paso 5: sacar p como factor común

$$p(1 + e^z) = e^z$$

Paso 6: despejar p

$$p = \frac{e^z}{1 + e^z}$$

Paso 7: forma equivalente dividiendo numerador y denominador por e^z

$$p = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

Función sigmoidea