

72.75: Aprendizaje Automático (Machine Learning)

Horario: Miércoles 16-19h- virtual sincrónico

Profesorado de la asignatura:

Carlos Bibián Nogueras, PhD | cbibian@itba.edu.ar

Alexa Sessarego Aurich

Francisco Sammartino, Ing. | frperez@itba.edu.ar

... en la sesión anterior

Plan de la sesión de hoy


- Repaso de probabilidades y modelos generativos
- Inferencia Bayesiana (MAP vs. ML)
- LDA (protagonista), QDA y GDA
- Naive Bayes

- Regresión Logística

Modelos Generativos

Francisco Pérez Sammartino,
frperez@itba.edu.ar

Instituto Tecnológico de Buenos Aires
Centro de Inteligencia Computacional



Modelos Discriminativos vs. Generativos

¿Cómo aprendemos a clasificar?

Modelos Discriminativos (ej. Regresión Logística):

- Intentan aprender el **límite de decisión** (frontera).
- Matemáticamente: Modelan directamente “dado un elemento x , cual es la probabilidad que pertenezca a la clase y ” $P(y|x)$ Ej. $P(\text{“gato”}/x) = 0.35$

Modelos Generativos (ej. GDA, Naive Bayes):

- Intentan aprender cómo se **distribuye cada clase** por separado.
- Si aprendo cómo se distribuyen, puedo intentar generar algún dato nuevo.
- Matemáticamente: Modelan $P(x|y)$ (la verosimilitud) y $P(y)$ (el prior).

Un poco de probabilidades



Repaso

- Espacio muestral: conjunto de todos los resultados posibles de un experimento.
- Sucesos/eventos: Cualquier subconjunto del espacio muestral.

Frecuencia Relativa:

Supongamos que repetimos n veces un mismo experimento aleatorio en forma independiente y bajo las mismas condiciones. Sea n_A el número de veces que ocurre el suceso A , entonces la frecuencia relativa de A está dada por:


$$f_A = \frac{n_A}{n}$$

Repaso

Frecuencia Relativa

0.53 = 106/200


0.47 = 94/200



Probabilidad

0.50

0.50



Probabilidad conjunta

¿Cuál es la probabilidad de que salgan dos caras?

Esto se denomina probabilidad conjunta , ya que consiste en unir dos eventos.

Por lo tanto, la probabilidad de que salgan dos caras es:

$$P(H \cap H) = 0.25$$

Las probabilidades conjuntas son conmutativas:

$$P(A \cap B) = P(B \cap A)$$



Un poco de probabilidades


Propiedades:

- Los eventos A y B son independientes si:

$$P(A \cap B) = P(A) * P(B)$$

- Si A y B son independientes, entonces A y Bc también lo son.
- Si los sucesos A y B son **mutuamente excluyentes** entonces $A \cap B = \emptyset$ y A y B no son independientes.


Probabilidad condicional



La probabilidad condicional es cuando determinamos la probabilidad de que ocurra una determinada condición o evento dado que otro evento ya ha ocurrido

¿Cuál es la probabilidad de elegir los 3 diamantes de un mazo dado que hemos elegido una carta roja?

Probabilidad condicional



Probabilidad condicional

¿Cuál es la probabilidad de elegir los 3 diamantes de una baraja de manos **dado que** hemos elegido una carta roja?

$$\left. \begin{array}{l} P(3D) = \frac{1}{52} \\ P(R) = \frac{26}{52} = \frac{1}{2} \end{array} \right\} P(3D | R) = \frac{\frac{1}{52}}{\frac{1}{2}} = \frac{1}{26}$$

Formalizando:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$




Teorema de probabilidad total

Sea S el espacio de muestreo, $B_i, i=1, \dots, n$ una partición de S y A otro evento en S

$$P(A) = \sum_{i=1}^n P(A \cap B_i) :$$

$$P(A) = \sum_{i=1}^n P(B_i)P(A | B_i)$$

Prob Condicional



Thomas Bayes

Matemático Inglés, nació en Londres, Inglaterra en 1702 y murió en Tunbridge Wells, Kent, Inglaterra el 17 de Abril de 1761.


Sea S el espacio de muestreo y A y B dos eventos en S

$$P(A | B) = \frac{P(A)P(B | A)}{P(B)}$$




Teorema de Bayes en el aprendizaje automático


- El Razonamiento Bayesiano provee un enfoque probabilístico para realizar inferencias.
- Algoritmos basados en Razonamiento Bayesiano compiten con otros métodos, incluyendo Árboles de decisión y Redes Neuronales y incluso a veces llegando a mejores resultados en algunas aplicaciones (Michie et al.)



Clasificadores Bayesianos



Definiciones



Teorema de Bayes en el aprendizaje de Conceptos

Buscamos la mejor Hipótesis

Un camino es buscar la hipótesis más probable, dentro de un conjunto de hipótesis H y tomando un conjunto de entrenamiento D .

El teorema de Bayes nos da una forma de calcular la probabilidades

Entonces si las hipótesis posibles son $h_1, \dots, h_n$ buscamos la más probable.

Maximum a Posteriori (MAP)

Probabilidad a Posteriori

$$P(h|D) = \frac{P(D|h) \cdot P(h)}{P(D)}$$

MAP

Significa maximizar la probabilidad a posteriori de las hipótesis, dado el conjunto de entrenamiento.

$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h|D) \\ &= \arg \max_{h \in H} \frac{P(D|h)P(h)}{P(D)} \quad \leftarrow \text{constante} \\ &= \arg \max_{h \in H} P(D|h)P(h) \end{aligned}$$

Máxima verosimilitud

Si todas las hipótesis en el conjunto de entrenamiento H son equiprobables, es decir $P(h_i) = P(h_j) \forall i, j$ entonces

$$\arg \max_{h \in H} P(D | h) \underbrace{P(h)}_{\text{constante}} = \arg \max_{h \in H} P(D | h)$$

ML: Maximum Likelihood

$$h_{\text{ML}} = \arg \max_{h \in H} P(D | h)$$

Cuando las hipótesis son equiprobables, entonces $h_{\text{MAP}} = h_{\text{ML}}$.

Concept Check: El poder del Prior

Situación

Tenés un detector de metales en la playa que suena. Suponemos que ambos objetos hacen sonar el detector:

$$P(\text{Sonido} \mid \text{Lata}) \approx P(\text{Sonido} \mid \text{Tesoro}) \approx 1$$

Pregunta

¿Por qué, a pesar del sonido, es mucho más probable haber encontrado una lata que un tesoro pirata?



$$P(h \mid D) = \frac{P(D \mid h) \cdot P(h)}{P(D)}$$

Cómo estimamos $P(D/h)$?



Campana de Gauss

Para atributos continuos, modelamos $P(x | y)$ como la densidad de cada clase asumiendo distribución normal.

Usamos una campana de Gauss en varias dimensiones.

Para definir la campana de la clase k hay que estimar dos cosas:


Media μ

Dónde está centrado el grupo.
El punto de máxima densidad.

Covarianza Σ


Forma, estiramiento y orientación
de la nube de puntos.

$$f(x) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)\right)$$





LDA

Análisis de Discriminante Lineal



LDA - Requisitos

- Misma matriz de Covarianza/Dispersión.
- Distribución normal por clase



Deducción discriminante

1 Bayes en logaritmos

$$\text{Score}(k) = \ln P(x | C_k) + \ln P(C_k)$$

El log evita la exponencial de la Gaussiana y no cambia el argmax.

$$P(h|D) = \frac{P(D|h) \cdot P(h)}{P(D)}$$

2 Reemplazamos $P(x | C_k)$ por la Gaussiana multivariada

$$\text{Score}(k) = -(d/2) \ln(2\pi) - (1/2) \ln|\Sigma| - (1/2)(x - \mu_k)^T \Sigma^{-1} (x - \mu_k) + \ln P(C_k)$$

3 Expandimos $(x - \mu_k)^T \Sigma^{-1} (x - \mu_k)$

$$\text{Score}(k) = -(1/2) x^T \Sigma^{-1} x + x^T \Sigma^{-1} \mu_k - (1/2) \mu_k^T \Sigma^{-1} \mu_k + \ln P(C_k) + \text{cte}$$

Aparece un término cuadrático en x, uno lineal y uno constante (no depende de x).

Se cancela el término cuadrático

4

Cancelación mágica: $\text{Score}(1) - \text{Score}(0) > 0$

El término $-(1/2) \mathbf{x}^T \Sigma^{-1} \mathbf{x}$ es idéntico en ambas clases: Σ es compartida.

Al restar, se cancela. Desaparece $\mathbf{x}^2$. Si cada clase tuviera su Σ (QDA), no se cancela.

Quedan solo términos lineales en $\mathbf{x}$ y constantes.

Resultado: función discriminante lineal $\delta_i(\mathbf{x})$

$$\delta_i(\mathbf{x}) = \mathbf{x}^T (\Sigma^{-1} \boldsymbol{\mu}_i) - (1/2) \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i + \ln P(C_i)$$

$$\delta_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + b_i$$

Ecuación de primer grado: un hiperplano (en 2D, una recta).

La normal de esa recta es $\mathbf{w} \propto \Sigma^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$. Criterio de Fisher.

La magia de LDA: la mejor separación lineal

1. Cancelación del cuadrado


Al igualar $P(C_1|x) = P(C_0|x)$, el término $x^T \Sigma^{-1} x$ es idéntico en ambos lados. Σ es compartida, así que se cancelan. Queda una ecuación lineal.

2. Dirección de separación óptima (criterio de Fisher)

$$w = \Sigma^{-1} (\mu_1 - \mu_2)$$


LDA maximiza la distancia entre centros relativa a cuán apretada está cada clase.

Reducción de dimensionalidad




LDA vs PCA

- Maximizar separación entre clases vs maximizar varianza



Ejercicio

- Generar un conjunto de datos de puntos en $[0,1] \times [0,1]$ que tengan 3 clases.
- Dividir el conjunto en 70% entrenamiento, 30% test.
- Visualizar el cuadrantes con los puntos y las clases representadas con colores.
- Mostrar la transformación con LDA (para una dimensión), sobre el mismo gráfico
- Realizar la predicción del 30% de test usando el algoritmo LDA para clasificar. Mostrar los resultados.



QDA: qué pasa si el supuesto falla (GDA)

El problema de LDA

Si una clase es un círculo chico y la otra un óvalo enorme, forzar una sola Σ da una mala frontera (mucho sesgo).

La solución de QDA

Cada clase tiene su propia matriz de covarianza Σ_i .

Los términos $x^T \Sigma_i^{-1} x$ ya no se cancelan. La frontera se vuelve cuadrática (curva).

Trade-off

QDA es más flexible, pero estima muchos más parámetros.

La familia de métodos se llama Gaussian Discriminant Analysis (GDA)

Concept Check: ¿LDA o QDA en la práctica?

Dataset de imágenes médicas

200 pacientes y 500 características por paciente.

Sospechamos que las clases tienen dispersiones un poco distintas.

¿Elegimos LDA o QDA?



De GDA a Naive Bayes

GDA / QDA (Quadratic Discriminant Analysis):

- Cada clase tiene su propia media y su propia matriz de covarianza.
- **Resultado:** Fronteras de decisión cuadráticas (curvas). Mucha flexibilidad, muchos parámetros.

LDA (Linear Discriminant Analysis):


- Cada clase tiene su media pero **todas comparten la misma matriz de covarianza**.
- **Resultado:** Las curvas se vuelven rectas. Fronteras de decisión lineales.

Gaussian Naive Bayes:

- Asumimos que los atributos son independientes entre sí dada la clase.
- Esto equivale a decir que matriz de covarianza es una **Matriz Diagonal** (ceros fuera de la diagonal).
- **Resultado:** Solo nos importa la varianza de cada variable por separado. Muy pocos parámetros, ideal para cuando hay pocos datos o muchas dimensiones.

La gran familia generativa

Modelo	Matriz de covarianza (Σ)	Frontera
LDA (principal)	Idéntica para todas las clases	Lineal (separación óptima)
QDA (alternativa)	Distinta para cada clase	Cuadrática (curvas)
Gaussian Naive Bayes	Diagonal (sin correlación)	Lineal / cuadrática simple



Naive Bayes

Atributos categóricos



Independencia Condicional

Sean X , Y y Z tres variables aleatorias a valores discretos, decimos que X es independiente condicional de Y dado Z , si

$$P(X | Y, Z) = P(X | Z)$$

La probabilidad de X , dados Y y Z es la probabilidad de X dado Z .

$$P(X, Y | Z) = P(X | Z) \times P(Y | Z)$$

Concept Check: ¿es realmente independiente?

Clasificamos propiedades inmobiliarias

Dos atributos: tamaño_en_m² y numero_de_habitaciones.


¿Se cumple la independencia condicional de Naive Bayes?



Clasificador Bayesiano naive

La clase con mayor probabilidad posterior:

$$v_{opt} = \arg \max_{v_j \in V} (P(v_j | a_1, \dots, a_n))$$



$$= \arg \max_{v_j \in V} \frac{P(a_1, \dots, a_n | v_j) P(v_j)}{P(a_1, \dots, a_n)}$$

← Usando Bayes

$$= \arg \max_{v_j \in V} P(a_1, \dots, a_n | v_j) P(v_j)$$

← constante

Clasificador Bayesiano naive

El clasificador Bayesiano naive asume que los valores de los atributos son independientes, dado el valor de la clase, por eso lleva esa denominación de ingenuo.

Los valores de los atributos son independientes dada la clase, es decir:

$$P(a_1, \dots, a_n | v_j) = \prod_i P(a_i | v_j)$$

$$V_{opt} = \arg \max_{v_j \in V} P(a_1, \dots, a_n | v_j) P(v_j) \quad \longrightarrow \quad v_{NB} = \arg \max_{v_j \in V} \prod_{i=1}^n P(a_i | v_j) * P(v_j)$$

Los valores $P(a_i | v_j)$ se estiman con la frecuencia de los datos observados.

Ejemplo

Este es un ejemplo de cómo aplicar el clasificador naive Bayes para el concepto "Pepe juega al tenis los sábados por la mañana":

- La variable objetivo es binaria: "Pepe juega al tenis" (sí/no).
- Cada instancia (un sábado) se describe mediante 4 atributos:
 - Pronóstico (soleado, nublado, lluvioso)
 - Temperatura (calurosa, templada, fría)
 - Humedad (alta, normal)
 - Viento (fuerte, débil)

Ejemplo

Se tiene una tabla de 14 ejemplos de entrenamiento, con días descritos por esos 4 atributos y el valor de la clase "si/no juega tenis".

Los atributos:

- pronóstico
- temperatura
- humedad
- viento

Día	Pronóstico	Temperatura	Humedad	Viento	¿Juega?
D1	soleado	cálido	alta	débil	no
D2	soleado	cálido	alta	fuerte	no
D3	nublado	cálido	alta	débil	si
D4	lluvioso	templado	alta	débil	si
D5	lluvioso	frío	normal	débil	si
D6	lluvioso	frío	normal	fuerte	no
D7	nublado	frío	normal	fuerte	si
D8	soleado	templado	alta	débil	no
D9	soleado	frío	normal	débil	si
D10	lluvioso	templado	normal	débil	si
D11	soleado	templado	normal	fuerte	si
D12	nublado	templado	alta	fuerte	si
D13	nublado	cálido	normal	débil	si
D14	lluvioso	templado	alta	fuerte	no

Ejemplo

Clasificar una nueva instancia como la siguiente aplicando naive Bayes:

<pronóstico = soleado, temperatura = fría, humedad = alta, viento = fuerte>

Vamos a usar:

$$v_{NB} = \arg \max_{v_j \in V} \prod_{i=1}^n P(a_i | v_j) * P(v_j)$$

$$V_{NB} = \arg \max_{\text{si, no}} \left\{ \begin{array}{l} P(\text{si}) * P(\text{soleado}|\text{si}) * P(\text{frío}|\text{si}) * P(\text{alta}|\text{si}) * P(\text{fuerte}|\text{si}), \\ P(\text{no}) * P(\text{soleado}|\text{no}) * P(\text{frío}|\text{no}) * P(\text{alta}|\text{no}) * P(\text{fuerte}|\text{no}) \end{array} \right\}$$

Resolverlo

¿Probabilidades Nulas?


El clasificador naive Bayes puede tener problemas si existen probabilidades nulas o ceros en las estimaciones a partir de los datos de entrenamiento.

Por ejemplo:

Imaginemos que humedad puede ser “Baja”. No hay ejemplo para Humedad Baja en el conjunto.:

$$P(\text{Humedad=Baja} | \text{“Juega”}) = 0$$

¿Cómo lo solucionamos?



Corrección de Laplace

Se basa en la asignación de una probabilidad no nula para que una posible probabilidad nula en la productoria no anule la probabilidad final.


Calculando p la frecuencia relativa

$$p = \frac{\text{cantidad de ocurrencias}}{\text{total}}$$

La probabilidad corregida por el método de Laplace es;

$$\hat{p} = \frac{\text{cantidad de ocurrencias} + 1}{\text{total} + k}$$

siendo k el número de clases posibles.



Corrección de Laplace

Se basa en asumir que la variable aleatoria siempre tomará alguno de los valores posibles.

Entonces **¿cuál es la probabilidad que la variable tome un determinado valor?**, observamos la muestra y estimamos la probabilidad usando la frecuencia relativa.

$$p = \frac{n_i}{N}$$

Cálculo $\hat{p}$:

La probabilidad corregida por el método de Laplace es $\hat{p} = \frac{n_i + 1}{N + k}$

k: la cantidad de valores diferentes que la variable puede tomar.

n_i : cantidad de veces que la variable toma el valor i en la muestra.

N: es la cantidad de veces que la variable toma alg'un valor y

Algoritmo para el Clasificador de Bayes

Queremos clasificar según el conjunto V cuyas opciones son $\{v_j, j = 1, \dots, k\}$, dado un conjunto de entrenamiento D con atributos $\{a_i, i = 1, \dots, n\}$

- ❶ Para cada posible valor de la clase v_j :
 - ❶ Obtener la estimación $\hat{P}(v_j)$.
 - ❷ Para cada valor del atributo a_i , obtener una estimación de $\hat{P}(a_i|v_j)$.
- ❷ Dar como datos de salida:

$$v_{NB} = \arg \max_{j \in \{1, \dots, k\}} \prod_{i=1}^n \hat{P}(a_i|v_j) * \hat{P}(v_j)$$



Los valores de $\hat{P}(a_i|v_j)$ y $\hat{P}(v_j)$ se estiman con la frecuencia de los datos observados o conjunto de entrenamiento.

La probabilidad más alta nos dará v_{NB} , el valor de la clasificación

Naive Bayes: ¿este correo es spam?

Dataset sintético: 4 correos por clase. Priors: $P(\text{spam}) = P(\text{no spam}) = \frac{1}{2}$.

Ejemplos del dataset (se muestran 2 de 4 correos por clase)

Spam: «oferta urgente» · «oferta oferta»

No spam: «reunión reunión» · «oferta reunión»

Conteos de palabras

Palabra	Spam	No spam
oferta	4	1
urgente	3	1
reunión	1	6
Total	8	8

Laplace ($\alpha = 1$), vocabulario de 3 palabras:

$$P(\text{palabra} \mid \text{clase}) = (\text{conteo} + 1) / (8 + 3)$$

Correo: «oferta urgente»

Score de spam


$$\frac{1}{2} \times (4 + 1)/11 \times (3 + 1)/11 \\ = 10/121 \approx 0,0826$$

Score de no spam


$$\frac{1}{2} \times (1 + 1)/11 \times (1 + 1)/11 \\ = 2/121 \approx 0,0165$$

Predicción: spam

$$P(\text{spam} \mid \text{correo}) = 10 / (10 + 2) = 83,3 \%$$



¡Fin! ¿Alguna pregunta?



$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

$$= \arg \max_{v_j \in V} P(a_1, \dots, a_n | v_j) P(v_j)$$

Problema Ejemplo

Consideremos el siguiente vector de atributos binarios para representar preferencias de una persona:

(scones, cerveza, whiskey, avena, fútbol)

Por ejemplo, el vector: $x = (1, 0, 1, 1, 0)$ significa que esta persona

- Le gustan los scones (1)
- No toma cerveza (0)
- Le gusta el whiskey (1)
- Le gusta la avena (1)
- No ve fútbol (0)



Problema Ejemplo

Conjunto de Entrenamiento o datos observados

En las columnas de las siguientes tablas se dan los vectores de preferencias de 6 personas inglesas y 7 personas escocesas.

	0	1	1	1	0	0
	0	0	1	1	1	0
Ingleses:	1	1	0	0	0	0
	1	1	0	0	0	1
	1	0	1	0	1	0

	1	1	1	1	1	1
	0	1	1	1	1	0
Escoceses:	0	0	1	0	0	1
	1	0	1	1	1	1
	1	1	0	0	1	0

Dado el ejemplo $\mathbf{x} = (1, 0, 1, 1, 0)$ determinar si corresponde a las preferencias de una persona inglesa o escocesa..



Datos

scones	cerveza	whiskey	avena	futbol	Nacionalidad
0	0	1	1	1	I
1	0	1	1	0	I
1	1	0	0	1	I
1	1	0	0	0	I
0	1	0	0	1	I
1	1	1	1	0	E
1	0	0	1	1	E
1	1	0	0	1	E

Columnas: **Atributos o variables**

Filas: **Registros**