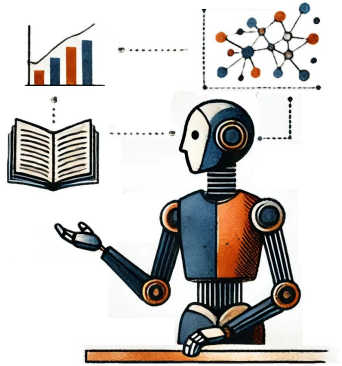
72.75: Aprendizaje Automático (Machine Learning)

Aprendizaje No Supervisado

Horario: Miércoles 18-21h- virtual sincrónico

Profesorado de la asignatura:
Carlos Bibián Nogueras, PhD | cbibian@itba.edu.ar
Francisco Sammartino, Ing. | frperez@itba.edu.ar



en sesión anterior…

- Model vs Data-centric Design
- Aprendizaje avanzado y MLops
-

Plan de la sesión de hoy

- Introducción a aprendizaje no supervisado
- K-means (k medias)
- DBSCAN
- Reducción de Dimensionalidad (PCA y t-SNE)

Aprendizaje No Supervisado

Francisco Pérez Sammartino,
frperez@itba.edu.ar

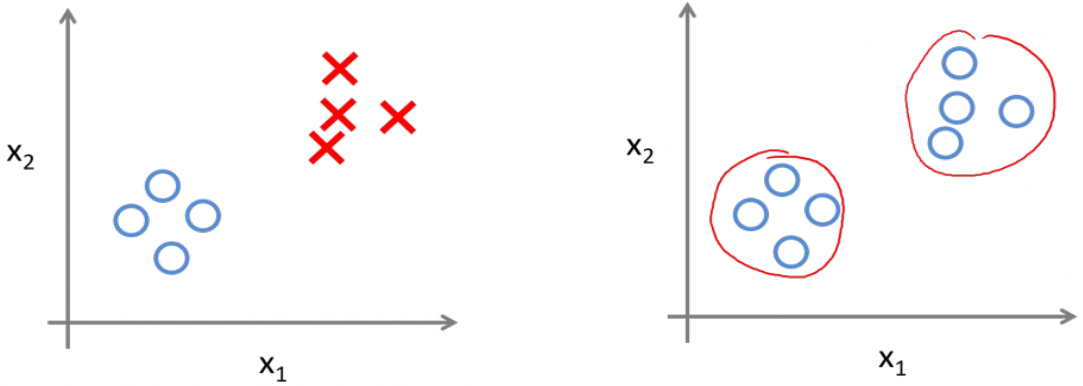
Instituto Tecnológico de Buenos Aires
Centro de Inteligencia Computacional



Aprendizaje Supervisado vs. No Supervisado

Supervisado: Modelos de predicción basados en la variable Respuesta conocida.

No supervisado: Modelos de predicción cuando la variable Respuesta es desconocida, se basa en relaciones entre variables observadas sin datos anotados.



Métodos No Supervisados - Aplicaciones

- **Segmentación de usuarios**
  - ej.: usuarios en compras online para campañas de marketing.
- **Sistemas de recomendación**
  - ej.:Plataformas de streaming.
- **Detección de anomalías**



Métodos No Supervisados

Algunos usos comunes de aprendizaje no supervisado son:

se agrupan
por similitudes

↓

AGRUPAMIENTO

↓

dividen pacientes por
síndromes



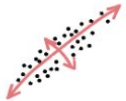
se identifican
dependencias ocultas

↓

REDUCCIÓN DE DIMENSIONES

↓

aprovecha las característi-
cas para crear mejores
modelos



Reglas del tipo

si/entonces

Asociación

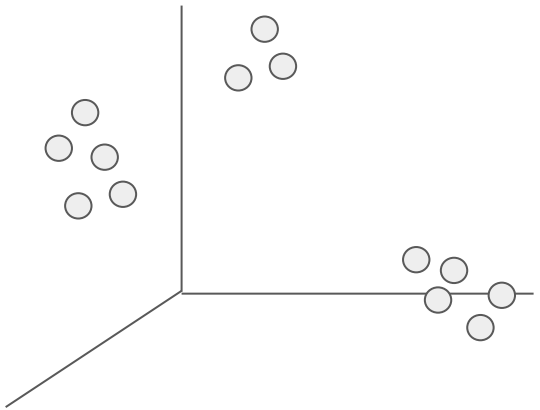
Algoritmo Apriori

Clustering o Agrupamiento

Se agrupan las observaciones de acuerdo a algún criterio con el objetivo de **encontrar subgrupos (clusters)** en los datos.

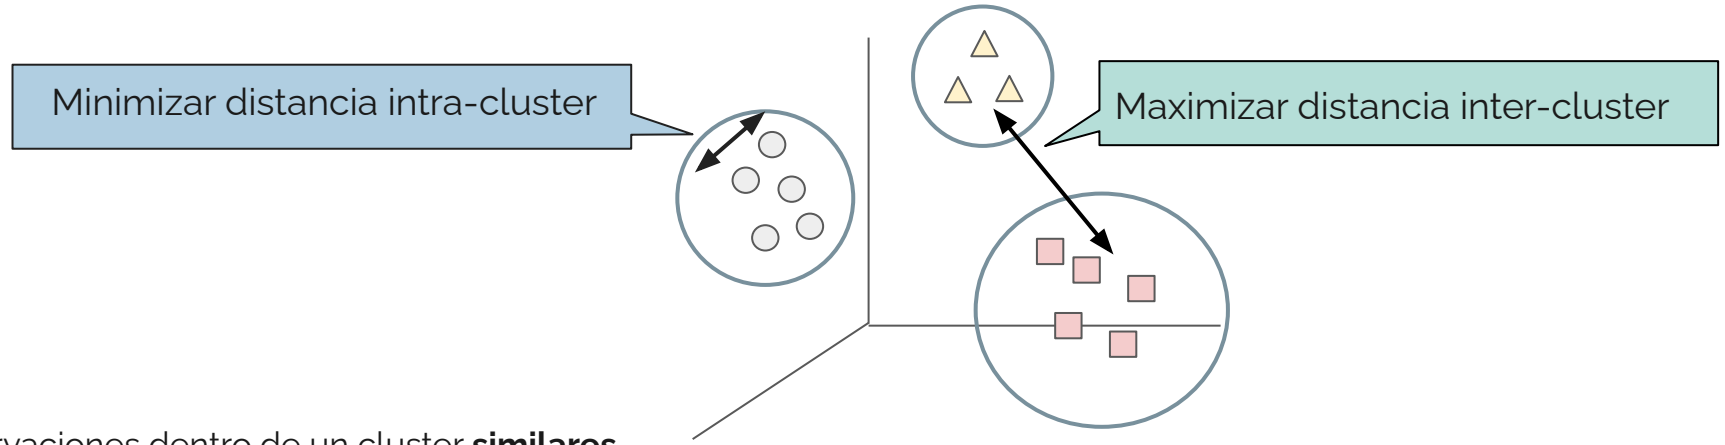
¿Que hacen?

Agrupan objetos en clusters de forma tal que el grado de asociación o similitud entre miembros del mismo cluster sea lo más fuerte posible



Clustering o Agrupamiento

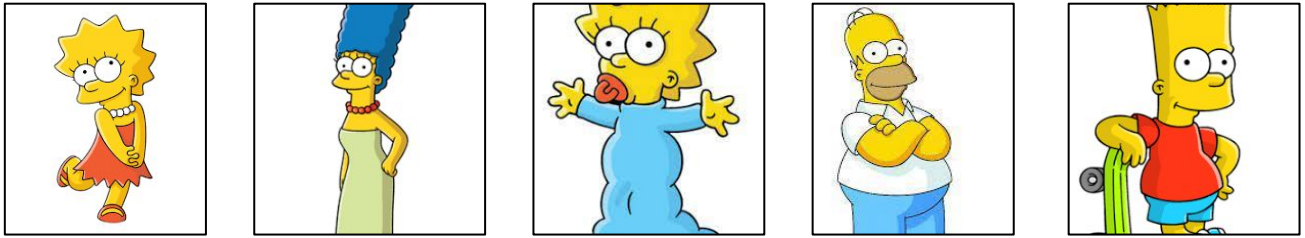
Se agrupan las observaciones de acuerdo a algún criterio con el objetivo de **encontrar subgrupos (clusters)** en los datos.



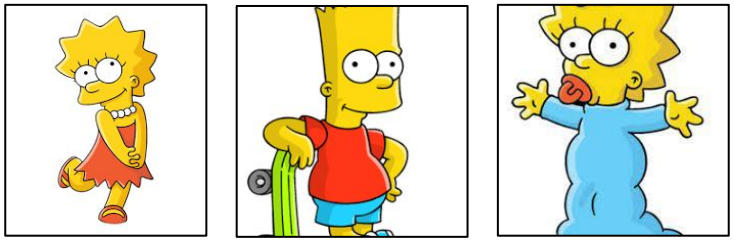
Observaciones dentro de un cluster **similares**

Observaciones entre clusters **no similares**

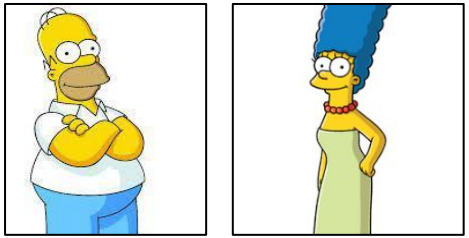
Clustering - Agrupación los datos



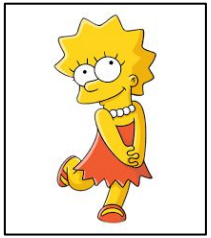
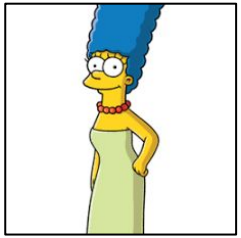
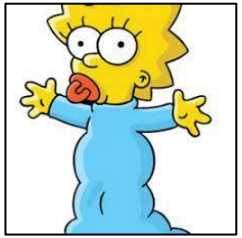
Niños

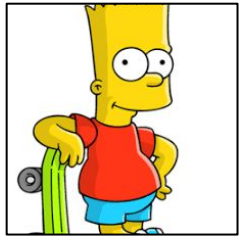


Adultos

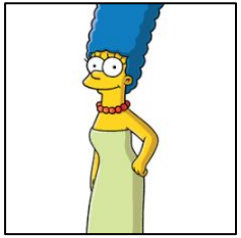


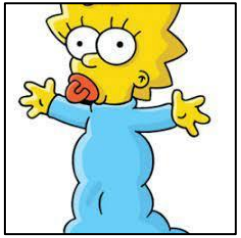
Clustering - Agrupación los datos

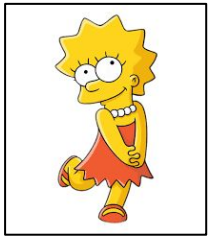
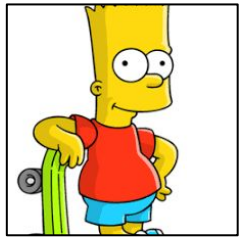


No van a la primaria

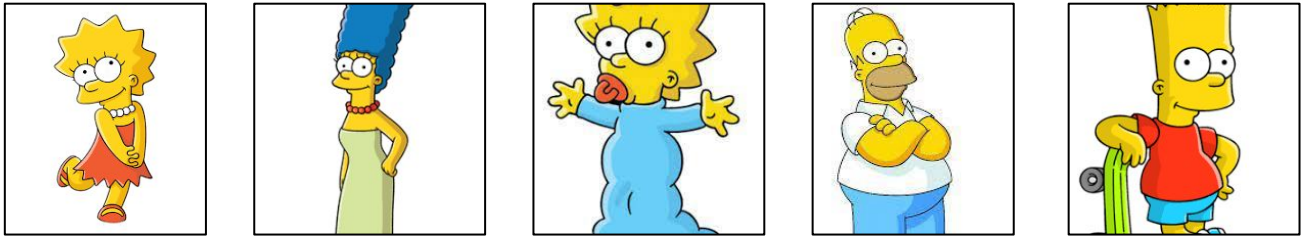




Van a la primaria

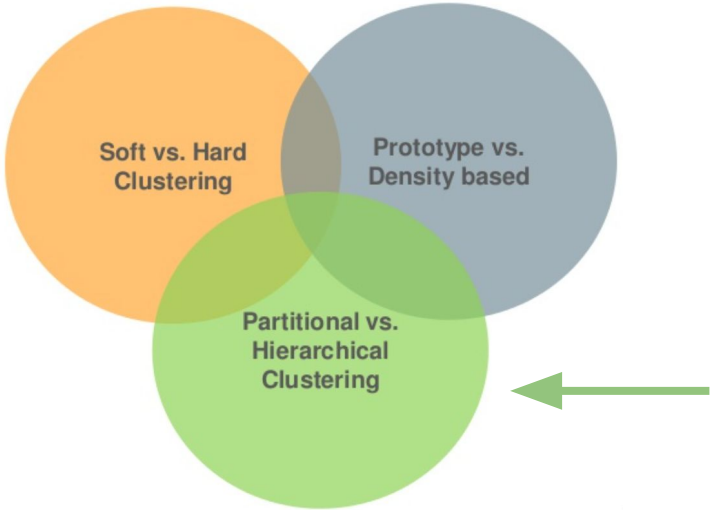
Clustering - Agrupación los datos



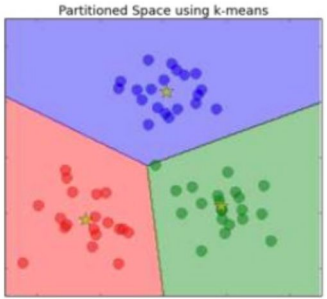
No hay una única forma de agrupar los datos, la mejor elección de grupos depende de cuál sea nuestro objetivo.

Clustering - Métodos

Hay muchos métodos de clusterización y distintos criterios de división.



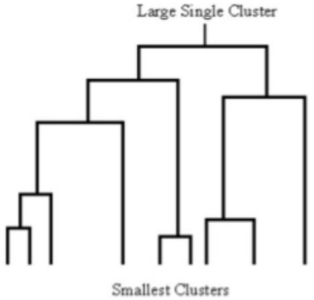
Partición



-particiona el espacio

-encuentra todos los clusters simultáneamente

Jerárquico



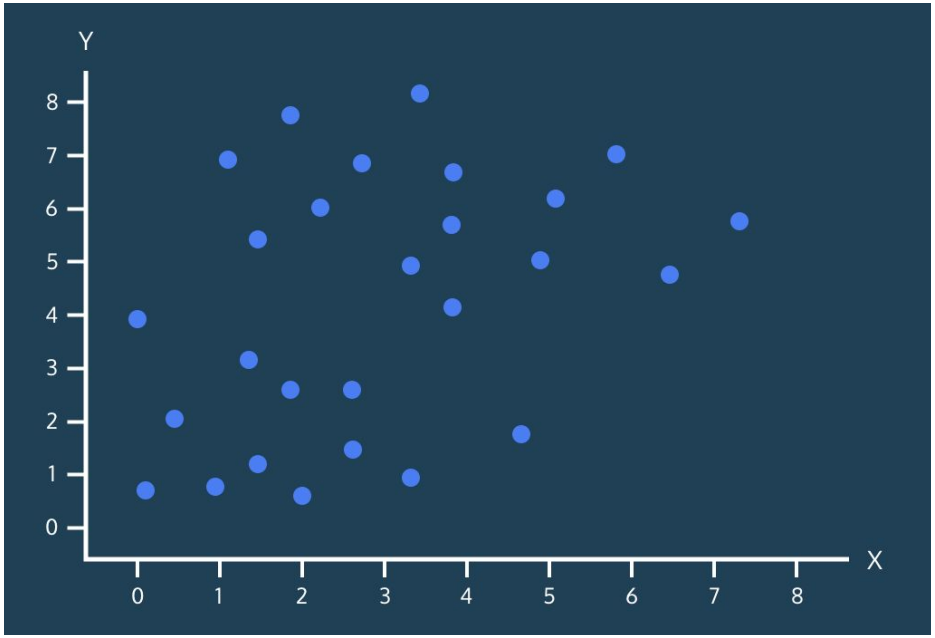
-genera una jerarquía de clusters anidados

Cluster basados en prototipos

Un cluster es un conjunto de objetos en el cual cada objeto está más cerca (o es más similar) al **prototipo** que define al cluster que al prototipo que define cualquier otro cluster.

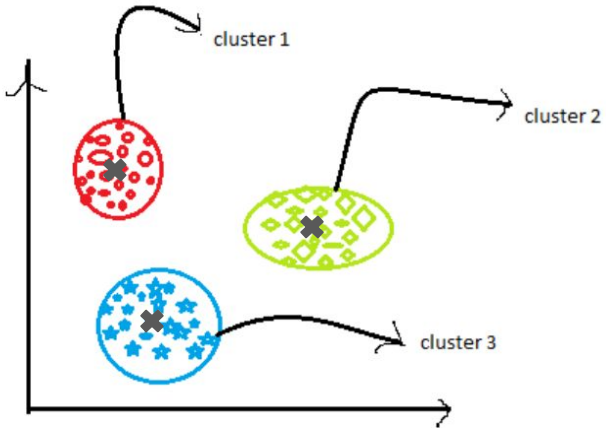
- **Atributos continuos:** el prototipo de un cluster puede ser el centroide.
- **Atributos categóricos:** el prototipo es el objeto más representativo del cluster.

K-means



¿Qué es la agrupación de k-medias?

Tiene como objetivo **generar una partición** de un conjunto de n observaciones en k grupos. Cada grupo está representado por el promedio de los puntos que lo componen, denominado **centroide.**



El valor de **k** representa el **número de clusters** o grupos en los que se dividirán los datos, es un parámetro que se debe fijar a priori.

Algoritmo K-medias

Dado un conjunto de observaciones $\{x_1, x_2, \ldots x_n\}$, donde $x_i \in R^p$.

El algoritmo K-medias construye una **partición de las observaciones en K conjuntos** (K≤n) que **minimiza la distancia de los elementos dentro de cada grupo**: $S = \{S_1, S_2, \ldots, S_k\}$

$$\arg\min_{\mathbf{S}} \sum_{i=1}^{k} \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

donde μ_i es la media o centroide de puntos en S_i

Algoritmo K-medias

Agrupa el conjunto de datos en K conjuntos no solapados:

- Definir K
- n observaciones
- p variables
- $\{C_1, C_2, \ldots, C_k\}$ son los conjuntos donde están los índices de las observaciones tal que
    - Cada observación pertenece a uno de los K conjuntos

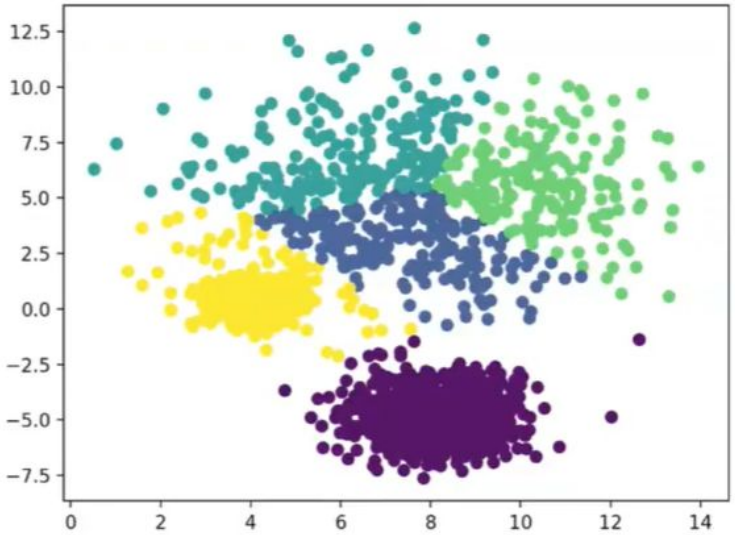
$$C_1 \cup C_2, \cdots \cup C_K = \{1, \ldots, n\}$$

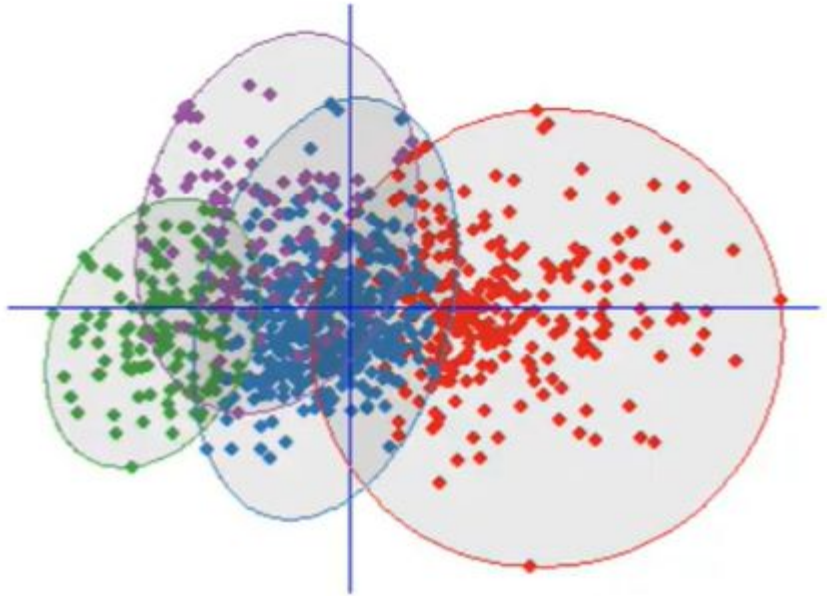
    - Estos conjuntos representan la partición de las observaciones

$$C_i \cap C_j = \emptyset, \ \forall i \neq j$$

¿Se usó k-means?

si es una partición





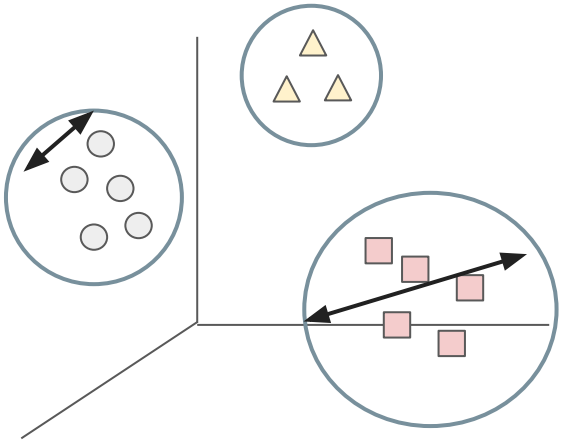
no es una partición

La idea de K-medias

Un **buen agrupamiento** es aquel que la variación dentro de un mismo cluster es pequeña.

Pero...

¿Cómo medimos la variación?



Baja variación dentro de un mismo cluster

Medida la variación W

La idea es establecer los clústeres de manera que se **minimice la variabilidad dentro de cada clúster**. Esta se mide como la suma de las distancias euclidianas al cuadrado entre los elementos y su respectivo centroide.

$$W(C_k) = \frac{1}{|C_k|} \sum_{i,j \in C_k} \sum_{l=1}^{p} (x_{il} - x_{jl})^2$$

- |Ck | el número de elementos de la clase k.
- p es la cantidad de variables.

WSSC (Within-Cluster Sum of Squares)

$$W(C_k) = \frac{1}{|C_k|} \sum_{i,j \in C_k} \sum_{l=1}^{p} (x_{il} - x_{jl})^2$$

Donde:

- C_k representa el cluster k
- $|C_k|$ es la cantidad de puntos de datos en el cluster C_k
- La primera sumatoria, $\sum_{i,j \in Ck}$, recorre todos los pares de puntos i y j dentro del cluster C_k
- La segunda sumatoria, $\sum^{p}_{i=1}$, recorre todas las dimensiones l (siendo p el número de dimensiones de los datos).
- x_{il} y x_{jl} son las coordenadas en la dimensión l para los puntos iy j, respectivamente

Medida la variación W

Queremos minimizar la variación total dentro del cluster:

$$min_{C_1,\dots,C_K} \sum_{k=1}^{K} W(C_k) = min_{C_1,\dots,C_K} \sum_{k=1}^{K} \frac{1}{|C_k|} \sum_{i,j \in C_k} \sum_{l=1}^{p} (x_{il} - x_{jl})^2$$

distancia euclídea al cuadrado es lo más usual

La suma total de cuadrados dentro del cluster mide la compacidad de la agrupación y queremos que sea lo más pequeña posible.

K-means es un algoritmo de optimización de esta función objetivo

El Algoritmo - Paso a Paso

Dado K

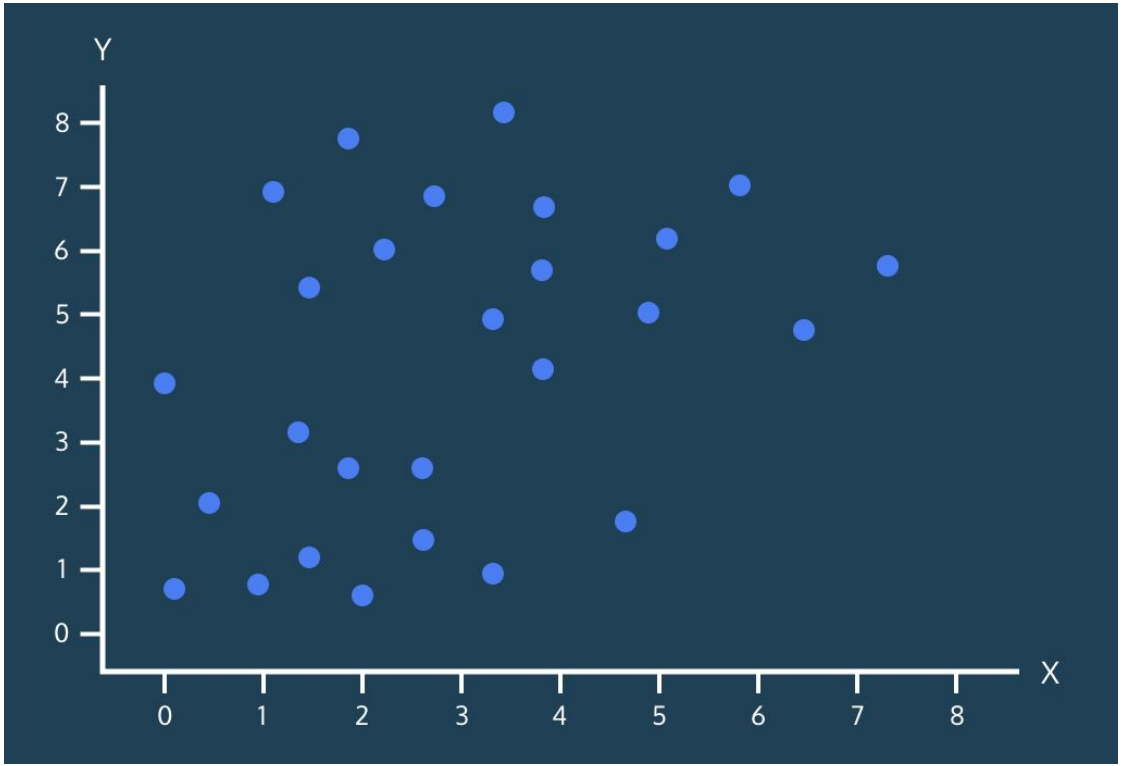
1. Asignar aleatoriamente un número de 1 a K a cada una de las observaciones
2. Realizar los siguientes pasos hasta que la asignación de clusters se mantenga estable de una iteración a otra.
   a. Para cada clase i, calcular el centroide $c^i = (c^i_1, c^i_2, \ldots, c^i_p)$ donde

$$c^i_j = \frac{1}{|C_i|} \sum_{l=1}^{|C_i|} x^j_l$$

   b. Asignar cada observación al cluster cuyo centroide está más cerca en distancia euclídea

El Algoritmo

1. Inicialización
2. Asignación
3. Actualizar
4. Repetir



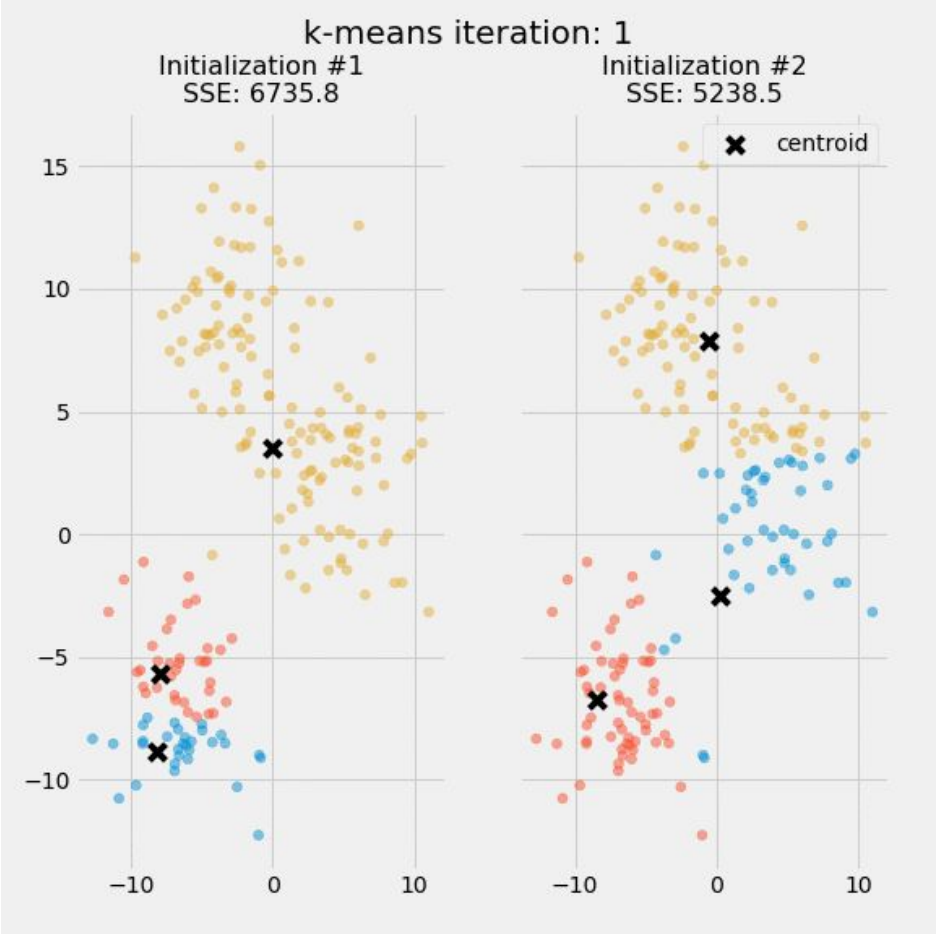
El Algoritmo

Observaciones:

- Cuando de un paso a otro no hay modificaciones, significa que se está en presencia de un mínimo local.
- El método modifica la clasificación si existe una mejoría, por lo tanto siempre converge a una clasificación mejorada.

K-means: Gif

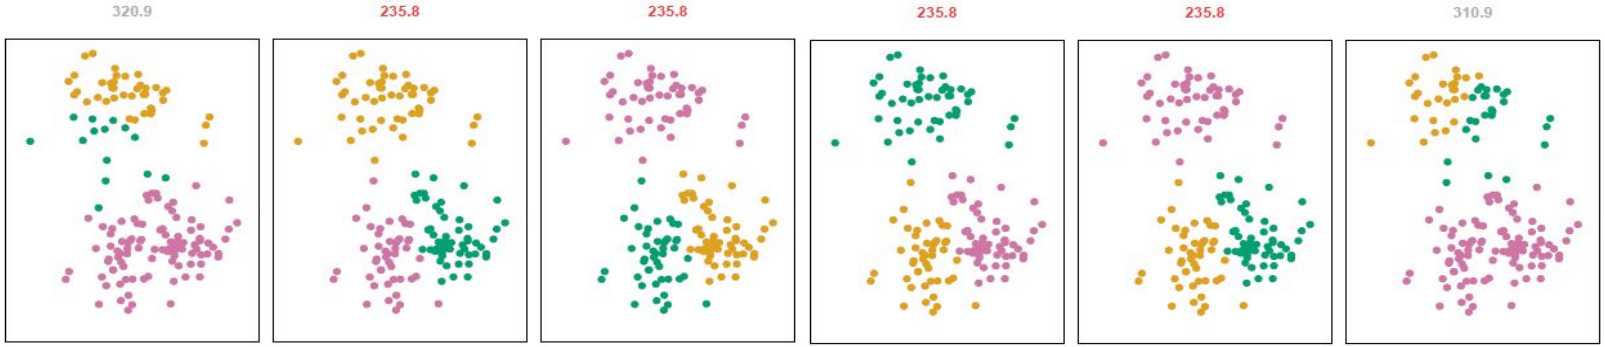



k-means iteration: 1
Initialization #1
SSE: 6735.8
Initialization #2
SSE: 5238.5
centroid
15
10
5
0
−5
−10
−10
0
10
−10
0
10

El Algoritmo

Inconveniente

El resultado final de la clasificación depende fuertemente de la asignación de clases que se haya utilizado en el primer paso del algoritmo.



Distintas inicializaciones del mismo modelo con los mismos datos

El Algoritmo

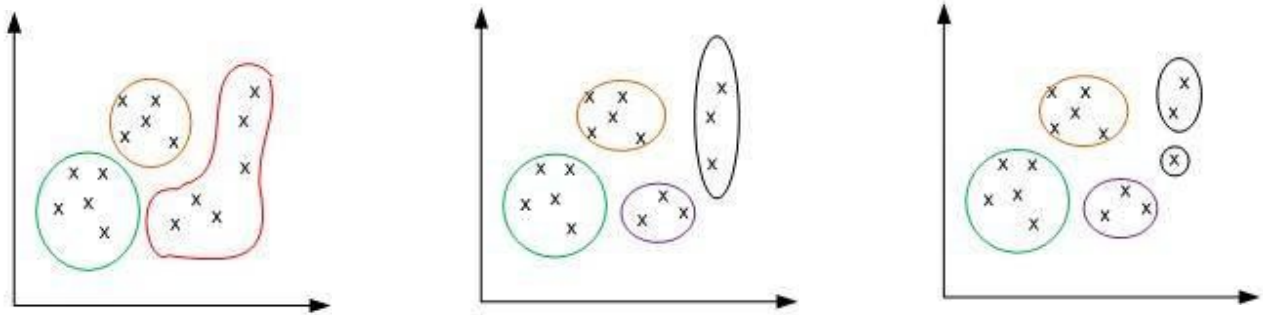
Para solucionarlo

- Aplicar el método varias veces.
- Elegir agrupamiento que minimiza

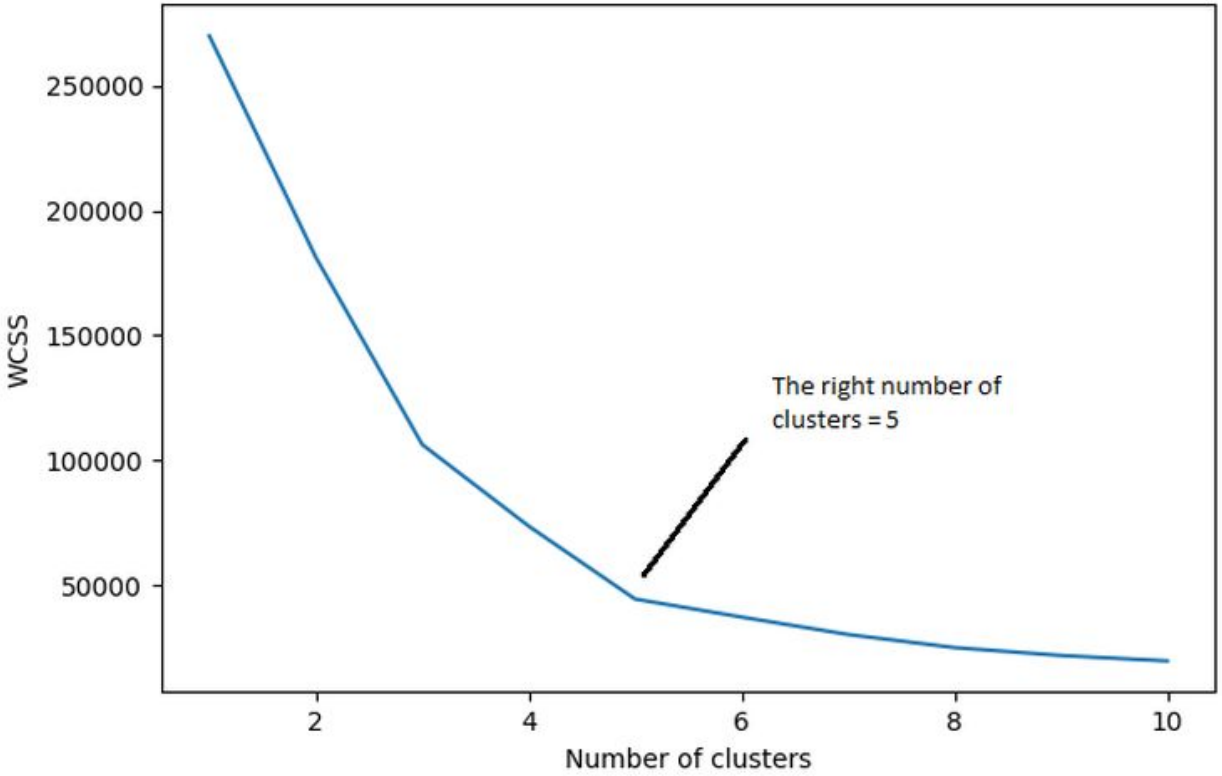
$$\sum_{k=1}^{K} W(C_k)$$

K-means: Elección de *k*

Al aumentar K, disminuye la variabilidad dentro de los clústeres, pero también se corre el riesgo de segmentar en exceso los datos. Por esto, es importante elegir k de manera de encontrar un equilibrio para obtener una segmentación útil y representativa sin caer en el extremo de la sobre segmentación..



Método del codo

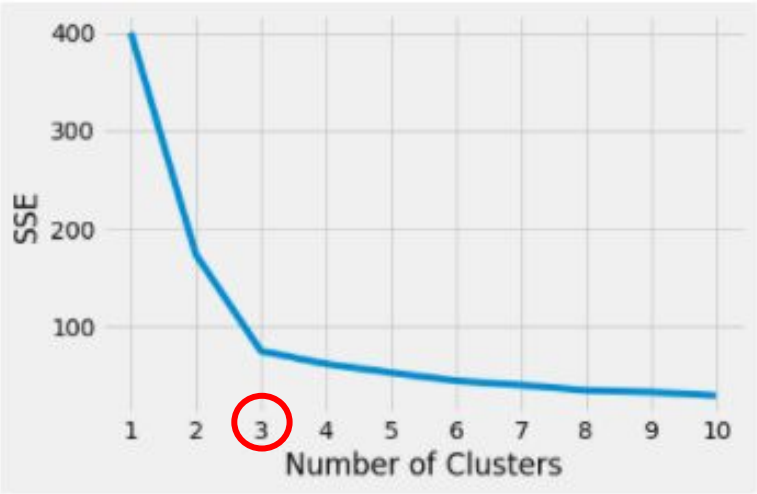


Para determinar el número óptimo de clusters, encuentra el "codo" donde la disminución de variabilidad se estabiliza.

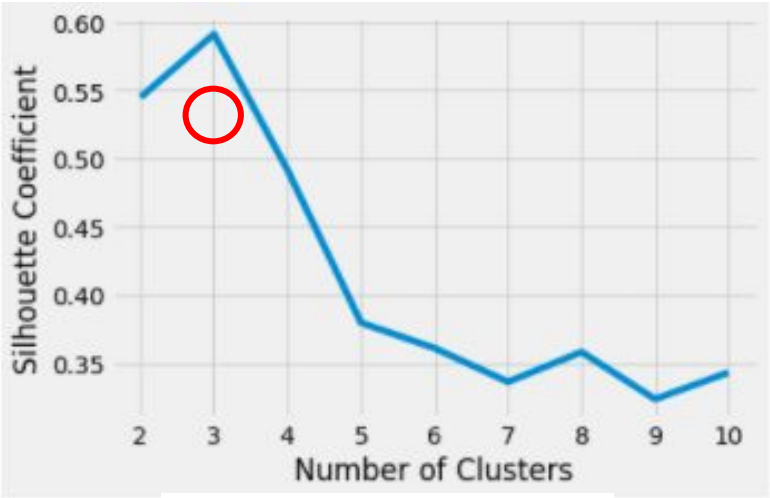
K-means: Elección de *k*

No es trivial elegir **k** en la mayoría de los dataset reales y no existe algún método que funcione siempre.

“Método del codo”



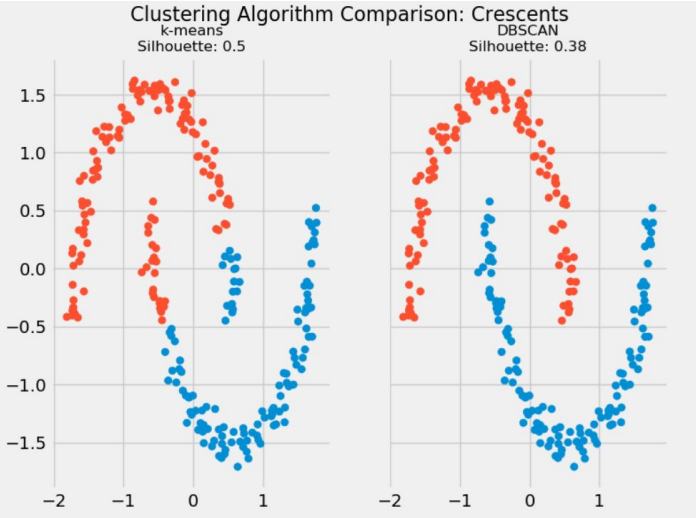
“coeficiente de Silhouette”

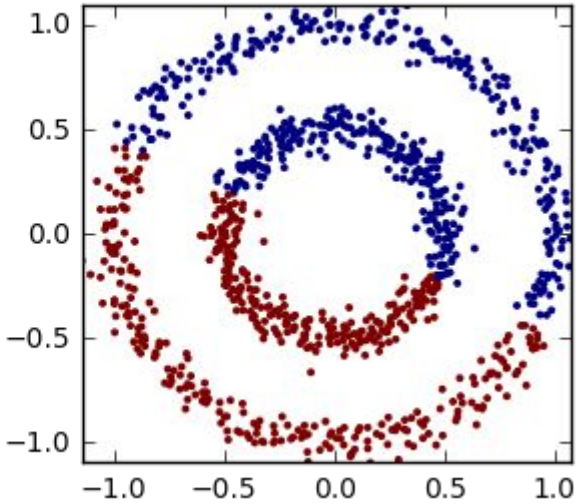


$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Limitaciones

K-Means asume clústeres con forma esférica y densidad uniforme, lo que puede llevar a tener dificultades para identificar adecuadamente estos grupos con densidades diferentes en diferentes partes de la media luna.

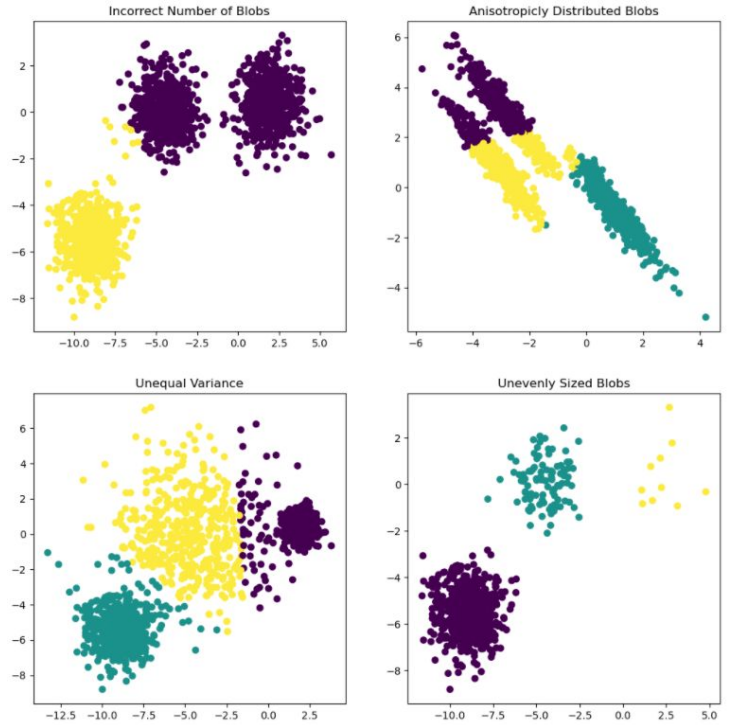




K-means: Pros y Cons

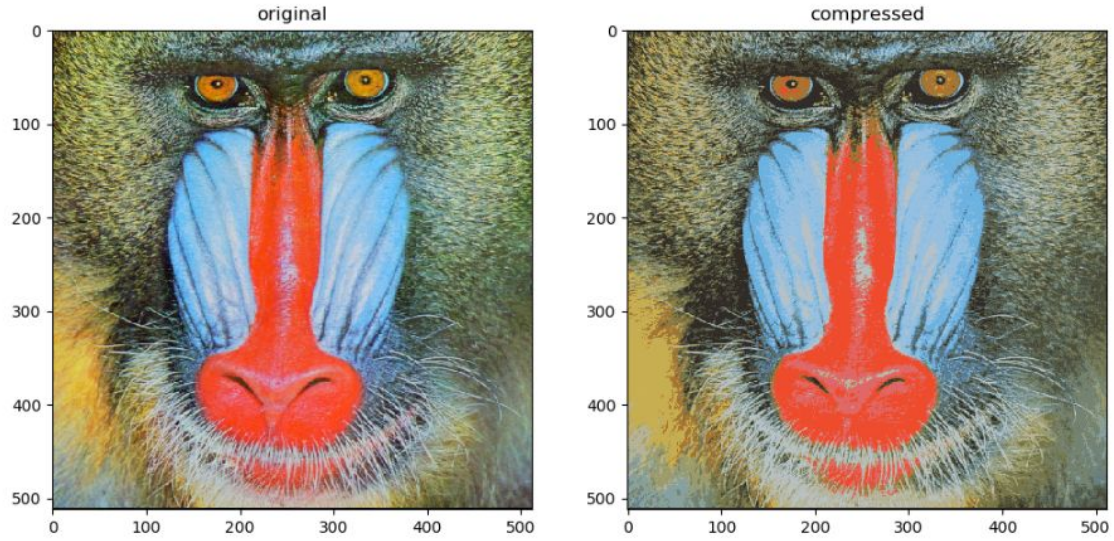
+ **Simple y Fácil de implementar**
+ **Orden del algoritmo es lineal**

- Depende de la inicialización
- Tiende a caer en un mínimo local
- Sensible a outliers
- Los clusters tienen que tener forma esférica
- No se puede aplicar a data categórica



Usos de K-medias

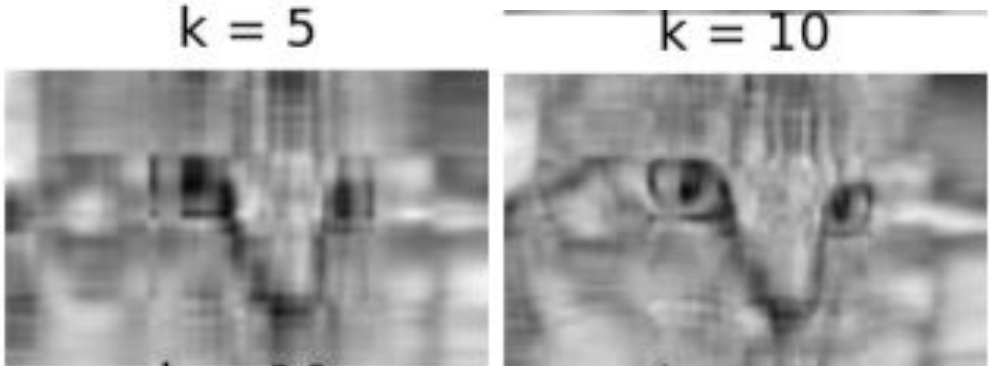
Reducir el tamaño del archivo de una imagen sin reducir significativamente su calidad.

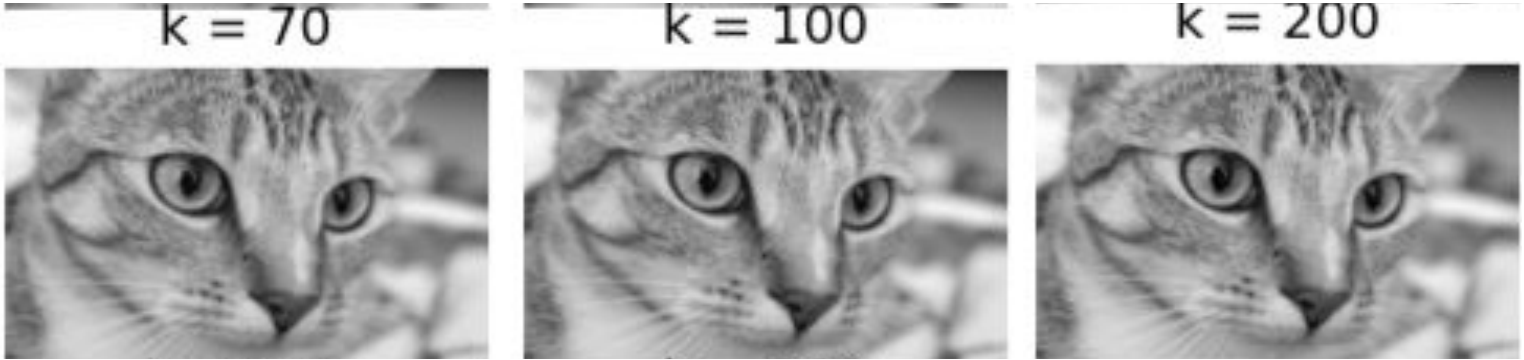


Reduciendo de 16,77 millones de colores a 16 colores

Usos de K-medias

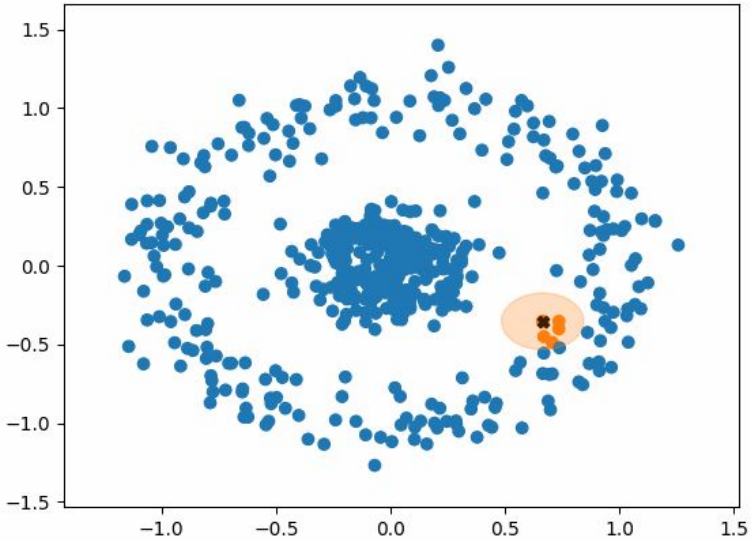






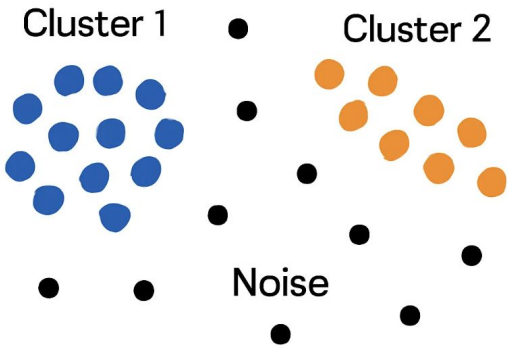
DBSCAN

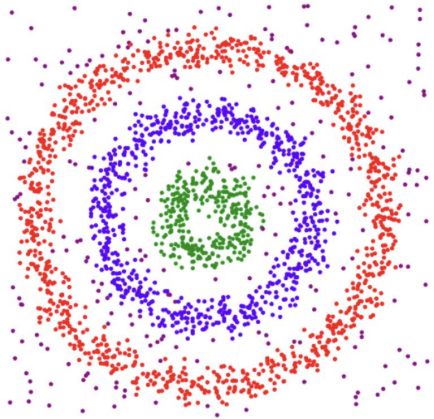
Density-Based Spatial Clustering of Applications with Noise



¿Qué es la agrupación de DBSCAN?

Tiene como objetivo agrupar puntos en función de su densidad local. Los puntos que tienen suficientes vecinos cercanos forman un grupo, mientras que los que están aislados se consideran ruido o anomalías.

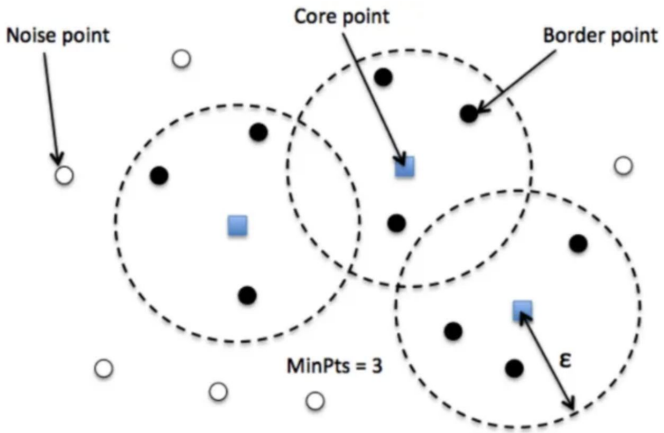




Algoritmo DBSCAN - Hiper parámetros

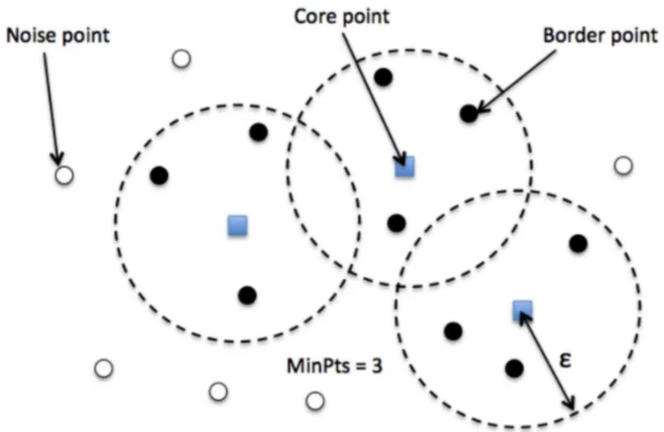
- ε (epsilon): radio de vecindad — define qué tan cerca deben estar dos puntos para considerarse vecinos.

- minPts: número mínimo de vecinos dentro del radio ε para que un punto sea considerado un punto núcleo (core point).



Algoritmo DBSCAN - Tipos de Puntos

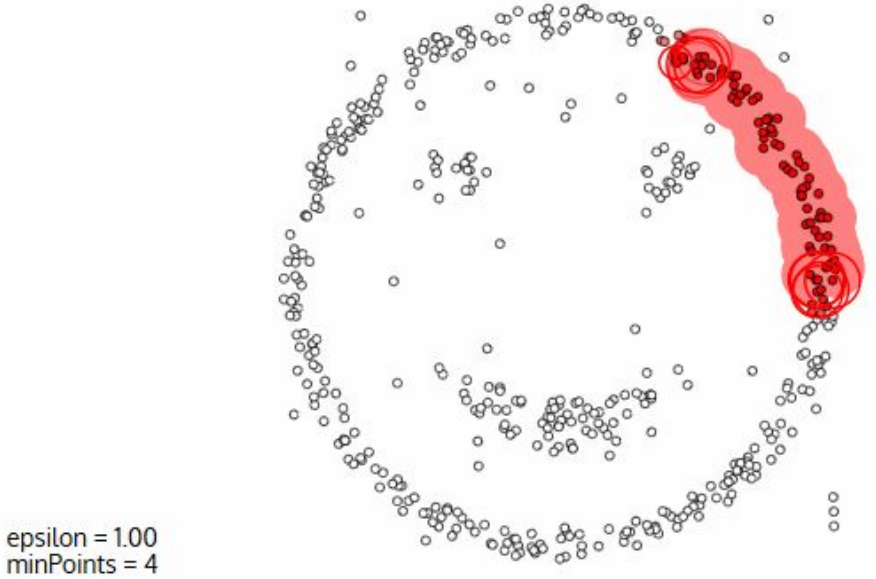
- Punto núcleo: tiene al menos minPts puntos (incluyéndose a sí mismo) dentro del radio ε.
- Punto alcanzable (border point): está dentro del radio ε de un punto núcleo, pero no tiene suficientes vecinos para ser núcleo.
- Punto ruido: no pertenece a ningún grupo ni está cerca de un punto núcleo.



Algoritmo DBSCAN - Paso a Paso

- Inicialización:
  - Marcar todos los puntos como no visitados.
  - Crear una lista vacía de clusters.
- Selección del punto:
  - Elegir un punto p no visitado y marcarlo como visitado.
- Búsqueda de vecinos:
  - Encontrar todos los puntos dentro del radio ε de p.
  - Si el número de vecinos < minPts, marcar p como ruido (por ahora)
  - Si el número de vecinos ≥ minPts, crear un nuevo cluster con p.
- Expansión del cluster:
  - Agregar todos los vecinos de p (los llamamos q) al cluster formado.
  - Para cada punto vecino q:
    - Si q no fue visitado, marcarlo como visitado.
    - Si q tiene al menos minPts vecinos, agregar esos vecinos al conjunto del cluster (de forma recursiva).
    - Si q no tiene menos de minPts vecinos se marca como punto frontera y detiene la expansión.
- Repetir:
  - Continuar hasta que todos los puntos hayan sido visitados.

Algoritmo DBSCAN - *Una imagen vale más que 1000 palabras*



Algoritmo DBSCAN - *Conclusiones*

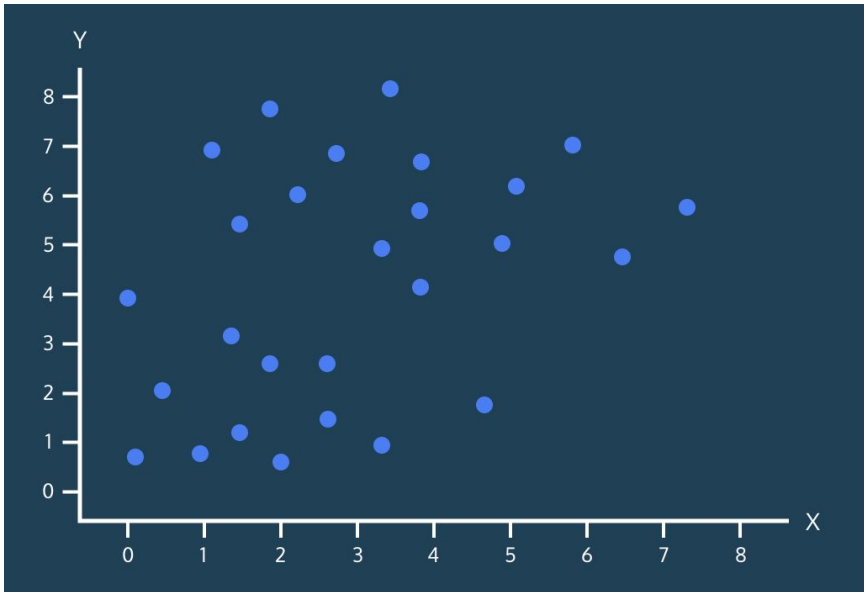
Ventajas:

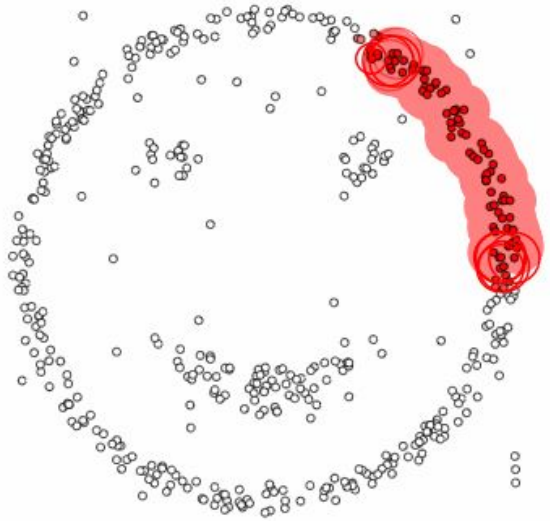
- No requiere número de grupos como hiperparámetro.
- Identifica outliers.
- Identifica clusters con formas variadas

Desventajas:

- La definición de ε (epsilon) y minPts
- No es resistente a grupos con distintas densidades.
- Menos eficiente en datasets grandes o de alta dimensionalidad.

Preguntas…





epsilon = 1.00
minPoints = 4

Reducción de Dimensionalidad

PCA y t-SNE

Reducción de Dimensionalidad

¿Por qué reducir dimensiones?

En datasets reales los datos tienen muchas variables (features):

- **Maldición de la dimensionalidad:** a mayor dimensión, el espacio crece exponencialmente y los puntos se vuelven escasos.
- **Ruido y redundancia:** muchas variables correlacionadas no agregan información real.
- **Costo computacional:** más dimensiones → más tiempo de entrenamiento
- **Dificultad de visualización:** los humanos solo podemos visualizar 2D o 3D.

Dos objetivos distintos: comprimir y visualizar datos.

PCA — Análisis de Componentes Principales

¿Qué es PCA?

PCA es un método lineal de reducción de dimensionalidad que transforma los datos originales en un nuevo conjunto de variables llamadas **componentes principales**, ordenadas por la cantidad de varianza que explican.

Propiedades clave:

- ✦ Las componentes son ortogonales entre sí (no están correlacionadas).
- ✦ La primera componente captura la mayor **varianza** posible.
- ✦ Cada componente siguiente captura la mayor varianza restante.
- ✦ Es un método no supervisado: no usa etiquetas.

PCA — Idea Geométrica

Intuición geométrica

PCA busca los ejes (componentes) en los que los datos tienen mayor dispersión (varianza). Proyectar sobre esos ejes conserva la mayor cantidad de información posible.

Pasos del algoritmo:

1. Estandarizar los datos
2. Calcular la matriz de covarianza.
3. Obtener los autovectores y autovalores de la covarianza.
4. Ordenar los autovectores por autovalor descendente → componentes principales.
5. Proyectar los datos sobre las primeras k componentes.

El resultado es un cambio de base: de p variables originales a k componentes ($k \leq p$).

PCA — Varianza Explicada

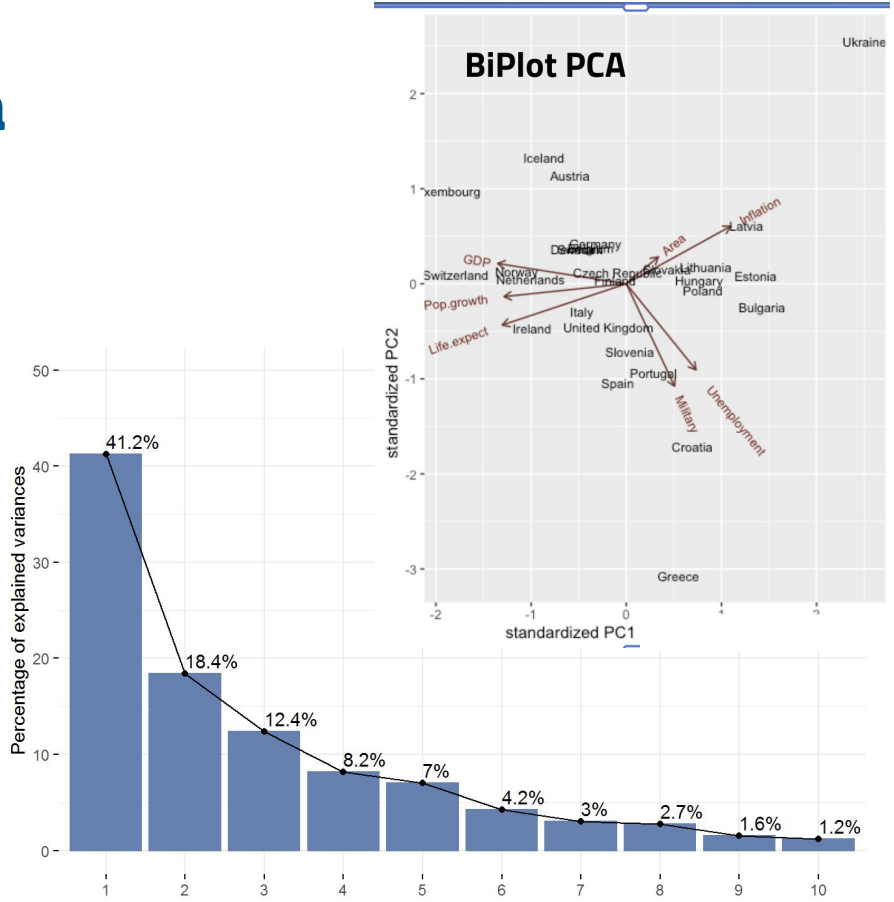
¿Cuántas componentes elegir?

Cada componente principal tiene asociada una proporción de la varianza total de los datos, llamada varianza explicada.

Criterios comunes:

- **Umbral de varianza acumulada:** elegir k tal que las primeras k componentes expliquen el x % de la varianza.
- **Gráfico de codo (scree plot):** graficar varianza explicada por componente y encontrar el "codo" — análogo al método del codo en K-means.

Nota: no existe un criterio universal — la elección depende del problema y del objetivo.



PCA — Pros y Cons

+ Ventajas

+ Reduce dimensionalidad manteniendo la mayor varianza posible.
+ Elimina correlaciones entre variables.
+ Útil como preprocesamiento para otros algoritmos de ML.
+ Resultados interpretables (loading de variables).
+ Computacionalmente eficiente.

- Limitaciones

- Solo captura relaciones lineales.
- Las componentes pueden ser difíciles de interpretar.
- Sensible a la escala de las variables (requiere estandarización).
- No preserva estructuras no lineales (clusters curvos, etc.).

t-SNE

t-distributed Stochastic Neighbor Embedding

t-SNE — ¿Qué es?

¿Qué problema resuelve?

t-SNE es un método **no lineal** diseñado específicamente para **explorar y visualizar datos de alta dimensión en 2D o 3D.**

Idea central:

t-SNE preserva las relaciones de vecindad local: puntos que eran cercanos en el espacio original tienden a quedar cercanos en la proyección 2D.

$$p_{j|i} = \frac{\exp\left(-\|x_i - x_j\|^2 / 2\sigma_i^2\right)}{\sum_{k \neq i} \exp\left(-\|x_i - x_k\|^2 / 2\sigma_i^2\right)},$$

Dimensión original (gaussiana)

$$C = \sum_i KL(P_i || Q_i)$$

Divergencia Kullback-Leibler

$$q_{ij} = \frac{\left(1 + \|y_i - y_j\|^2\right)^{-1}}{\sum_{k \neq l} \left(1 + \|y_k - y_l\|^2\right)^{-1}}.$$

Dimensión resultante (t-student)

t-SNE — Cómo funciona

Algoritmo

Paso 1: Para cada par de puntos en el espacio original, calcular una probabilidad de que sean "vecinos" usando una distribución gaussiana. Puntos cercanos → probabilidad alta.

Paso 2: En el espacio de baja dimensión (2D), inicializar los puntos aleatoriamente y calcular probabilidades de vecindad usando una distribución t de Student .

Paso 3: Optimizar iterativamente la posición de los puntos en 2D para que las distribuciones de vecindad se parezcan lo más posible (minimiza KL-divergence).

Algorithm 1: Simple version of t-Distributed Stochastic Neighbor Embedding.

Data: data set $\mathcal{X} = \{x_1, x_2, ..., x_n\}$,
cost function parameters: perplexity $Perp$,
optimization parameters: number of iterations T, learning rate η, momentum $\alpha(t)$.
Result: low-dimensional data representation $\mathcal{Y}^{(T)} = \{y_1, y_2, ..., y_n\}$.
begin
  compute pairwise affinities $p_{j|i}$ with perplexity $Perp$ (using Equation 1)
  set $p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$
  sample initial solution $\mathcal{Y}^{(0)} = \{y_1, y_2, ..., y_n\}$ from $\mathcal{N}(0, 10^{-4}I)$
  for t=1 **to** T **do**
    compute low-dimensional affinities q_{ij} (using Equation 4)
    compute gradient $\frac{\delta C}{\delta \mathcal{Y}}$ (using Equation 5)
    set $\mathcal{Y}^{(t)} = \mathcal{Y}^{(t-1)} + \eta \frac{\delta C}{\delta \mathcal{Y}} + \alpha(t)\left(\mathcal{Y}^{(t-1)} - \mathcal{Y}^{(t-2)}\right)$
  end
end

$$\frac{\delta C}{\delta y_i} = 4 \sum_j (p_{ij} - q_{ij})(y_i - y_j)\left(1 + \|y_i - y_j\|^2\right)^{-1}.$$

t-SNE — Hiperparámetro: Perplejidad

Perplejidad (perplexity)

La perplejidad controla el balance entre estructura local y global. Informalmente, indica cuántos vecinos cercanos considera cada punto al calcular sus probabilidades de vecindad.

Valores típicos: entre 5 y 50 (default = 30).

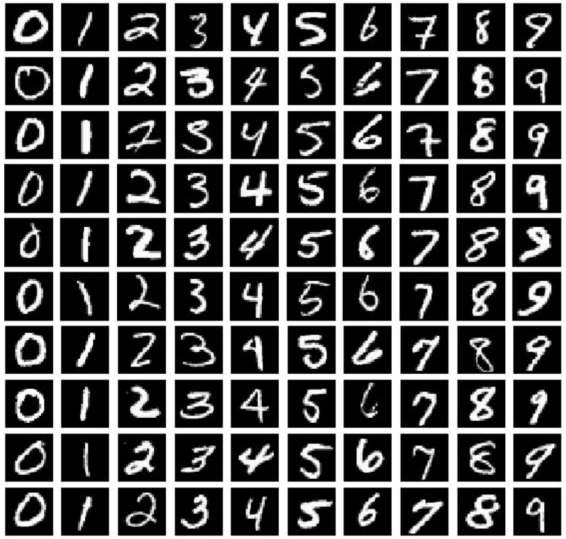
- **Perplejidad baja (5–10):** captura estructuras muy locales; puede fragmentar clusters reales.
- **Perplejidad media (30):** balance recomendado para la mayoría de los datasets.
- **Perplejidad alta (50+):** captura más estructura global; clusters pueden solaparse más.

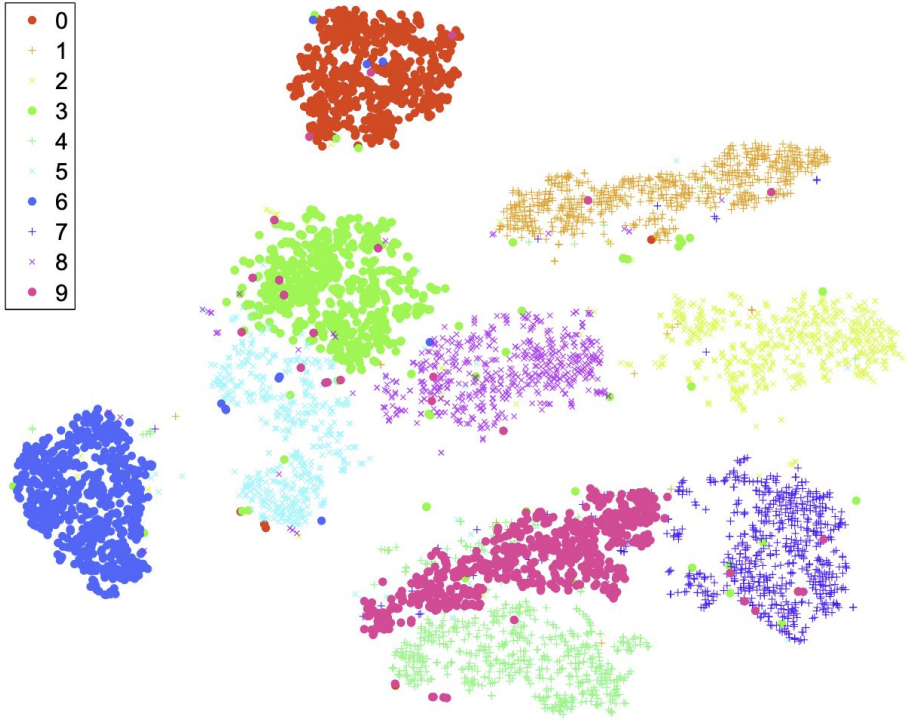
⚠ **Las distancias ENTRE clusters en un plot de t-SNE NO son interpretables. Solo es significativa la cohesión interna de cada grupo.**

t-SNE — MNIST

Dataset MNIST

Resultado de aplicar t-SNE al dataset de números de MNIST





PCA vs t-SNE — Comparación

